


Ventajas y límites de la inferencia exacta

Semana 2

Aplicación estricta de las reglas de la probabilidad. Ejemplos Gaussian y Beta-Binomial

El problema histórico de la probabilidad: el costo computacional. Efectos secundarios de la ruptura de las reglas de la probabilidad: el overfitting. Evaluación de modelos polinomiales de complejidad creciente. No identificabilidad de modelos



El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

- Siglo 18: Nace la probabilidad (soluciones analíticas).

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

- Siglo 18: Nace la probabilidad (soluciones analíticas).
- Siglo 19: Física estadística (contar estados).

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.

- Siglo 18: Nace la probabilidad (soluciones analíticas).
- Siglo 19: Física estadística (contar estados).
- Siglo 20: Estimadores puntuales (evitan evaluar todo el espacio de hipótesis).

El costo computacional

Problema histórico de la probabilidad

La **aplicación estricta** de las reglas de la probabilidad obligan a **evaluar todo el espacio de hipótesis**.


- Siglo 18: Nace la probabilidad (soluciones analíticas).
- Siglo 19: Física estadística (contar estados).
- Siglo 20: Estimadores puntuales (evitan evaluar todo el espacio de hipótesis).
- Siglo 21: Comienza a ser posible evaluar todo el espacio de hipótesis mediante la (aproximación a) la aplicación estricta de las reglas de la probabilidad de forma general

Siglo 18: la primera solución analítica.


¿A quién le compro?

- 100% Me gusta de 10 Ratings
- 96% Me gusta de 50 Ratings
- 93% Me gusta de 200 Ratings


Siglo 18: la primera solución analítica.





Siglo 18: la primera solución analítica.




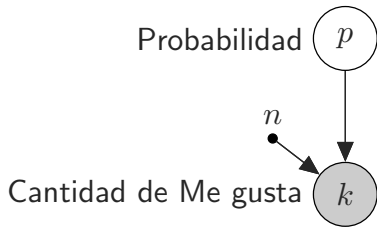
Siglo 18: la primera solución analítica.




Siglo 18: la primera solución analítica.




Siglo 18: la primera solución analítica.




Siglo 18: la primera solución analítica.



Siglo 18: la primera solución analítica.




Siglo 18: la primera solución analítica.




$$P(p | k, n) = \frac{P(k | p, n)P(p)}{P(k | n)}$$

Siglo 18: la primera solución analítica.




$$P(p | k, n) = \frac{P(k | p, n)P(p)}{P(k | n)} = \underbrace{(n+1)}_{1/P(k|n)} \underbrace{\frac{n!}{k!(n-k)!} p^k (1-p)^{n-k}}_{P(k|p,n)} \underbrace{1}_{P(p)}$$

Siglo 18: la primera solución analítica.




$$P(p | k, n) = \frac{P(k | p, n)P(p)}{P(k | n)} = \frac{(n+1)!}{k!(n-k)!} p^k (1-p)^{n-k}$$

Siglo 18: la primera solución analítica.



$$P(p | k, n) = \frac{P(k | p, n) P(p)}{P(k | n)}$$

- 100%, $n=10$
- 96%, $n=50$
- 93%, $n=200$



Siglo 19: Física estadística

Gases

Micro Estados

•	•		•	
		•		•
	•		•	•
•		•		

$$\left. \begin{array}{l} N = 10 \\ V = 20 \end{array} \right\} \text{Macro estados}$$

Siglo 19: Física estadística

Gases

Micro Estados

•	•		•	
		•		•
	•		•	•
•		•		

$$\left. \begin{array}{l} N = 10 \\ V = 20 \end{array} \right\} \text{Macro estados}$$

Expansión de volumen

•			•				•	
				•		•		
	•						•	
•				•				•

$$\begin{array}{l} N = 10 \\ V = 40 \end{array}$$

Siglo 19: Física estadística

Gases

Micro Estados

•	•		•	
		•		•
	•		•	•
•		•		

$$\left. \begin{array}{l} N = 10 \\ V = 20 \end{array} \right\} \text{Macro estados}$$

Expansión de volumen

•			•				•	
				•		•		
	•						•	
•				•				•

$$\begin{array}{l} N = 10 \\ V = 40 \end{array}$$

¿Cuál es la probabilidad de que se contraiga nuevamente?

Siglo 19: Física estadística

Gases

Micro Estados

•	•		•	
		•		•
	•		•	•
•		•		

$$\left. \begin{array}{l} N = 10 \\ V = 20 \end{array} \right\} \text{Macro estados}$$

$$W = \binom{20}{10} = 184\,756$$

Expansión de volumen

•			•				•	
				•		•		
	•						•	
•				•				•

$$\begin{array}{l} N = 10 \\ V = 40 \end{array}$$

Siglo 19: Física estadística

Gases

Micro Estados

•	•		•	
		•		•
	•		•	•
•		•		

$$\left. \begin{array}{l} N = 10 \\ V = 20 \end{array} \right\} \text{Macro estados}$$

$$W = \binom{20}{10} = 184\,756$$

Expansión de volumen

•			•				•	
				•		•		
	•						•	
•				•				•

$$\begin{array}{l} N = 10 \\ V = 40 \end{array} \quad W = \binom{40}{10} = 847\,660\,528$$

Siglo 19: Física estadística

Gases

Micro Estados

•	•		•	
		•		•
	•		•	•
•		•		

$$\left. \begin{array}{l} N = 10 \\ V = 20 \end{array} \right\} \text{Macro estados}$$

$$W = \binom{20}{10} = 184\,756$$

Expansión de volumen

•			•				•	
				•		•		
	•						•	
•				•				•

$$\begin{array}{l} N = 10 \\ V = 40 \end{array} \quad W = \binom{40}{10} = 847\,660\,528$$


$$P(\text{contraiga} | N = 10, V = 40) = \frac{\binom{20}{10}}{\binom{40}{10}} = 0.0002$$

Modelos gaussianos




Modelos gaussianos

Arco y flecha | Habilidad y desempeño




Modelos gaussianos

Arco y flecha | Habilidad y desempeño



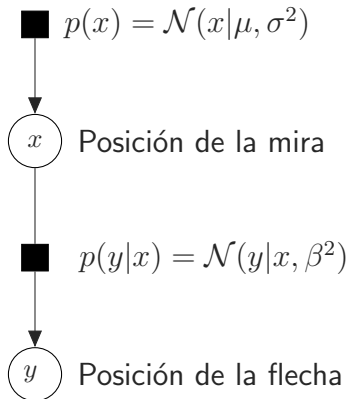
Modelos gaussianos

Arco y flecha | Habilidad y desempeño



Modelos gaussianos

Arco y flecha | Habilidad y desempeño



Modelos gaussianos

Arco y flecha | Habilidad y desempeño

■ $p(x) = \mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$

↓
○ x Posición de la mira

■ $p(y|x) = \mathcal{N}(y|x, \beta^2)$

↓
○ y Posición de la flecha

Modelos gaussianos

Arco y flecha | Habilidad y desempeño

■ $p(x) = \mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$




Posición de la mira



$p(y|x) = \mathcal{N}(y|x, \beta^2)$



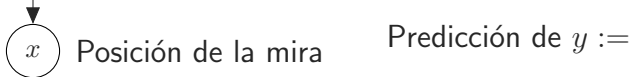
Posición de la flecha




Modelos gaussianos

Arco y flecha | Habilidad y desempeño

■ $p(x) = \mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$



■ $p(y|x) = \mathcal{N}(y|x, \beta^2)$



Modelos gaussianos

Arco y flecha | Habilidad y desempeño

■ $p(x) = \mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$



Posición de la mira

Predicción de $y := p(y)$



$p(y|x) = \mathcal{N}(y|x, \beta^2)$

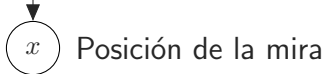


Posición de la flecha

Modelos gaussianos


Arco y flecha | Habilidad y desempeño

■ $p(x) = \mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$



Predicción de $y := p(y) = \int \mathcal{N}(y|x, \beta^2) \mathcal{N}(x|\mu, \sigma^2) dx$

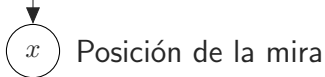
■ $p(y|x) = \mathcal{N}(y|x, \beta^2)$




Modelos gaussianos

Arco y flecha | Habilidad y desempeño


■ $p(x) = \mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$



■ $p(y|x) = \mathcal{N}(y|x, \beta^2)$



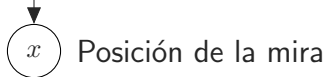
Predicción de $y := p(y) = \int \mathcal{N}(y|x, \beta^2) \mathcal{N}(x|\mu, \sigma^2) dx$




Modelos gaussianos

Arco y flecha | Habilidad y desempeño


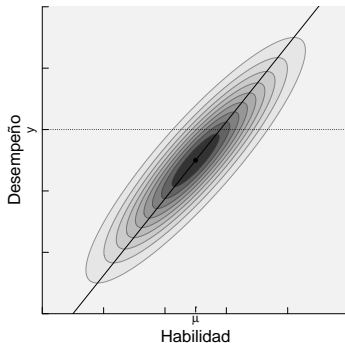
■ $p(x) = \mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$



■ $p(y|x) = \mathcal{N}(y|x, \beta^2)$

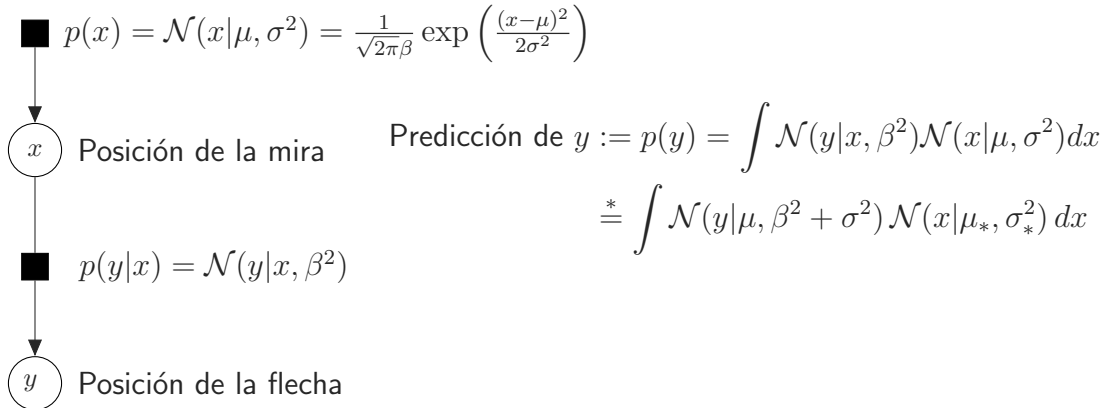


Predicción de $y := p(y) = \int \mathcal{N}(y|x, \beta^2) \mathcal{N}(x|\mu, \sigma^2) dx$



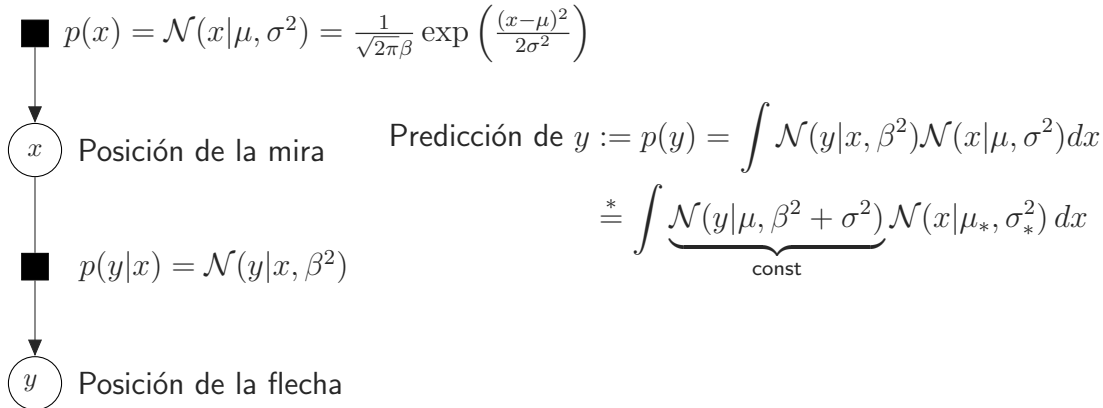
Modelos gaussianos

Arco y flecha | Habilidad y desempeño



Modelos gaussianos

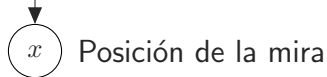
Arco y flecha | Habilidad y desempeño




Modelos gaussianos

Arco y flecha | Habilidad y desempeño

■ $p(x) = \mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$



■ $p(y|x) = \mathcal{N}(y|x, \beta^2)$




Predicción de $y := p(y) = \int \mathcal{N}(y|x, \beta^2) \mathcal{N}(x|\mu, \sigma^2) dx$

$$\stackrel{*}{=} \int \underbrace{\mathcal{N}(y|\mu, \beta^2 + \sigma^2)}_{\text{const}} \underbrace{\mathcal{N}(x|\mu_*, \sigma_*^2)}_1 dx$$


Modelos gaussianos

Arco y flecha | Habilidad y desempeño

■ $p(x) = \mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$



■ $p(y|x) = \mathcal{N}(y|x, \beta^2)$



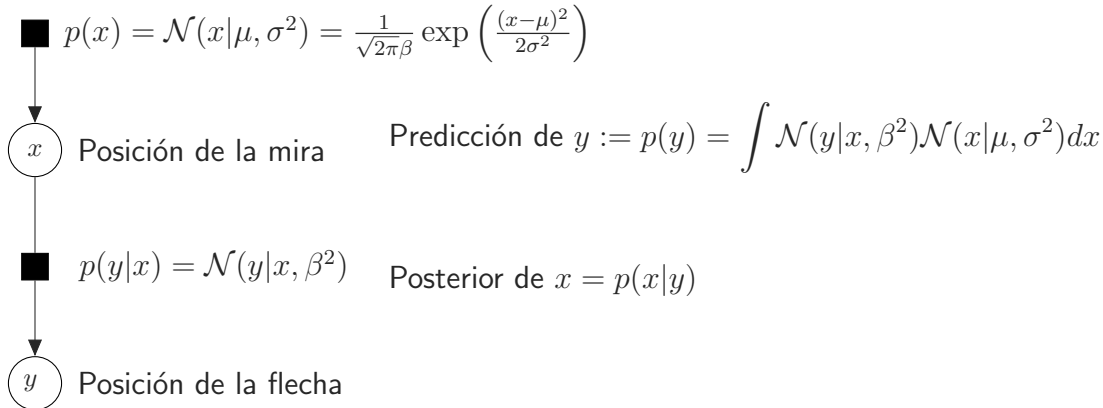
Predicción de $y := p(y) = \int \mathcal{N}(y|x, \beta^2) \mathcal{N}(x|\mu, \sigma^2) dx$

$$\stackrel{*}{=} \int \underbrace{\mathcal{N}(y|\mu, \beta^2 + \sigma^2)}_{\text{const}} \underbrace{\mathcal{N}(x|\mu, \sigma^2)}_1 dx$$

$$= \mathcal{N}(y|\mu, \beta^2 + \sigma^2)$$


Modelos gaussianos

Arco y flecha | Habilidad y desempeño



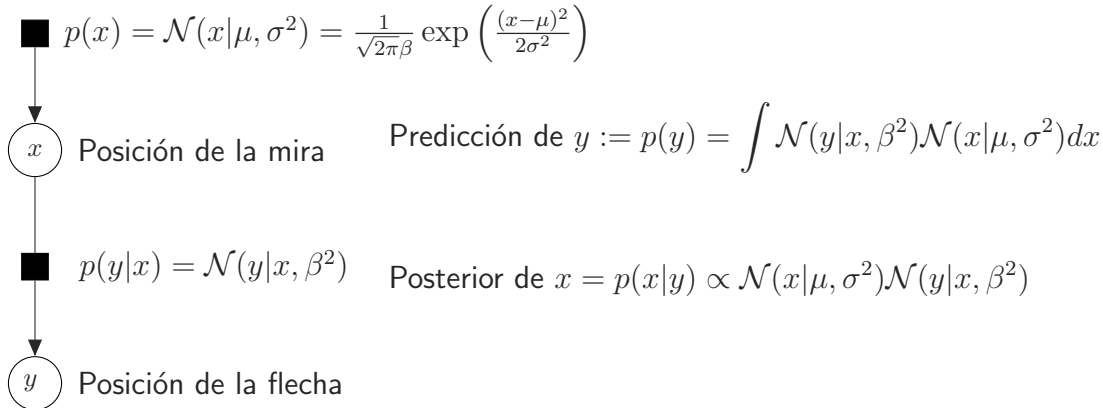
Modelos gaussianos

Arco y flecha | Habilidad y desempeño



Modelos gaussianos

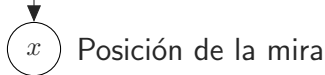
Arco y flecha | Habilidad y desempeño




Modelos gaussianos

Arco y flecha | Habilidad y desempeño

■ $p(x) = \mathcal{N}(x|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$



Predicción de $y := p(y) = \int \mathcal{N}(y|x, \beta^2) \mathcal{N}(x|\mu, \sigma^2) dx$



Posterior de $x = p(x|y) \propto \mathcal{N}(x|\mu, \sigma^2) \mathcal{N}(y|x, \beta^2)$

Modelos lineales

(lineales en las hipótesis)

Modelos lineales

(lineales en las hipótesis)

$$p(y|x, \mathbf{w}, \beta) = \mathcal{N} \left(y \mid \sum_i w_i \cdot \phi_i(x), \beta^2 \right)$$

Modelos lineales


(lineales en las hipótesis)

$$p(y|x, \mathbf{w}, \beta) = \mathcal{N}\left(y \mid \sum_i w_i \cdot \phi_i(x), \beta^2\right) \quad p(w_i) = \mathcal{N}(w_i \mid 0, \sigma_i^2)$$

Modelos lineales

(lineales en las hipótesis)


$$p(y|x, \mathbf{w}, \beta) = \mathcal{N}\left(y \mid \sum_i w_i \cdot \phi_i(x), \beta^2\right) \quad p(w_i) = \mathcal{N}(w_i \mid 0, \sigma_i^2)$$



Modelos lineales

(lineales en las hipótesis)


$$p(y|x, \mathbf{w}, \beta) = \mathcal{N}\left(y \mid \sum_i w_i \cdot \phi_i(x), \beta^2\right) \quad p(w_i) = \mathcal{N}(w_i \mid 0, \sigma_i^2)$$



Modelos lineales

Función objetivo


$$\mathcal{N}(y \mid \sin(2\pi x), \beta^2) \quad x \in \left[-\frac{1}{2}, \frac{1}{2}\right]$$



Modelos lineales

Función objetivo

$$\mathcal{N}(y \mid \sin(2\pi x), \beta^2) \quad x \in \left[-\frac{1}{2}, \frac{1}{2}\right]$$




$$y = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + \dots$$

Modelos lineales

Función objetivo

$$\mathcal{N}(y \mid \sin(2\pi x), \beta^2) \quad x \in \left[-\frac{1}{2}, \frac{1}{2}\right]$$



$$y = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + \dots$$

$$y = \sum_{i=0}^M w_i \cdot x^i$$

¿Cuál es el mejor modelo polinomial?

Siglo 20: Estimadores puntuales


~~Evaluación~~ Selección de hipótesis

$$\max_{\boldsymbol{w}} P(\boldsymbol{y}|\boldsymbol{x}, \boldsymbol{w}, \beta) = \min_{\boldsymbol{w}} \sum_{i=1}^n (y_i - f(x_i, \boldsymbol{w}))^2$$

Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis



$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$



Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis



$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$



Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$



Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\boldsymbol{w}} P(\boldsymbol{y}|\boldsymbol{x}, \boldsymbol{w}, \beta) = \min_{\boldsymbol{w}} \sum_{i=1}^n (y_i - f(x_i, \boldsymbol{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = \sum_{\text{hipótesis}} P(\text{dato} | \text{hipótesis}, \text{Modelo}) P(\text{hipótesis}|\text{Modelo})$$

Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\boldsymbol{w}} P(\boldsymbol{y}|\boldsymbol{x}, \boldsymbol{w}, \beta) = \min_{\boldsymbol{w}} \sum_{i=1}^n (y_i - f(x_i, \boldsymbol{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = P(\text{dato} \mid \text{hipótesis}, \text{Modelo})$$

Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = P(\text{dato} \mid \text{hipótesis}, \text{Modelo})$$

$$= P(\text{dato} \mid \overbrace{\arg \max_h P(\text{dato}|h, \text{Modelo})}^{\text{Hipótesis que mejor predice}}, \text{Modelo})$$

Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = P(\text{dato} \mid \text{hipótesis}, \text{Modelo})$$

$$= P(\text{dato} \mid \overbrace{\arg \max_h P(\text{dato}|h, \text{Modelo})}^{\text{Hipótesis que mejor predice}}, \text{Modelo})$$

¿Predecimos o “post-decimos”?

Siglo 20: Estimadores puntuales

~~Evaluación~~ Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$

$$P(\text{dato}|\text{Modelo}) = P(\text{dato} \mid \text{hipótesis}, \text{Modelo})$$

$$= P(\text{dato} \mid \overbrace{\arg \max_h P(\text{dato}|h, \text{Modelo})}^{\text{Hipótesis que mejor predice}}, \text{Modelo})$$

$$P(\text{dato}_{\text{Testear}}|\text{Modelo}) = P(\text{dato}_{\text{Testear}} \mid \arg \max_h P(\text{dato}_{\text{Entrenar}}|h, \text{Modelo}), \text{Modelo})$$



Testeo y Entrenamiento

Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis

$$\max_{\mathbf{w}} P(\mathbf{y}|\mathbf{x}, \mathbf{w}, \beta) = \min_{\mathbf{w}} \sum_{i=1}^n (y_i - f(x_i, \mathbf{w}))^2$$

Con testeo y entrenamiento





Siglo 20: Estimadores puntuales

Evaluación Selección de hipótesis

Perio si empezamos a ver datos $x \notin [-\frac{1}{2}, \frac{1}{2}]$ este modelo no sirve!

Con testeo y entrenamiento



¿Será que la aplicación estricta de las reglas de la probabilidad produce sobreajuste (*overfitting*)?

¿Será que la aplicación estricta de las reglas de la probabilidad produce sobreajuste (*overfitting*)?

¿Y entonces el sistema de razonamiento en contextos de incertidumbre funciona mal?

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad

El modelo lineal tiene solución analítica!

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad

El modelo lineal tiene solución analítica!

- Para evaluar las hipótesis al interior de los modelos (**posterior**),

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo})$$

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad

El modelo lineal tiene solución analítica!

- Para evaluar las hipótesis al interior de los modelos (**posterior**),

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo})$$

- Y para evaluar modelos alternativos (**evidencia**),

$$P(\text{Datos}|\text{Modelos})$$

Evidencia y Posterior

Dado el prior $p(\mathbf{w})$ y el likelihood $p(\mathbf{y}|\mathbf{w})$

$$p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\boldsymbol{\mu}, \boldsymbol{\Lambda}^{-1}) \quad p(\mathbf{y}|\mathbf{w}) = \mathcal{N}(\mathbf{y}|\mathbf{A}\mathbf{w} + \mathbf{b}, \mathbf{L}^{-1})$$


Obtenemos la evidencia $p(\mathbf{y})$, y el posterior $p(\mathbf{w}|\mathbf{y})$.

$$p(\mathbf{y}) = \mathcal{N}(\mathbf{y}|\mathbf{A}\boldsymbol{\mu} + \mathbf{b}, \mathbf{L}^{-1} + \mathbf{A}\boldsymbol{\Lambda}^{-1}\mathbf{A}^T)$$

$$p(\mathbf{w}|\mathbf{y}) = \mathcal{N}(\mathbf{w}|\boldsymbol{\Sigma} (\mathbf{A}^T\mathbf{L}(\mathbf{y} - \mathbf{b}) + \boldsymbol{\Lambda}\boldsymbol{\mu}), \boldsymbol{\Sigma})$$


$$\text{con } \boldsymbol{\Sigma} = (\boldsymbol{\Lambda} + \mathbf{A}^T\mathbf{L}\mathbf{A})^{-1}$$

$$P(\text{Hipótesis}|\text{Datos, Modelo})$$




$$P(\text{Hipótesis}|\text{Datos, Modelo})$$

Priori




Espacio de datos





Verosimilitud



$$P(\text{Hipótesis}|\text{Datos, Modelo})$$



Priori/Posteriori



Espacio de datos

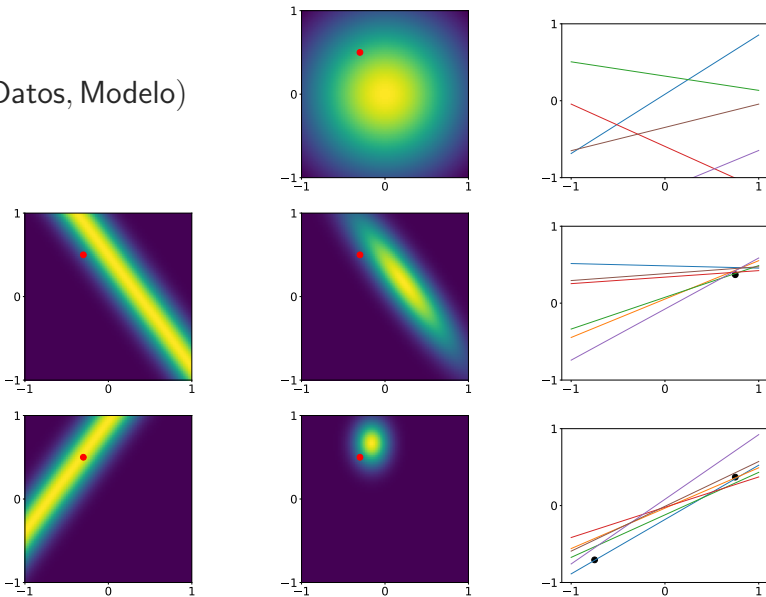


Verosimilitud

Priori/Posteriori

Espacio de datos

$$P(\text{Hipótesis}|\text{Datos, Modelo})$$



La función de costo epistémica

Todos los datos son de testeo y entrenamiento:

$$\underbrace{P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo})}_{\text{Evidencia: predicción del modelo}} = \underbrace{P(d_1 | \text{Modelo})}_{\text{Predicción 1}} \underbrace{P(d_2 | d_1, \text{Modelo})}_{\text{Predicción 2}} \dots$$

La función de costo epistémica

Todos los datos son de testeo y entrenamiento:


$$\underbrace{P(\text{Datos} = \{d_1, d_2, \dots\} | \text{Modelo})}_{\text{Evidencia: predicción del modelo}} = \underbrace{P(d_1 | \text{Modelo})}_{\text{Predicción 1}} \underbrace{P(d_2 | d_1, \text{Modelo})}_{\text{Predicción 2}} \dots$$

La predicción se hace con todas las hipótesis


$$P(\text{dato}_1 | \text{Modelo}) = \sum_{\text{hipótesis}} P(\text{dato}_1 | \text{hipótesis}, \text{Modelo}) P(\text{hipótesis} | \text{Modelo})$$

Siglo 21: Inferencia exacta

Aplicación estricta de las reglas de la probabilidad




$$P(\text{Modelo}|\text{Datos})$$



Evidencia

Balance natural entre complejidad y predicción



La verdadera predicción

Predicción con la contribución de todos los modelos


$$P(\text{Datos}) = \sum_{\text{Modelo}} P(\text{Datos}|\text{Modelo})P(\text{Modelo})$$

La verdadera predicción

Predicción con la contribución de todos los modelos

$$P(\text{Datos}) = \sum_{\text{Modelo}} P(\text{Datos}|\text{Modelo})P(\text{Modelo})$$

Si aparecen datos $x \notin [-\frac{1}{2}, \frac{1}{2}]$ van a poder ser explicados con los modelos más complejos



Ejercicio: Identificación de modelo causal

$P(A)$	
$A = 0$	$A = 1$
0.5	0.5

	$P(B A)$	
	$B = 0$	$B = 1$
$A = 0$	0.95	0.05
$A = 1$	0.05	0.95



Ejercicio: Identificación de modelo causal

$P(A)$				$P(A B)$	
	$A = 0$	$A = 1$			$A = 0$ $A = 1$
	0.5	0.5			$B = 0$ 0.95 0.05
			A		$B = 1$ 0.05 0.95
			↓		
$P(B A)$	$B = 0$	$B = 1$	B	A	
$A = 0$	0.95	0.05		↑	
$A = 1$	0.05	0.95			
					$P(B)$
	$B = 0$	$B = 1$			$B = 0$ $B = 1$
	0.5	0.5			0.5 0.5

Ejercicio: Identificación de modelo causal

$P(A)$					
	$A = 0$	$A = 1$			
	0.5	0.5			
$P(B A)$					
	$B = 0$	$B = 1$			
$A = 0$	0.95	0.05			
$A = 1$	0.05	0.95			

A_i

↓

B_i

i : Dato

A_i

↑

B_i

i : Dato

$P(A B)$		$A = 0$	$A = 1$
$B = 0$	0.95	0.05	
$B = 1$	0.05	0.95	

$P(B)$		$B = 0$	$B = 1$
	0.5	0.5	

$$P(\text{Modelo} | \text{Datos} = \{(a_1, b_1), (a_2, b_2), \dots\}) =$$

Ejercicio: Identificación de modelo causal

$P(A)$					
	$A = 0$	$A = 1$			
	0.5	0.5			
$P(B A)$					
	$B = 0$	$B = 1$			
$A = 0$	0.95	0.05			
$A = 1$	0.05	0.95			

A_i

↓

B_i

i : Dato

A_i

↑

B_i

i : Dato

$P(A B)$		$A = 0$	$A = 1$
$B = 0$	0.95	0.05	
$B = 1$	0.05	0.95	

$P(B)$		$B = 0$	$B = 1$
	0.5	0.5	

$$P(\text{Modelo} | \text{Datos} = \{(a_1, b_1), (a_2, b_2), \dots\}) = \frac{\overbrace{P(\text{Datos} | \text{Modelo})}^{\text{Predicción}} P(\text{Modelo})}{P(\text{Datos})}$$

$p = \mathbf{b}$

Laboratorios de
Métodos Bayesianos

Bibliografía Unidad 2

- Herbrich. **TrueSkill Through Time: A Bayesian Skill Rating System.** Advances in Neural Information Processing Systems. 2006. ([Descargar](#)). (lectura paper)
- MacKay. *Information theory, inference and learning algorithms..* Cambridge university press; 2003 ([Descargar](#)). (lecturas 1.1, 2.4-6, 4.1)

Otras:

- Kschischang. *Factor graphs and the sum-product algorithm*; IEEE Transactions on information theory. 2001. ([Descargar](#)). (lectura partes del paper)
- Kelly. *A New Interpretation of Information Rate.*; Bell System Technical Journal. 1956. ([Descargar](#)). (lectura paper)