

# Sorpresa: el problema de la comunicación con la realidad

## Semana 3

La estructura invariante del dato científico.  
Construcción de sistemas de comunicación con la realidad. Tasa de información. Evaluación de sistemas alternativos por su tasa de sorpresa.

# Bibliografía Semana 3

- MacKay. *Information theory, inference and learning algorithms*.. Cambridge university press; 2003 ([Descargar](#)). (lecturas 1.1, 2.4-6, 4.1) Lecturas muy cortas. MacKay tiene su curso en Youtube ([Ver](#)).

Otras:

- Kelly. *A New Interpretation of Information Rate*.; Bell System Technical Journal. 1956. ([Descargar](#)). (lectura paper)

# Base empírica

¿Cuál es el dato de la realidad?

¿Cuál es el conjunto de elementos del mundo  
que sirven de evidencia indubitable (dato)?

# Base empírica


¿Cuál es el dato de la realidad?

- BE Filosófica:  $\emptyset$

# Base empírica

¿Cuál es el dato de la realidad?


- BE Filosófica:  $\emptyset$
- BE Epistemológica: Precios



# Base empírica

¿Cuál es el dato de la realidad?


- BE Filosófica:  $\emptyset$
- BE Epistemológica: Precios
- Teoría: Inflación



# Base empírica

¿Cuál es el dato de la realidad?


- BE Filosófica:  $\emptyset$
- BE Epistemológica: Precios
- BE Metodológica<sub>1</sub>: Inflación



# Base empírica

¿Cuál es el dato de la realidad?

- BE Filosófica:  $\emptyset$
- BE Epistemológica: Precios
- BE Metodológica<sub>1</sub>: Inflación
- Teoría: Producto Bruto Interno






# Base empírica

¿Cuál es el dato de la realidad?


- BE Filosófica:  $\emptyset$
- BE Epistemológica: Precios
- BE Metodológica<sub>1</sub>: Inflación
- BE Metodológica<sub>2</sub>: Producto Bruto Interno



# Base empírica

¿Cuál es el dato de la realidad?


- BE Filosófica:  $\emptyset$
- BE Epistemológica: Precios
- BE Metodológica<sub>1</sub>: Inflación
- BE Metodológica<sub>2</sub>: Producto Bruto Interno
- Teoría: Política pública



# Base empírica


¿Cuál es el dato de la realidad?

Depende del conjunto de supuestos  
que una comunidad no pone en duda!



# Base empírica

El dato se construye



# Los datos como funciones proposicionales

$$f(x) = y$$

$x$  **Unidad de análisis** (UA)

$f$  **Variable** de la unidad de análisis (V)

$y$  **Resultado** o valor de la variable (R)

# Los datos como funciones proposicionales

$$f(x) = y$$

$x$  **Unidad de análisis** (UA)

$f$  **Variable** de la unidad de análisis (V)

$y$  **Resultado** o valor de la variable (R)

$$Altura(\text{Gustavo}) = 1.77\text{m}$$

# Los datos como funciones proposicionales

$$f(x) = y$$

$x$  **Unidad de análisis** (UA)

$f$  **Variable** de la unidad de análisis (V)

$y$  **Resultado** o valor de la variable (R)

*Ideología*(Partido Comunista) = Comunista

# Los datos como funciones proposicionales

$$f(x) = y$$

$x$  **Unidad de análisis** (UA)

$f$  **Variable** de la unidad de análisis (V)

$y$  **Resultado** o valor de la variable (R)

$Ideología(\text{Partido Comunista}) = \text{Comunista}$

$P(Ideología(\text{Partido Comunista}) = \text{Comunista}) = 0.8$



# Los datos como funciones proposicionales

$$f(x) = y$$

$x$  **Unidad de análisis** (UA)

$f$  **Variable** de la unidad de análisis (V)

$y$  **Resultado** o valor de la variable (R)

$$Habilidad(\text{Maradona}) > Habilidad(\text{Messi})$$

# Los datos como funciones proposicionales

$$f(x) = y$$


$x$  **Unidad de análisis** (UA)

$f$  **Variable** de la unidad de análisis (V)


$y$  **Resultado** o valor de la variable (R)

El significado preciso de la función depende de la **operacionalización**

# La estructura invariante del dato empírico




# La estructura invariante del dato empírico



- **Fuente:** el estado *real* de la variable

# La estructura invariante del dato empírico




- **Fuente:** el estado *real* de la variable

*habilidad*(Messi)

Pregunta de investigación (el problema de conocimiento)


# La estructura invariante del dato empírico



- Fuente: el estado *real* de la variable
- **Codificador**: epifenómeno

*habilidad*(Messi)

# La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- **Codificador**: epifenómeno

*habilidad*(Messi)  
Ganar/Perder

Examen de representatividad: que la dimensión exprese lo relevante de la variable.

# La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
- **Mensaje enviado**

*habilidad*(Messi)  
Ganar/Perder

Examen de representatividad: que la dimensión exprese lo relevante de la variable.



# La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
- **Mensaje enviado**

*habilidad*(Messi)  
Ganar/Perder  
Realidad Causal

Examen de representatividad: que la dimensión exprese lo relevante de la variable.

# La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
- Mensaje enviado, **señal enviada**

*habilidad*(Messi)  
Ganar/Perder  
Realidad Causal

Examen de representatividad: que la dimensión exprese lo relevante de la variable.


# La estructura invariante del dato empírico



- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
  - Mensaje enviado, señal enviada
- **Perceptor**: el instrumento de medición

*habilidad*(Messi)  
Ganar/Perder  
Realidad Causal

# La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
  - Mensaje enviado, señal enviada
- **Perceptor**: el instrumento de medición

*habilidad*(Messi)  
Ganar/Perder  
Realidad Causal  
*Scraper* de fifa.com

Examen de confiabilidad: que el procedimiento detecte fielmente la señal enviada.

# La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
  - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
  - **Señal recibida**: base empírica

*habilidad*(Messi)  
Ganar/Perder  
Realidad Causal  
*Scraper* de fifa.com

Examen de confiabilidad: que el procedimiento detecte fielmente la señal enviada.

# La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
  - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
  - **Señal recibida**: base empírica

*habilidad*(Messi)  
Ganar/Perder  
Realidad Causal  
*Scraper* de fifa.com  
True/False

Examen de confiabilidad: que el procedimiento detecte fielmente la señal enviada.


# La estructura invariante del dato empírico



- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
  - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
  - Señal recibida: base empírica
- **Decodificador**: la interpretación

*habilidad*(Messi)  
Ganar/Perder  
Realidad Causal  
*Scraper* de fifa.com  
True/False

# La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
  - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
  - Señal recibida: base empírica
- **Decodificador**: la interpretación

*habilidad*(Messi)  
Ganar/Perder  
Realidad Causal  
*Scraper* de fifa.com  
True/False  
Modelo Causal

Hipótesis indicadora: los elementos necesarios para hacer inferencia.



# La estructura invariante del dato empírico




- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
  - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
  - Señal recibida: base empírica
- Decodificador: la interpretación
  - **Mensaje recibido**: la inferencia

*habilidad*(Messi)  
Ganar/Perder  
Realidad Causal  
*Scraper* de fifa.com  
True/False  
Modelo Causal

Hipótesis indicadora: los elementos necesarios para hacer inferencia.

# La estructura invariante del dato empírico



- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
  - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
  - Señal recibida: base empírica
- Decodificador: la interpretación
  - **Mensaje recibido**: la inferencia

*habilidad*(Messi)

Ganar/Perder

Realidad Causal

*Scraper* de fifa.com


True/False

Modelo Causal

Verosimilitud:  $P(\text{Indicador}|h, M)$

Hipótesis indicadora: los elementos necesarios para hacer inferencia.

# La estructura invariante del dato empírico



- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
  - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
  - Señal recibida: base empírica
- Decodificador: la interpretación
  - Mensaje recibido: la inferencia
- **Destino**: la estimación

*habilidad*(Messi)

Ganar/Perder

Realidad Causal


*Scraper* de fifa.com

True/False

Modelo Causal

Verosimilitud:  $P(\text{Indicador}|h, M)$

# La estructura invariante del dato empírico



- Fuente: el estado *real* de la variable
- Codificador: epifenómeno
  - Mensaje enviado, señal enviada
- Perceptor: el instrumento de medición
  - Señal recibida: base empírica
- Decodificador: la interpretación
  - Mensaje recibido: la inferencia
- **Destino**: la estimación

*habilidad*(Messi)

Ganar/Perder

Realidad Causal

*Scraper* de fifa.com

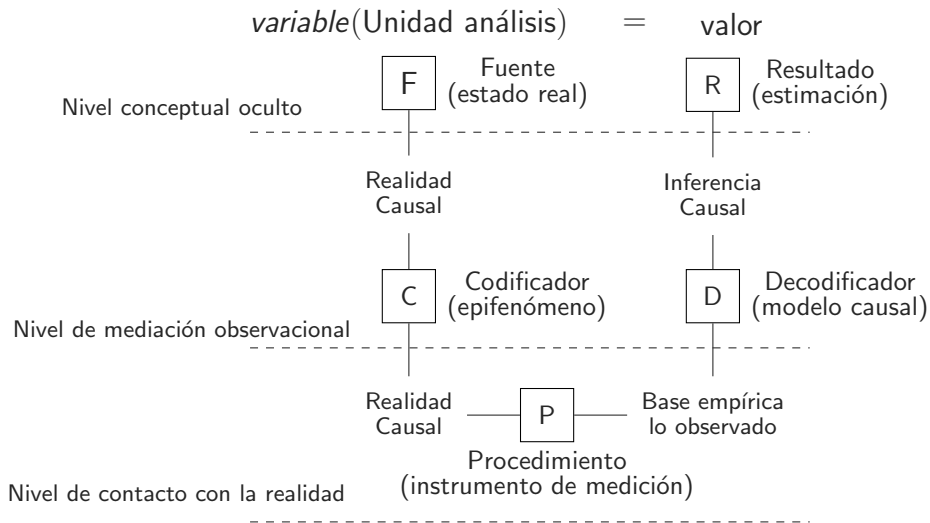
True/False

Modelo Causal

Verosimilitud:  $P(\text{Indicador}|h, M)$

Posterior:  $P(\text{habilidad}(\text{Messi}) = h|I, M)$

# Sistema de comunicación con la realidad



# Teoría de la información

**El problema de la comunicación con la realidad**

# Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

# Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

## Soluciones

Física: acercarme para escuchar mejor

Inferencia: interpretar la señal con ruido



# Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

## Soluciones

Física: acercarme para escuchar mejor

**Inferencia: interpretar la señal con ruido**

# Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

## Soluciones


Física: acercarme para escuchar mejor

**Inferencia: interpretar la señal con ruido**

¿Cómo exactamente?

# Estimación de habilidad

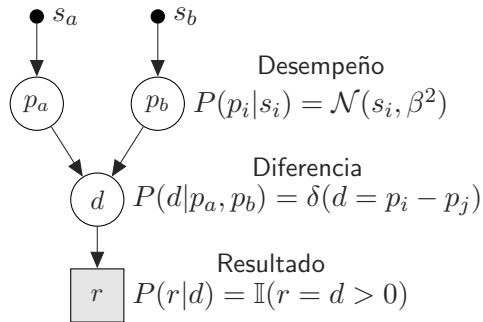
De la federación internacional de ajedrez



# Estimación de habilidad



De la federación internacional de ajedrez

Habilidad



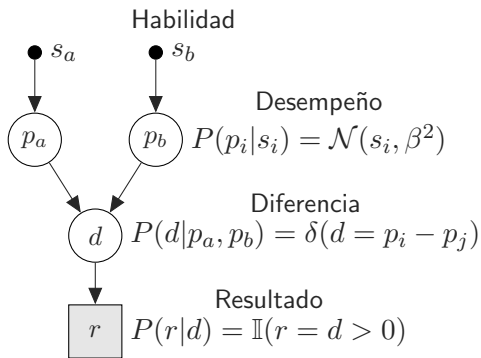
# Estimación de habilidad

De la federación internacional de ajedrez




# Estimación de habilidad

De la federación internacional de ajedrez




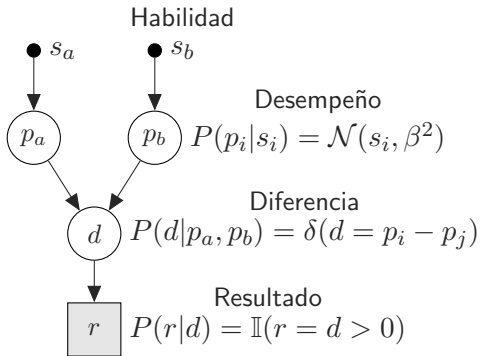
$$P(d > 0 \mid s_a, s_b, M)$$



# Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, M) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$




# Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, \mathbf{M}) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$

Habilidad



$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$

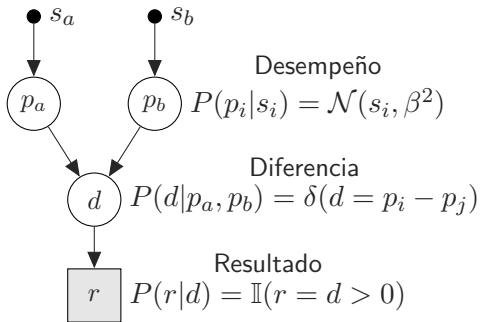


# Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, \mathbf{M}) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$

Habilidad



$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$


$$\Delta = \underbrace{(1 - P(d > 0 \mid s_a, s_b))}_{\text{Sorpresa}}$$

# Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, \mathbf{M}) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$

Habilidad



$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$

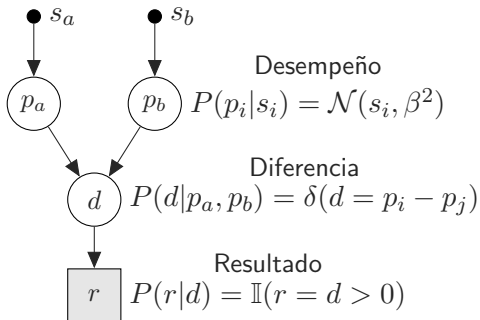
$$\Delta = \underbrace{(1 - P(d > 0 \mid s_a, s_b))}_{\text{Sorpresa}} \underbrace{(-1)^{(1-r)}}_{\text{Signo}}$$

# Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, M) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$

Habilidad



$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$

$$\Delta = \underbrace{(1 - P(d > 0 \mid s_a, s_b))}_{\text{Sorpresa}} \underbrace{(-1)^{(1-r)}}_{\text{Signo}}$$


Problemas:

- Actualización simétrica

# Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, M) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$



$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$

$$\Delta = \underbrace{(1 - P(d > 0 \mid s_a, s_b))}_{\text{Sorpresa}} \underbrace{(-1)^{(1-r)}}_{\text{Signo}}$$

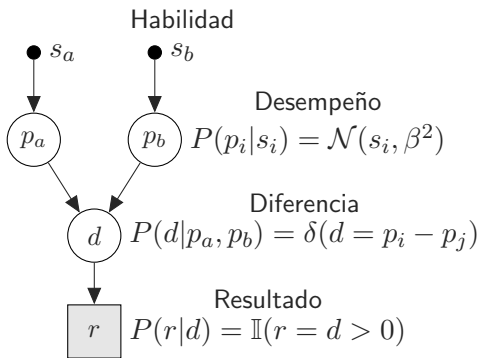
Problemas:

- Actualización simétrica
- Jugadores nuevos desconocidos

# Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, M) = 1 - \Phi \left( \frac{s_a - s_b}{\sqrt{2}\beta} \right)$$



$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta$$

$$\Delta = \underbrace{(1 - P(d > 0 \mid s_a, s_b))}_{\text{Sorpresa}} \underbrace{(-1)^{(1-r)}}_{\text{Signo}}$$


Problemas:

- Actualización simétrica
- Jugadores nuevos desconocidos
- No tiene en cuenta la incertidumbre

# Estimación de habilidad

De la federación internacional de ajedrez

$$P(d > 0 \mid s_a, s_b, M) = 1 - \Phi\left(\frac{s_a - s_b}{\sqrt{2}\beta}\right)$$



$$s_a^{\text{new}} = s_a^{\text{old}} + \Delta K_a$$

$$\Delta = \underbrace{(1 - P(d > 0 \mid s_a, s_b))}_{\text{Sorpresa}} \underbrace{(-1)^{(1-r)}}_{\text{Signo}}$$

Problemas:

- Actualización simétrica
- Jugadores nuevos desconocidos
- No tiene en cuenta la incertidumbre

# Estimación de habilidad

¿Cómo se resuelven todos esos problemas?

# Estimación de habilidad

Aplicación estricta de las reglas de la probabilidad

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo}) = \frac{\overbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}^{\text{Creencia compatible con los datos}}}{P(\text{Datos}|\text{Modelo})}$$



# Estimación de habilidad

Aplicación estricta de las reglas de la probabilidad

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo}) = \frac{\overbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}^{\text{Creencia compatible con los datos}}}{P(\text{Datos}|\text{Modelo})}$$

$$P(\text{Hipótesis}, \text{Datos}|\text{Modelo}) = P(\text{Hipótesis}|\text{Modelo}) P(\text{Datos}|\text{Hipótesis}, \text{Modelo})$$

# Estimación de habilidad


Aplicación estricta de las reglas de la probabilidad

$$P(\text{Hipótesis}|\text{Datos}, \text{Modelo}) = \frac{\overbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}^{\text{Creencia compatible con los datos}}}{P(\text{Datos}|\text{Modelo})}$$

$$\underbrace{P(\text{Hipótesis}, \text{Datos}|\text{Modelo})}_{\text{Creencia inicial compatible con los datos}} = \underbrace{P(\text{Hipótesis}|\text{Modelo})}_{\text{Creencia inicial}} \underbrace{P(\text{Datos}|\text{Hipótesis}, \text{Modelo})}_{\text{Sorpresa fuente de información.}}$$

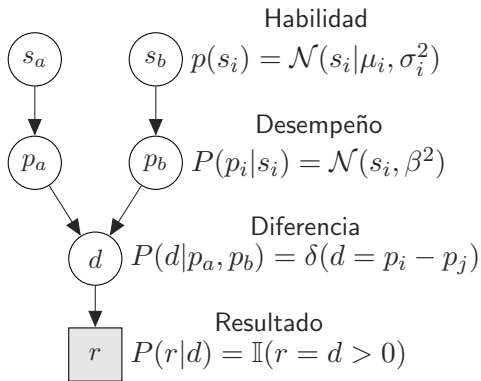
# Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




# Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Teorema de Bayes.




# Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




Teorema de Bayes.




# Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




## Teorema de Bayes.




# Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad




## Teorema de Bayes.




# Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad



## Teorema de Bayes.




$$P(\text{Gana} | \text{Habilidad} = +\infty) = 1$$




# Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad



$$P(\text{Gana} | \text{Habilidad} = -\infty) = 0$$


## Teorema de Bayes.



$$P(\text{Gana} | \text{Habilidad} = +\infty) = 1$$


# Estimación de habilidad

Siglo 21: Aplicación estricta de las reglas de la probabilidad



$$P(\text{Gana} | \text{Habilidad} = -\infty) =$$

Teorema de Bayes.



$$P(\text{Gana} | \text{Habilidad} = +\infty) =$$

# Sorpresa

Fuente de información

# Sorpresa

Fuente de información

Información para las hipótesis.

$$P(\text{Datos} | \text{Hipótesis}_i, \text{Modelo})$$

# Sorpresas

Fuente de información

Información para las hipótesis.

$$P(\text{Datos} | \text{Hipótesis}_i, \text{Modelo})$$

Información para los modelos.

$$P(\text{Datos} | \text{Modelo}_i)$$

# Sorpresas

Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i)$$

# Sorpresas

## Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i) = P(d_1 | \text{Modelo}_i) P(d_2 | d_1, \text{Modelo}_i) \dots$$

# Sorpresas

Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i) = P(d_1 | \text{Modelo}_i) P(d_2 | d_1, \text{Modelo}_i) \dots \approx 0$$



# Sorpresas

## Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i) = P(d_1 | \text{Modelo}_i) P(d_2 | d_1, \text{Modelo}) \dots \approx 0$$

Predicción en órdenes de magnitud

$$\log P(\text{Datos}_T | \text{Modelo}_i) = \log P(d_1 | \text{Modelo}_i) + \log P(d_2 | d_1, \text{Modelo}) \dots$$

# Sorpresa

Fuente de información

$$P(\text{Datos}_T = \{d_1, d_2, \dots, d_T\} | \text{Modelo}_i) = P(d_1 | \text{Modelo}_i) P(d_2 | d_1, \text{Modelo}) \dots \approx 0$$

## Predicción en órdenes de magnitud

$$\log P(\text{Datos}_T | \text{Modelo}_i) = \log P(d_1 | \text{Modelo}_i) + \log P(d_2 | d_1, \text{Modelo}) \dots$$

## Tasa de predicción

$$\underbrace{P(\text{Datos}_T | \text{Modelo}_i)^{1/T}}_{\text{Media geométrica}}$$

# Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos})$$

# Predicción en órdenes de magnitud

$\log_2 P(\text{Datos})$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

# Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos})$$


¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

1)  $x \bmod 16 \geq 8$  

# Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos})$$



¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1)  $x \bmod 16 \geq 8$  
- 2)  $x \bmod 8 \geq 4$  

# Predicción en órdenes de magnitud

$\log_2 P(\text{Datos})$





¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1)  $x \bmod 16 \geq 8$  
- 2)  $x \bmod 8 \geq 4$  
- 3)  $x \bmod 4 \geq 2$  

# Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?





- 1)  $x \bmod 16 \geq 8$  
- 2)  $x \bmod 8 \geq 4$  
- 3)  $x \bmod 4 \geq 2$  
- 4)  $x \bmod 2 \geq 1$  



# Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\})$$





¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1)  $x \bmod 16 \geq 8$    $d_1 = 0$
- 2)  $x \bmod 8 \geq 4$    $d_2 = 1$
- 3)  $x \bmod 4 \geq 2$    $d_3 = 1$
- 4)  $x \bmod 2 \geq 1$    $d_4 = 0$

# Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?





- 1)  $x \bmod 16 \geq 8$    $d_1 = 0$
- 2)  $x \bmod 8 \geq 4$    $d_2 = 1$
- 3)  $x \bmod 4 \geq 2$    $d_3 = 1$
- 4)  $x \bmod 2 \geq 1$    $d_4 = 0$

¿Qué número es?

# Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?





- 1)  $x \bmod 16 \geq 8$    $d_1 = 0$
- 2)  $x \bmod 8 \geq 4$    $d_2 = 1$
- 3)  $x \bmod 4 \geq 2$    $d_3 = 1$
- 4)  $x \bmod 2 \geq 1$    $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0$$

# Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\})$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?





- 1)  $x \bmod 16 \geq 8$    $d_1 = 0$
- 2)  $x \bmod 8 \geq 4$    $d_2 = 1$
- 3)  $x \bmod 4 \geq 2$    $d_3 = 1$
- 4)  $x \bmod 2 \geq 1$    $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

# Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i)$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?





- 1)  $x \bmod 16 \geq 8$    $d_1 = 0$
- 2)  $x \bmod 8 \geq 4$    $d_2 = 1$
- 3)  $x \bmod 4 \geq 2$    $d_3 = 1$
- 4)  $x \bmod 2 \geq 1$    $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

# Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i)$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1)  $x \bmod 16 \geq 8$    $d_1 = 0$
- 2)  $x \bmod 8 \geq 4$    $d_2 = 1$
- 3)  $x \bmod 4 \geq 2$    $d_3 = 1$
- 4)  $x \bmod 2 \geq 1$    $d_4 = 0$





$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

$$\log_2 P(\text{Dato} = (x \bmod N \geq N/2)) = \log_2 \frac{1}{2}$$

# Predicción en órdenes de magnitud

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = -4$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1)  $x \bmod 16 \geq 8$    $d_1 = 0$
- 2)  $x \bmod 8 \geq 4$    $d_2 = 1$
- 3)  $x \bmod 4 \geq 2$    $d_3 = 1$
- 4)  $x \bmod 2 \geq 1$    $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

$$\log_2 P(\text{Dato} = (x \bmod N \geq N/2)) = \log_2 \frac{1}{2}$$

# Predicción en órdenes de magnitud

## - Información en bits

$$\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = -4$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1)  $x \bmod 16 \geq 8$   $d_1 = 0$
- 2)  $x \bmod 8 \geq 4$   $d_2 = 1$
- 3)  $x \bmod 4 \geq 2$   $d_3 = 1$
- 4)  $x \bmod 2 \geq 1$   $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

$$\log_2 P(\text{Dato} = (x \bmod N \geq N/2)) = \log_2 \frac{1}{2}$$







# Predicción en órdenes de magnitud

## - Información en bits

$$-\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = 4$$

¿Cuál es la menor cantidad de preguntas Sí/No que se necesitan para identificar un entero entre 0 y 15?

- 1)  $x \bmod 16 \geq 8$    $d_1 = 0$
- 2)  $x \bmod 8 \geq 4$    $d_2 = 1$
- 3)  $x \bmod 4 \geq 2$    $d_3 = 1$
- 4)  $x \bmod 2 \geq 1$    $d_4 = 0$

$$d_1 2^3 + d_2 2^2 + d_3 2^1 + d_4 2^0 = 0 + 4 + 2 + 0 = 6$$

$$\log_2 P(\text{Dato} = (x \bmod N \geq N/2)) = \log_2 \frac{1}{2}$$

# Predicción en órdenes de magnitud

## - Información en bits

$$-\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = 4$$

## Información de Shannon

$$-\log_2 P(\text{Datos} | \dots)$$

# Predicción en órdenes de magnitud

## - Información en bits

$$-\log_2 P(\text{Datos} = \{d_1 = 0, d_2 = 1, d_3 = 1, d_4 = 0\}) = \sum_i \log_2 P(d_i) = 4$$

## Información de Shannon

$$-\log_2 P(\text{Datos} | \dots)$$
$$=$$

$$\log_2 P(d_1 | \dots) + \log_2 P(d_2 | d_1 \dots) + \log_2 P(d_3 | d_2, d_1 \dots) + \log_2 P(d_4 | d_3, d_2, d_1 \dots)$$

# Información en órdenes de magnitud

Información de Shannon

Submarino:


|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
| 8 |   |   |   |   |   |   |   |   |
| 7 |   |   |   |   |   |   |   |   |
| 6 |   |   |   |   |   |   |   |   |
| 5 |   |   |   |   |   |   |   |   |
| 4 |   |   |   |   |   |   |   |   |
| 3 |   |   |   |   |   |   |   |   |
| 2 |   |   |   |   |   |   |   |   |
| 1 |   |   |   |   |   |   |   |   |
|   | A | B | C | D | E | F | G | H |

# Información en órdenes de magnitud

## Información de Shannon

$$P(A1 = 1) = 1/64$$

Submarino:




# Información en órdenes de magnitud

Información de Shannon

$$-\log_2 P(A1 = 1) = 6 \text{ bits}$$

Submarino:



# Información en órdenes de magnitud

Información de Shannon

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

Submarino:

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
| 8 |   |   |   |   |   |   |   |   |
| 7 |   |   |   |   |   |   |   |   |
| 6 |   |   |   |   |   |   |   |   |
| 5 |   |   |   |   |   |   |   |   |
| 4 |   |   |   |   |   |   |   |   |
| 3 |   |   |   |   |   |   |   |   |
| 2 |   |   |   |   |   |   |   |   |
| 1 | x |   |   |   |   |   |   |   |
|   | A | B | C | D | E | F | G | H |

# Información en órdenes de magnitud

Información de Shannon

Submarino:

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
| 8 |   |   |   |   |   |   |   |   |
| 7 |   |   |   |   |   |   |   |   |
| 6 |   |   |   |   |   |   |   |   |
| 5 |   |   |   |   |   |   |   |   |
| 4 |   |   |   |   |   |   |   |   |
| 3 |   |   |   |   |   |   |   |   |
| 2 | x |   |   |   |   |   |   |   |
| 1 | x |   |   |   |   |   |   |   |
|   | A | B | C | D | E | F | G | H |

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62$$



# Información en órdenes de magnitud

Información de Shannon

Submarino:

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
| 8 |   |   |   |   |   |   |   |   |
| 7 |   |   |   |   |   |   |   |   |
| 6 |   |   |   |   |   |   |   |   |
| 5 |   |   |   |   |   |   |   |   |
| 4 |   |   |   |   |   |   |   |   |
| 3 |   |   |   |   |   |   |   |   |
| 2 | x |   |   |   |   |   |   |   |
| 1 | x |   |   |   |   |   |   |   |
|   | A | B | C | D | E | F | G | H |

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

# Información en órdenes de magnitud

## Información de Shannon

Submarino:

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
| 8 | x | x | x | x |   |   |   |   |
| 7 | x | x | x | x |   |   |   |   |
| 6 | x | x | x | x |   |   |   |   |
| 5 | x | x | x | x |   |   |   |   |
| 4 | x | x | x | x |   |   |   |   |
| 3 | x | x | x | x |   |   |   |   |
| 2 | x | x | x | x |   |   |   |   |
| 1 | x | x | x | x |   |   |   |   |
|   | A | B | C | D | E | F | G | H |

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

# Información en órdenes de magnitud

## Información de Shannon

Submarino:

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
| 8 | x | x | x | x |   |   |   |   |
| 7 | x | x | x | x |   |   |   |   |
| 6 | x | x | x | x |   |   |   |   |
| 5 | x | x | x | x |   |   |   |   |
| 4 | x | x | x | x |   |   |   |   |
| 3 | x | x | x | x |   |   |   |   |
| 2 | x | x | x | x |   |   |   |   |
| 1 | x | x | x | x |   |   |   |   |
|   | A | B | C | D | E | F | G | H |

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$0.0227 + 0.0230 + \cdots + 0.0430 = 1.0 \text{ bit}$$

# Información en órdenes de magnitud

## Información de Shannon

Submarino:

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
| 8 | x | x | x | x |   |   | x | x |
| 7 | x | x | x | x |   |   | x | x |
| 6 | x | x | x | x |   |   | x | x |
| 5 | x | x | x | x |   |   | x | x |
| 4 | x | x | x | x |   |   | x | x |
| 3 | x | x | x | x |   |   | x | x |
| 2 | x | x | x | x |   |   | x | x |
| 1 | x | x | x | x |   |   | x | x |
|   | A | B | C | D | E | F | G | H |

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 = 2.0 \text{ bit}$$

# Información en órdenes de magnitud

## Información de Shannon

Submarino:

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
| 8 | x | x | x | x |   |  | x | x |
| 7 | x | x | x | x |   |   | x | x |
| 6 | x | x | x | x |   |   | x | x |
| 5 | x | x | x | x |   |   | x | x |
| 4 | x | x | x | x |   |   | x | x |
| 3 | x | x | x | x |   |   | x | x |
| 2 | x | x | x | x |   |   | x | x |
| 1 | x | x | x | x |   |   | x | x |
|   | A | B | C | D | E | F   | G | H |

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

# Información en órdenes de magnitud

## Información de Shannon

Submarino:

|   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|
| 8 | x | x | x | x |   |   | x | x |
| 7 | x | x | x | x |   |   | x | x |
| 6 | x | x | x | x |   |   | x | x |
| 5 | x | x | x | x |   |   | x | x |
| 4 | x | x | x | x |   |   | x | x |
| 3 | x | x | x | x |   |   | x | x |
| 2 | x | x | x | x |   |   | x | x |
| 1 | x | x | x | x |   |   | x | x |
|   | A | B | C | D | E | F | G | H |

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

$$\log_2 \frac{64}{63} + \log_2 \frac{63}{62} + \cdots + \log_2 \frac{n+1}{n} + \log_2 \frac{n}{1}$$

# Información en órdenes de magnitud

## Información de Shannon

Submarino:

|                 |   |   |   |   |  |  |   |   |
|-----------------|---|---|---|---|--|--|---|---|
| 8               | x | x | x | x |  |  | x | x |
| 7               | x | x | x | x |  |  | x | x |
| 6               | x | x | x | x |  |  | x | x |
| 5               | x | x | x | x |  |  | x | x |
| 4               | x | x | x | x |  |  | x | x |
| 3               | x | x | x | x |  |  | x | x |
| 2               | x | x | x | x |  |  | x | x |
| 1               | x | x | x | x |  |  | x | x |
| A B C D E F G H |   |   |   |   |  |  |   |   |

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

$$\log_2 \frac{64}{\cancel{63}} + \log_2 \frac{\cancel{63}}{62} + \cdots + \log_2 \frac{n+1}{n} + \log_2 \frac{n}{1}$$

# Información en órdenes de magnitud

## Información de Shannon

Submarino:

|                 |   |   |   |   |  |  |   |   |
|-----------------|---|---|---|---|--|--|---|---|
| 8               | x | x | x | x |  |  | x | x |
| 7               | x | x | x | x |  |  | x | x |
| 6               | x | x | x | x |  |  | x | x |
| 5               | x | x | x | x |  |  | x | x |
| 4               | x | x | x | x |  |  | x | x |
| 3               | x | x | x | x |  |  | x | x |
| 2               | x | x | x | x |  |  | x | x |
| 1               | x | x | x | x |  |  | x | x |
| A B C D E F G H |   |   |   |   |  |  |   |   |

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

$$\log_2 \frac{64}{\cancel{63}} + \log_2 \frac{\cancel{63}}{\cancel{62}} + \cdots + \log_2 \frac{\cancel{n+1}}{\cancel{n}} + \log_2 \frac{\cancel{n}}{1}$$



# Información en órdenes de magnitud

## Información de Shannon

Submarino:

|                 |   |   |   |   |  |  |   |   |
|-----------------|---|---|---|---|--|--|---|---|
| 8               | x | x | x | x |  |  | x | x |
| 7               | x | x | x | x |  |  | x | x |
| 6               | x | x | x | x |  |  | x | x |
| 5               | x | x | x | x |  |  | x | x |
| 4               | x | x | x | x |  |  | x | x |
| 3               | x | x | x | x |  |  | x | x |
| 2               | x | x | x | x |  |  | x | x |
| 1               | x | x | x | x |  |  | x | x |
| A B C D E F G H |   |   |   |   |  |  |   |   |

$$-\log_2 P(A1 = 0) = \log_2 64/63 = 0.0227 \text{ bit}$$

$$-\log_2 P(A2 = 0|A1 = 0) = \log_2 63/62 = 0.0230 \text{ bit}$$

$$\log_2 64/63 + \log_2 63/62 + \cdots + \log_2 33/32$$

$$\log_2 32/31 + \log_2 31/30 + \cdots + \log_2 17/16 + \underbrace{\log_2 16/1}_{4.0 \text{ bit}} = 6.0 \text{ bit}$$

$$\log_2 \frac{64}{\cancel{63}} + \log_2 \frac{\cancel{63}}{\cancel{62}} + \cdots + \log_2 \frac{\cancel{n+1}}{\cancel{n}} + \log_2 \frac{\cancel{n}}{1} = \log_2 \frac{64}{1} = 6.0 \text{ bit}$$


# Información en órdenes de magnitud

Información de Shannon

Hasta ahora medimos la información  
contenida en observaciones individuales.

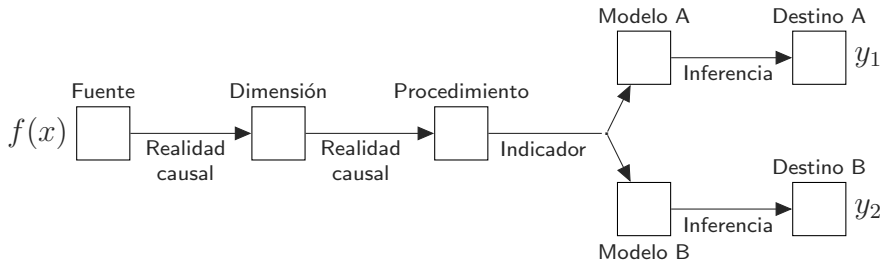
# Información en órdenes de magnitud

Información de Shannon



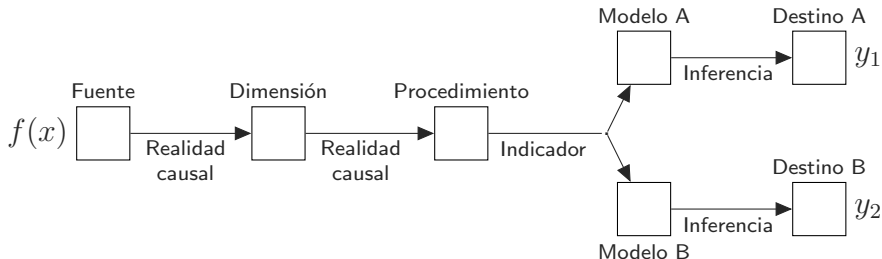
¿Podemos calcular la tasa de información de los sistemas de comunicación alternativos?

# Tasa de información de los sistemas de comunicación



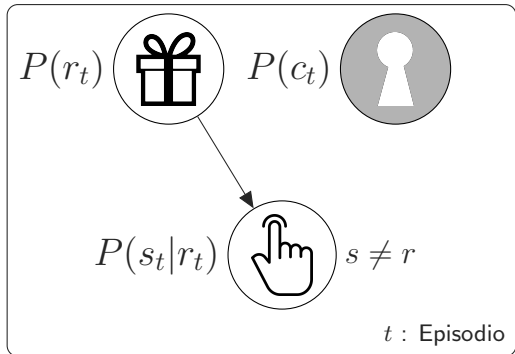
¿Podemos calcular la tasa de información de los sistemas de comunicación alternativos?

# Tasa de información de los sistemas de comunicación



¿Preferimos sistemas de comunicación  
con mayor o con menor tasa de información?

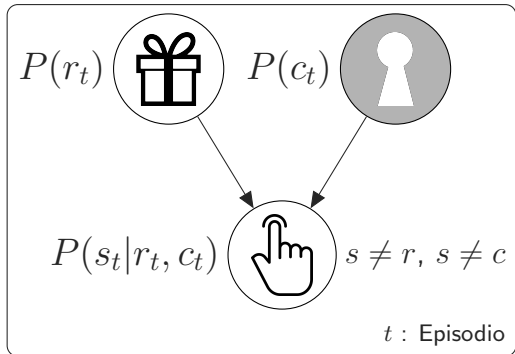
# Tasa de información de los sistemas de comunicación



1/2

0

1/2



1/3

0

2/3



# Tasa de información

de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

# Tasa de información

de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$P(\text{Datos}_T | \text{Modelo} = M) = \prod_t^T P(c_t, s_t, r_t | M)$$



# Tasa de información

## de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

# Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

con  $n_{ijk}$  la cantidad de observaciones de  $(c = i, s = j, r = k)$ .

# Tasa de información

## de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ &= \text{tasaDePrediccion}^T \end{aligned}$$

# Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ &= \text{tasaDePrediccion}^T \end{aligned}$$

la tasaDePrediccion es la media geométrica  $(P(d_1|M)P(d_2|d_1, M) \dots)^{1/T}$ .

# Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción}} = \text{tasaDePrediccion}$$

# Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción}} &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}/T} \end{aligned}$$

# Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción temporal}} &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{p_{ijk}} \end{aligned}$$

# Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \\ \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción temporal}} &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{p_{ijk}} \end{aligned}$$

con  $p_{ijk} = P(c = i, s = j, r = k | \text{Realidad Causal})$



# Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\log \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\substack{\text{Tasa de predicción temporal} \\ \text{en órdenes de magnitud}}} = \log \prod_{i,j,k} P(c = i, s = j, r = k | M)^{p_{ijk}}$$

con  $p_{ijk} = P(c = i, s = j, r = k | \text{Realidad Causal})$

# Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\log \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\substack{\text{Tasa de predicción temporal} \\ \text{en órdenes de magnitud}}} = \sum_{i,j,k} p_{ijk} \log P(c = i, s = j, r = k | M)$$

con  $p_{ijk} = P(c = i, s = j, r = k | \text{Realidad Causal})$

# Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

$$\log \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\substack{\text{Tasa de predicción temporal} \\ \text{en órdenes de magnitud}}} = \underbrace{\sum_{i,j,k} p_{ijk} \log P(c = i, s = j, r = k | M)}_{\substack{\text{Valor esperado de la informa-} \\ \text{ción en órdenes de magnitud}}}$$

# Tasa de información de los sistemas de comunicación

$$P(\text{Modelo}_i, \text{Datos}_T) = P(\text{Modelo}_i) \underbrace{P(\text{Datos}_T = \{(c_0, s_0, r_0), (c_1, s_1, r_1), \dots\} | \text{Modelo}_i)}_{\text{La \textbf{información} está en la \textbf{sorpresa} de la predicción}}$$

$$\begin{aligned} P(\text{Datos}_T | \text{Modelo} = M) &= \prod_t^T P(c_t, s_t, r_t | M) \\ &= \prod_{i,j,k} P(c = i, s = j, r = k | M)^{n_{ijk}} \end{aligned}$$

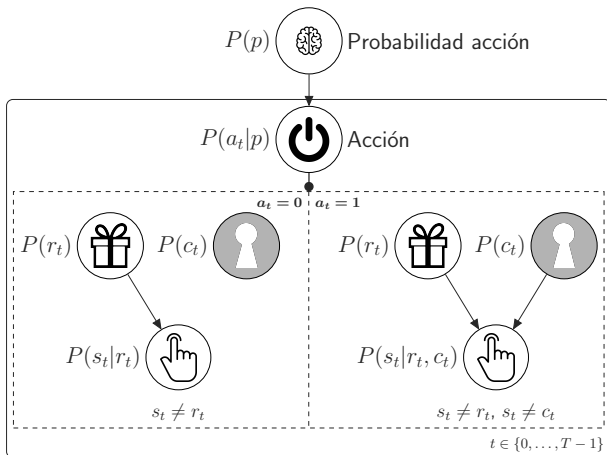
$$\log \lim_{T \rightarrow \infty} \underbrace{P(\text{Datos}_T | \text{Modelo} = M)^{\frac{1}{T}}}_{\text{Tasa de predicción temporal en órdenes de magnitud}} = \underbrace{\sum_{i,j,k} p_{ijk} \log P(c = i, s = j, r = k | M)}_{\begin{array}{l} \text{Valor esperado de la información} \\ \text{— en órdenes de magnitud} \end{array}}$$

# Tasa de información de los sistemas de comunicación

$$\begin{array}{c} \text{Tasa de predicción en} \\ \text{órdenes de magnitud} \\ \hline -\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T} \\ \\ = \\ \sum_{c,s,r} \underbrace{P(c, s, r | \text{Realidad Causal})}_{\text{Probabilidad de que se genere el dato}} \cdot \underbrace{\left( -\log P(c, s, r | \text{Modelo Causal}) \right)}_{\text{Información en órdenes de magnitud}} \\ \hline \text{Entropía cruzada} \\ \text{Tasa de información} \\ \text{del sistema de comunicación} \end{array}$$

# Inteligencia Bayesiana vs Inteligencia Artificial

¿Quién gana?



ChatGPT  $\infty.0$



# Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{H}(\text{Realidad}_{\underset{R}{R}} \text{ causal}, \text{Modelo}_{\underset{M}{M}} \text{ causal}) = \sum_{c,s,r} P(c, s, r|R) \cdot ( - \log P(c, s, r|M))$$

# Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{H}(\text{Realidad}_{\underset{R}{}}, \text{Modelo}_{\underset{M}{}} \text{ causal}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

- Caso:  $P(c, s, r|R) = P(c, s, r|M)$



# Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{H}(\text{Realidad}_{\underset{R}{}}, \text{Modelo}_{\underset{M}{}} \text{ causal}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

- Caso:  $P(c, s, r|R) = P(c, s, r|M)$

$$\mathcal{H}(R, M) = \mathcal{H}(R) = \mathcal{H}(M) = \underbrace{\sum_{c,s,r} P(c, s, r) \cdot (-\log P(c, s, r))}_{\text{Entropía}}$$

# Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{H}(\text{Realidad}_{\underset{R}{\text{causal}}}, \text{Modelo}_{\underset{M}{\text{causal}}}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

- Caso:  $P(c, s, r|R) = P(c, s, r|M)$

$$\mathcal{H}(R, M) = \mathcal{H}(R) = \mathcal{H}(M) = \underbrace{\sum_{c,s,r} P(c, s, r) \cdot (-\log P(c, s, r))}_{\text{Entropía}}$$

- Caso:  $P(c, s, r|R) \neq P(c, s, r|M)$

# Entropía cruzada

Tasa de información del sistema de comunicación

$$\mathcal{H}(\text{Realidad}_{\underset{R}{R}} \text{ causal}, \text{Modelo}_{\underset{M}{M}} \text{ causal}) = \sum_{c,s,r} P(c, s, r|R) \cdot (-\log P(c, s, r|M))$$

- Caso:  $P(c, s, r|R) = P(c, s, r|M)$

$$\mathcal{H}(R, M) = \mathcal{H}(R) = \mathcal{H}(M) = \underbrace{\sum_{c,s,r} P(c, s, r) \cdot (-\log P(c, s, r))}_{\text{Entropía}}$$

- Caso:  $P(c, s, r|R) \neq P(c, s, r|M)$

$$\mathcal{H}(R, M) = \mathcal{H}(R) + \underbrace{\sum_{c,s,r} P(c, s, r|R) \cdot \left(-\log \frac{P(c, s, r|M)}{P(c, s, r|R)}\right)}_{\text{Divergencia KL } \mathcal{D}_{KL}(R||M)}$$

# Entropía

En la física estadística

|   |   |   |   |   |
|---|---|---|---|---|
| • | • |   | • |   |
|   |   | • |   | • |
|   | • |   | • | • |
| • |   | • |   |   |

$$N_A = 10$$

$$V_A = 20$$

$$W_A = \binom{20}{10}$$

# Entropía

En la física estadística

|   |   |   |   |   |
|---|---|---|---|---|
| • | • |   | • |   |
|   |   | • |   | • |
|   | • |   | • | • |
| • |   | • |   |   |

|   |   |   |   |   |
|---|---|---|---|---|
|   | • |   | • |   |
| • |   |   | • |   |
| • |   | • | • | • |
|   | • |   |   | • |

$$N_A = 10$$

$$V_A = 20$$

$$W_A = \binom{20}{10}$$


$$N_B = 10$$

$$V_B = 20$$

$$W_B = \binom{20}{10}$$

# Entropía

En la física estadística



$$N_A = 10$$

$$N_B = 10$$

$$V_A = 20$$


$$V_B = 20$$

$$W_A = \binom{20}{10}$$

$$W_B = \binom{20}{10}$$

# Entropía

En la física estadística



$$N_{AB} = N_A + N_B$$

$$V_{AB} = V_A + V_B$$

$$W_{AB} = W_A W_B$$

$$N_A = 10$$

$$N_B = 10$$

$$V_A = 20$$


$$V_B = 20$$

$$W_A = \binom{20}{10}$$

$$W_B = \binom{20}{10}$$

# Entropía

En la física estadística



$$N_{AB} = N_A + N_B$$

$$V_{AB} = V_A + V_B$$

$$\log \mathbf{W}_{AB} = \mathbf{W}_A + \mathbf{W}_B$$

$$N_A = 10$$

$$N_B = 10$$

$$V_A = 20$$

$$V_B = 20$$


$$W_A = \binom{20}{10}$$

$$W_B = \binom{20}{10}$$



# Entropía

En la física estadística



$$N_{AB} = N_A + N_B$$

$$V_{AB} = V_A + V_B$$

$$\log \mathbf{W}_{AB} = \mathbf{W}_A + \mathbf{W}_B$$

$$N_A = 10$$

$$N_B = 10$$

$$V_A = 20$$

$$V_B = 20$$


$$W_A = \binom{20}{10}$$

$$W_B = \binom{20}{10}$$

$$P(\text{contraiga} | N = 20, V = 40) = \frac{2}{W_{AB}} \approx 0$$

# Entropía

En la física estadística



$$N_{AB} = N_A + N_B$$

$$V_{AB} = V_A + V_B$$

$$\log \mathbf{W}_{AB} = \mathbf{W}_A + \mathbf{W}_B$$

$$N_A = 10$$

$$N_B = 10$$

$$V_A = 20$$

$$V_B = 20$$


$$W_A = \binom{20}{10}$$

$$W_B = \binom{20}{10}$$

$$\text{Entropía} \propto - \cdot \log \mathbf{W}_{AB}$$

# Entropía

En la física estadística



$$N_A = 10$$

$$V_A = 20$$

$$W_A = \binom{20}{10}$$

$$N_B = 10$$

$$V_B = 20$$

$$W_B = \binom{20}{10}$$

$$N_{AB} = N_A + N_B$$

$$V_{AB} = V_A + V_B$$

$$\log W_{AB} = \log W_A + \log W_B$$

$$\underbrace{\text{Entropía} \propto - \cdot \log W_{AB}}$$

Cantidad de posibles estados en órdenes de magnitud

# Entropía

## En la física estadística

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

$e_i$     $n_i$

|   |                      |
|---|----------------------|
| 6 | <input type="text"/> |
| 5 | <input type="text"/> |
| 4 | <input type="text"/> |
| 3 | <input type="text"/> |
| 2 | <input type="text"/> |
| 1 | <input type="text"/> |
| 0 | <input type="text"/> |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

| $e_i$ | $n_i$                |
|-------|----------------------|
| 6     | <input type="text"/> |
| 5     | <input type="text"/> |
| 4     | <input type="text"/> |
| 3     | <input type="text"/> |
| 2     | <input type="text"/> |
| 1     | 6                    |
| 0     | <input type="text"/> |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

| $e_i$ | $n_i$ |   |
|-------|-------|---|
| 6     |       |   |
| 5     |       |   |
| 4     |       |   |
| 3     |       |   |
| 2     |       | 1 |
| 1     | 6     | 4 |
| 0     |       | 1 |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

| $e_i$ | $n_i$ |   |   |
|-------|-------|---|---|
| 6     |       |   |   |
| 5     |       |   |   |
| 4     |       |   |   |
| 3     |       |   |   |
| 2     |       | 1 | 2 |
| 1     | 6     | 4 | 2 |
| 0     |       | 1 | 2 |



# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

| $e_i$ | $n_i$ |   |   |   |  |
|-------|-------|---|---|---|--|
| 6     |       |   |   |   |  |
| 5     |       |   |   |   |  |
| 4     |       |   |   |   |  |
| 3     |       |   |   | 1 |  |
| 2     |       | 1 | 2 |   |  |
| 1     | 6     | 4 | 2 | 3 |  |
| 0     |       | 1 | 2 | 2 |  |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

| $e_i$ | $n_i$ |   |   |   |   |   |   |   |   |   |   |
|-------|-------|---|---|---|---|---|---|---|---|---|---|
| 6     |       |   |   |   |   |   |   |   |   | 1 | 1 |
| 5     |       |   |   |   |   |   |   |   | 1 |   |   |
| 4     |       |   |   |   |   |   | 1 |   |   |   |   |
| 3     |       |   |   | 1 |   | 1 |   | 2 |   |   |   |
| 2     |       | 1 | 2 |   | 3 | 1 |   |   | 1 |   |   |
| 1     | 6     | 4 | 2 | 3 |   | 1 | 2 |   |   | 1 |   |
| 0     |       | 1 | 2 | 2 | 3 | 3 | 3 | 4 | 4 | 4 | 5 |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

| $e_i$ | $n_i$ |    |    |    |    |    |    |    |    |    |     |
|-------|-------|----|----|----|----|----|----|----|----|----|-----|
| 6     |       |    |    |    |    |    |    |    |    | 1  | 1   |
| 5     |       |    |    |    |    |    |    |    | 1  |    |     |
| 4     |       |    |    |    |    |    | 1  |    |    |    |     |
| 3     |       |    |    | 1  |    | 1  |    | 2  |    |    |     |
| 2     |       | 1  | 2  |    | 3  | 1  |    |    | 1  |    |     |
| 1     | 6     | 4  | 2  | 3  |    | 1  | 2  |    |    | 1  |     |
| 0     |       | 1  | 2  | 2  | 3  | 3  | 3  | 4  | 4  | 4  | 5   |
| Gini: | 0     | 33 | 53 | 60 | 60 | 73 | 80 | 80 | 86 | 93 | 100 |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

$$W(n_0, n_1, n_2, n_3, n_4, n_5, n_6) = \frac{N!}{\prod_i n_i!}$$

| $e_i$ | $n_i$ |    |    |    |    |    |    |    |    |    |     |
|-------|-------|----|----|----|----|----|----|----|----|----|-----|
| 6     |       |    |    |    |    |    |    |    |    | 1  | 1   |
| 5     |       |    |    |    |    |    |    |    | 1  |    |     |
| 4     |       |    |    |    |    |    | 1  |    |    |    |     |
| 3     |       |    |    | 1  |    | 1  |    | 2  |    |    |     |
| 2     |       | 1  | 2  |    | 3  | 1  |    |    | 1  |    |     |
| 1     | 6     | 4  | 2  | 3  |    | 1  | 2  |    |    | 1  |     |
| 0     |       | 1  | 2  | 2  | 3  | 3  | 3  | 4  | 4  | 4  | 5   |
| Gini: | 0     | 33 | 53 | 60 | 60 | 73 | 80 | 80 | 86 | 93 | 100 |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

$$W(n_0, n_1, n_2, n_3, n_4, n_5, n_6) = \frac{N!}{\prod_i n_i!}$$

$$W(0, 6, 0, 0, 0, 0, 0) = 1$$

| $e_i$ | $n_i$ |    |    |    |    |    |    |    |    |    |     |
|-------|-------|----|----|----|----|----|----|----|----|----|-----|
| 6     |       |    |    |    |    |    |    |    |    | 1  | 1   |
| 5     |       |    |    |    |    |    |    |    | 1  |    |     |
| 4     |       |    |    |    |    |    | 1  |    |    |    |     |
| 3     |       |    |    | 1  |    | 1  |    | 2  |    |    |     |
| 2     |       | 1  | 2  |    | 3  | 1  |    |    | 1  |    |     |
| 1     | 6     | 4  | 2  | 3  |    | 1  | 2  |    |    | 1  |     |
| 0     |       | 1  | 2  | 2  | 3  | 3  | 3  | 4  | 4  | 4  | 5   |
| Gini: | 0     | 33 | 53 | 60 | 60 | 73 | 80 | 80 | 86 | 93 | 100 |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

$$W(n_0, n_1, n_2, n_3, n_4, n_5, n_6) = \frac{N!}{\prod_i n_i!}$$

$$W(0, 6, 0, 0, 0, 0, 0) = 1$$

$$W(1, 4, 1, 0, 0, 0, 0) = 30$$

| $e_i$ | $n_i$ |    |    |    |    |    |    |    |    |    |     |
|-------|-------|----|----|----|----|----|----|----|----|----|-----|
| 6     |       |    |    |    |    |    |    |    |    | 1  | 1   |
| 5     |       |    |    |    |    |    |    |    | 1  |    |     |
| 4     |       |    |    |    |    |    | 1  |    |    |    |     |
| 3     |       |    |    | 1  |    | 1  |    | 2  |    |    |     |
| 2     |       | 1  | 2  |    | 3  | 1  |    |    | 1  |    |     |
| 1     | 6     | 4  | 2  | 3  |    | 1  | 2  |    |    | 1  |     |
| 0     |       | 1  | 2  | 2  | 3  | 3  | 3  | 4  | 4  | 4  | 5   |
| Gini: | 0     | 33 | 53 | 60 | 60 | 73 | 80 | 80 | 86 | 93 | 100 |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

$$W(n_0, n_1, n_2, n_3, n_4, n_5, n_6) = \frac{N!}{\prod_i n_i!}$$

$$W(0, 6, 0, 0, 0, 0, 0) = 1$$

$$W(1, 4, 1, 0, 0, 0, 0) = 30$$

$$W(2, 2, 2, 0, 0, 0, 0) = 90$$

| $e_i$ | $n_i$ |    |    |    |    |    |    |    |    |    |     |
|-------|-------|----|----|----|----|----|----|----|----|----|-----|
| 6     |       |    |    |    |    |    |    |    |    | 1  | 1   |
| 5     |       |    |    |    |    |    |    |    | 1  |    |     |
| 4     |       |    |    |    |    |    | 1  |    |    |    |     |
| 3     |       |    |    | 1  |    | 1  |    | 2  |    |    |     |
| 2     |       | 1  | 2  |    | 3  | 1  |    |    | 1  |    |     |
| 1     | 6     | 4  | 2  | 3  |    | 1  | 2  |    |    | 1  |     |
| 0     |       | 1  | 2  | 2  | 3  | 3  | 3  | 4  | 4  | 4  | 5   |
| Gini: | 0     | 33 | 53 | 60 | 60 | 73 | 80 | 80 | 86 | 93 | 100 |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

$$W(n_0, n_1, n_2, n_3, n_4, n_5, n_6) = \frac{N!}{\prod_i n_i!}$$

$$W(0, 6, 0, 0, 0, 0, 0) = 1$$

$$W(1, 4, 1, 0, 0, 0, 0) = 30$$

$$W(2, 2, 2, 0, 0, 0, 0) = 90$$

...

$$W(5, 0, 0, 0, 0, 0, 1) = 6$$

| $e_i$ | $n_i$ |    |    |    |    |    |    |    |    |    |     |
|-------|-------|----|----|----|----|----|----|----|----|----|-----|
| 6     |       |    |    |    |    |    |    |    |    | 1  | 1   |
| 5     |       |    |    |    |    |    |    |    | 1  |    |     |
| 4     |       |    |    |    |    |    | 1  |    |    |    |     |
| 3     |       |    |    | 1  |    | 1  |    | 2  |    |    |     |
| 2     |       | 1  | 2  |    | 3  | 1  |    |    | 1  |    |     |
| 1     | 6     | 4  | 2  | 3  |    | 1  | 2  |    |    | 1  |     |
| 0     |       | 1  | 2  | 2  | 3  | 3  | 3  | 4  | 4  | 4  | 5   |
| Gini: | 0     | 33 | 53 | 60 | 60 | 73 | 80 | 80 | 86 | 93 | 100 |



# Entropía


## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 60$

$$W(n_0, n_1, n_2, n_3, n_4, n_5, n_6) = \frac{N!}{\prod_i n_i!}$$

| $e_i$ | $n_i$ |    |    |    |    |    |    |    |    |    |     |
|-------|-------|----|----|----|----|----|----|----|----|----|-----|
| 6     |       |    |    |    |    |    |    |    |    | 1  | 1   |
| 5     |       |    |    |    |    |    |    |    | 1  |    |     |
| 4     |       |    |    |    |    |    | 1  |    |    |    |     |
| 3     |       |    |    | 1  |    | 1  |    | 2  |    |    |     |
| 2     |       | 1  | 2  |    | 3  | 1  |    |    | 1  |    |     |
| 1     | 6     | 4  | 2  | 3  |    | 1  | 2  |    |    | 1  |     |
| 0     |       | 1  | 2  | 2  | 3  | 3  | 3  | 4  | 4  | 4  | 5   |
| Gini: | 0     | 33 | 53 | 60 | 60 | 73 | 80 | 80 | 86 | 93 | 100 |



# Entropía

En la física estadística

$$S = \log W = \log \binom{N}{n_1, n_2, \dots} =$$

# Entropía

En la física estadística

$$S = \log W = \log \binom{N}{n_1, n_2, \dots} = \log \frac{N!}{\prod_i n_i!}$$

# Entropía

En la física estadística

$$S = \log W = \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i!$$

# Entropía

En la física estadística

$$S = \log W = \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i!$$


$$\log N! = \sum_{k=1}^N \log k$$

# Entropía

En la física estadística

$$S = \log W = \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i!$$

$$\log N! = \sum_{k=1}^N \log k \approx \int_1^N \log k \, dk$$




# Entropía

## En la física estadística

$$S = \log W = \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i!$$

$$\begin{aligned} \log N! &= \sum_{k=1}^N \log k \approx \int_1^N \log k \, dk \\ &= N \log N - N + 1 \end{aligned}$$



# Entropía


## En la física estadística

$$S = \log W = \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i!$$

$$= N \log N - N - \left( \sum_i n_i \log n_i - n_i \right)$$

$$\log N! = \sum_{k=1}^N \log k \approx \int_1^N \log k \, dk$$

$$= N \log N - N + 1$$





# Entropía

## En la física estadística

$$\begin{aligned} S = \log W &= \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i! \\ &= N \log N - N - \left( \sum_i n_i \log n_i - n_i \right) \end{aligned}$$

# Entropía

En la física estadística

$$\begin{aligned} S = \log W &= \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i! \\ &= N \log N - N - \sum_i n_i \log n_i - \sum_i n_i \end{aligned}$$

# Entropía

En la física estadística

$$\begin{aligned} S = \log W &= \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i! \\ &= N \log N - \cancel{N} - \sum_i n_i \log n_i + \cancel{\sum_i n_i} \end{aligned}$$

# Entropía

En la física estadística

$$\begin{aligned} S = \log W &= \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i! \\ &= N \log N - \cancel{N} - \sum_i n_i \log n_i + \cancel{\sum_i n_i} \\ &= \left( \sum_i n_i \right) \log N - \sum_i n_i \log n_i \end{aligned}$$

# Entropía

En la física estadística

$$\begin{aligned} S &= \log W = \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i! \\ &= N \log N - \cancel{N} - \sum_i n_i \log n_i + \cancel{\sum_i n_i} \\ &= \left( \sum_i n_i \right) \log N - \sum_i n_i \log n_i \\ &= \sum_i n_i (\log N - \log n_i) \end{aligned}$$

# Entropía

En la física estadística

$$\begin{aligned} S = \log W &= \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i! \\ &= N \log N - \cancel{N} - \sum_i n_i \log n_i + \cancel{\sum_i n_i} \\ &= \left( \sum_i n_i \right) \log N - \sum_i n_i \log n_i \\ &= \sum_i n_i \log \frac{N}{n_i} \end{aligned}$$

# Entropía

En la física estadística

$$\begin{aligned} S = \log W &= \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i! \\ &= N \log N - \cancel{N} - \sum_i n_i \log n_i + \cancel{\sum_i n_i} \\ &= \left( \sum_i n_i \right) \log N - \sum_i n_i \log n_i \\ &= - \sum_i n_i \log \frac{n_i}{N} \end{aligned}$$

# Entropía

En la física estadística

$$S = \log W = \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i!$$

$$= N \log N - \cancel{N} - \sum_i n_i \log n_i + \cancel{\sum_i n_i}$$

$$= \left(\sum_i n_i\right) \log N - \sum_i n_i \log n_i$$

$$= - \sum_i n_i \log \frac{n_i}{N}$$

$$\frac{S}{N} = - \sum_i \frac{n_i}{N} \log \frac{n_i}{N}$$

**Entropía:** promedio de la cantidad de posibles estados en órdenes de magnitud



# Entropía

En la física estadística

$$S = \log W = \log \binom{N}{n_1, n_2, \dots} = \log N! - \sum_i \log n_i!$$

$$= N \log N - \cancel{N} - \sum_i n_i \log n_i + \cancel{\sum_i n_i}$$

$$= \left(\sum_i n_i\right) \log N - \sum_i n_i \log n_i$$

$$= - \sum_i n_i \log \frac{n_i}{N}$$

$$\frac{S}{N} = - \sum_i p_i \log p_i$$

**Entropía:** promedio de la cantidad de posibles estados en órdenes de magnitud

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

$$\mathcal{H}(W(n_0, n_1, n_2, n_3, n_4, n_5, n_6)) = - \sum \frac{n_i}{N} \log \frac{n_i}{N}$$

| $e_i$ | $n_i$ |    |    |    |    |    |    |    |    |    |     |
|-------|-------|----|----|----|----|----|----|----|----|----|-----|
| 6     |       |    |    |    |    |    |    |    |    | 1  | 1   |
| 5     |       |    |    |    |    |    |    |    | 1  |    |     |
| 4     |       |    |    |    |    |    | 1  |    |    |    |     |
| 3     |       |    |    | 1  |    | 1  |    | 2  |    |    |     |
| 2     |       | 1  | 2  |    | 3  | 1  |    |    | 1  |    |     |
| 1     | 6     | 4  | 2  | 3  |    | 1  | 2  |    |    | 1  |     |
| 0     |       | 1  | 2  | 2  | 3  | 3  | 3  | 4  | 4  | 4  | 5   |
| Gini: | 0     | 33 | 53 | 60 | 60 | 73 | 80 | 80 | 86 | 93 | 100 |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

$$\mathcal{H}(W(n_0, n_1, n_2, n_3, n_4, n_5, n_6)) = - \sum \frac{n_i}{N} \log \frac{n_i}{N}$$

$$\mathcal{H}(W(0, 6, 0, 0, 0, 0, 0)) = 0$$

| $e_i$ | $n_i$ |    |    |    |    |    |    |    |    |    |     |
|-------|-------|----|----|----|----|----|----|----|----|----|-----|
| 6     |       |    |    |    |    |    |    |    |    | 1  | 1   |
| 5     |       |    |    |    |    |    |    |    | 1  |    |     |
| 4     |       |    |    |    |    |    | 1  |    |    |    |     |
| 3     |       |    |    | 1  |    | 1  |    | 2  |    |    |     |
| 2     |       | 1  | 2  |    | 3  | 1  |    |    | 1  |    |     |
| 1     | 6     | 4  | 2  | 3  |    | 1  | 2  |    |    | 1  |     |
| 0     |       | 1  | 2  | 2  | 3  | 3  | 3  | 4  | 4  | 4  | 5   |
| Gini: | 0     | 33 | 53 | 60 | 60 | 73 | 80 | 80 | 86 | 93 | 100 |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

$$\mathcal{H}(W(n_0, n_1, n_2, n_3, n_4, n_5, n_6)) = - \sum \frac{n_i}{N} \log \frac{n_i}{N}$$

$$\mathcal{H}(W(0, 6, 0, 0, 0, 0, 0)) = 0$$

$$\mathcal{H}(W(1, 4, 1, 0, 0, 0, 0)) \approx 0.867$$

| $e_i$ | $n_i$ |    |    |    |    |    |    |    |    |    |     |
|-------|-------|----|----|----|----|----|----|----|----|----|-----|
| 6     |       |    |    |    |    |    |    |    |    | 1  | 1   |
| 5     |       |    |    |    |    |    |    |    | 1  |    |     |
| 4     |       |    |    |    |    |    | 1  |    |    |    |     |
| 3     |       |    |    | 1  |    | 1  |    | 2  |    |    |     |
| 2     |       | 1  | 2  |    | 3  | 1  |    |    | 1  |    |     |
| 1     | 6     | 4  | 2  | 3  |    | 1  | 2  |    |    | 1  |     |
| 0     |       | 1  | 2  | 2  | 3  | 3  | 3  | 4  | 4  | 4  | 5   |
| Gini: | 0     | 33 | 53 | 60 | 60 | 73 | 80 | 80 | 86 | 93 | 100 |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

$$\mathcal{H}(W(n_0, n_1, n_2, n_3, n_4, n_5, n_6)) = - \sum \frac{n_i}{N} \log \frac{n_i}{N}$$

$$\mathcal{H}(W(0, 6, 0, 0, 0, 0, 0)) = 0$$

$$\mathcal{H}(W(1, 4, 1, 0, 0, 0, 0)) \approx 0.867$$

$$\mathcal{H}(W(2, 2, 2, 0, 0, 0, 0)) \approx 1.099$$

| $e_i$ | $n_i$ |    |    |    |    |    |    |    |    |    |     |
|-------|-------|----|----|----|----|----|----|----|----|----|-----|
| 6     |       |    |    |    |    |    |    |    |    | 1  | 1   |
| 5     |       |    |    |    |    |    |    |    | 1  |    |     |
| 4     |       |    |    |    |    |    | 1  |    |    |    |     |
| 3     |       |    |    | 1  |    | 1  |    | 2  |    |    |     |
| 2     |       | 1  | 2  |    | 3  | 1  |    |    | 1  |    |     |
| 1     | 6     | 4  | 2  | 3  |    | 1  | 2  |    |    | 1  |     |
| 0     |       | 1  | 2  | 2  | 3  | 3  | 3  | 4  | 4  | 4  | 5   |
| Gini: | 0     | 33 | 53 | 60 | 60 | 73 | 80 | 80 | 86 | 93 | 100 |

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

$$\mathcal{H}(W(n_0, n_1, n_2, n_3, n_4, n_5, n_6)) = - \sum \frac{n_i}{N} \log \frac{n_i}{N}$$

$$\mathcal{H}(W(0, 6, 0, 0, 0, 0, 0)) = 0$$

$$\mathcal{H}(W(1, 4, 1, 0, 0, 0, 0)) \approx 0.867$$

$$\mathcal{H}(W(2, 2, 2, 0, 0, 0, 0)) \approx 1.099$$

...

$$\mathcal{H}(W(5, 0, 0, 0, 0, 0, 1)) \approx 0.451$$

$e_i$   $n_i$

|   |   |   |   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 6 |   |   |   |   |   |   |   |   |   | 1 | 1 |
| 5 |   |   |   |   |   |   |   |   | 1 |   |   |
| 4 |   |   |   |   |   |   | 1 |   |   |   |   |
| 3 |   |   |   | 1 |   | 1 |   | 2 |   |   |   |
| 2 |   | 1 | 2 |   | 3 | 1 |   |   | 1 |   |   |
| 1 | 6 | 4 | 2 | 3 |   | 1 | 2 |   |   | 1 |   |
| 0 |   | 1 | 2 | 2 | 3 | 3 | 3 | 4 | 4 | 4 | 5 |

Gini:    0    33    53    60    60    73    80    80    86    93    100

# Entropía

## En la física estadística

Restricciones:

- Partículas totales  $N = 6$
- Energía total  $E = \sum_i e_i \cdot n_i = 6$

$$\mathcal{H}(W(n_0, n_1, n_2, n_3, n_4, n_5, n_6)) = - \sum \frac{n_i}{N} \log \frac{n_i}{N}$$

$$\mathcal{H}(W(0, 6, 0, 0, 0, 0, 0)) = 0$$

$$\mathcal{H}(W(1, 4, 1, 0, 0, 0, 0)) \approx 0.867$$

$$\mathcal{H}(W(2, 2, 2, 0, 0, 0, 0)) \approx 1.099$$

...

$$\mathcal{H}(W(5, 0, 0, 0, 0, 0, 1)) \approx 0.451$$

$e_i$   $n_i$

|   |   |   |   |   |   |   |   |   |   |   |   |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 6 |   |   |   |   |   |   |   |   |   | 1 | 1 |
| 5 |   |   |   |   |   |   |   |   | 1 |   |   |
| 4 |   |   |   |   |   |   | 1 |   |   |   |   |
| 3 |   |   |   | 1 |   | 1 |   | 2 |   |   |   |
| 2 |   | 1 | 2 |   | 3 | 1 |   |   | 1 |   |   |
| 1 | 6 | 4 | 2 | 3 |   | 1 | 2 |   |   | 1 |   |
| 0 |   | 1 | 2 | 2 | 3 | 3 | 3 | 4 | 4 | 4 | 5 |

Gini: 0 33 53 60 60 73 80 80 86 93 100

Entropía como medida  
de la incertidumbre

# Maximizar entropía

$$\arg \max_{a=\text{Acción}} \mathcal{H}(\text{Realidad}(a)) = \arg \min_{a=\text{Acción}} P(\text{Datos}_{\infty} | \text{Realidad}(a))$$



# Maximizar entropía

$$\arg \max_{a=\text{Acción}} \mathcal{H}(\text{Realidad}(a)) = \arg \min_{a=\text{Acción}} P(\text{Datos}_{\infty} | \text{Realidad}(a))$$

Maximizar entropía (o información esperada)  
es

Maximizar incertidumbre (minimizar la tasa de predicción)

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

Seleccionar el plan de acción  $a$  que use la balanza la menor cantidad de veces para determinar cuál es la pelota y si pesa más o menos que el resto.

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | $\uparrow$ | $\leftrightarrow$ | $\downarrow$ | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|------------|-------------------|--------------|------------------------------|
| 6 vs 6 (0)                        |            |                   |              |                              |
| 5 vs 5 (2)                        |            |                   |              |                              |
| 4 vs 4 (4)                        |            |                   |              |                              |
| 3 vs 3 (6)                        |            |                   |              |                              |
| 2 vs 2 (8)                        |            |                   |              |                              |
| 1 vs 1 (10)                       |            |                   |              |                              |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | ↑ | ↔ | ↓ | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|---|---|---|------------------------------|
| 6 vs 6 (0)                        |   | 0 |   |                              |
| 5 vs 5 (2)                        |   |   |   |                              |
| 4 vs 4 (4)                        |   |   |   |                              |
| 3 vs 3 (6)                        |   |   |   |                              |
| 2 vs 2 (8)                        |   |   |   |                              |
| 1 vs 1 (10)                       |   |   |   |                              |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | $\uparrow$ | $\leftrightarrow$ | $\downarrow$ | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|------------|-------------------|--------------|------------------------------|
| 6 vs 6 (0)                        | $1/2$      | 0                 | $1/2$        |                              |
| 5 vs 5 (2)                        |            |                   |              |                              |
| 4 vs 4 (4)                        |            |                   |              |                              |
| 3 vs 3 (6)                        |            |                   |              |                              |
| 2 vs 2 (8)                        |            |                   |              |                              |
| 1 vs 1 (10)                       |            |                   |              |                              |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | $\uparrow$ | $\leftrightarrow$ | $\downarrow$ | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|------------|-------------------|--------------|------------------------------|
| 6 vs 6 (0)                        | $1/2$      | 0                 | $1/2$        | 1 bit                        |
| 5 vs 5 (2)                        |            |                   |              |                              |
| 4 vs 4 (4)                        |            |                   |              |                              |
| 3 vs 3 (6)                        |            |                   |              |                              |
| 2 vs 2 (8)                        |            |                   |              |                              |
| 1 vs 1 (10)                       |            |                   |              |                              |



# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | $\uparrow$ | $\leftrightarrow$ | $\downarrow$ | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|------------|-------------------|--------------|------------------------------|
| 6 vs 6 (0)                        | $1/2$      | 0                 | $1/2$        | 1 bit                        |
| 5 vs 5 (2)                        |            | $\frac{1}{3}$ ?   |              |                              |
| 4 vs 4 (4)                        |            |                   |              |                              |
| 3 vs 3 (6)                        |            |                   |              |                              |
| 2 vs 2 (8)                        |            |                   |              |                              |
| 1 vs 1 (10)                       |            |                   |              |                              |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | $\uparrow$ | $\leftrightarrow$ | $\downarrow$ | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|------------|-------------------|--------------|------------------------------|
| 6 vs 6 (0)                        | $1/2$      | 0                 | $1/2$        | 1 bit                        |
| 5 vs 5 (2)                        |            | $2/12$            |              |                              |
| 4 vs 4 (4)                        |            |                   |              |                              |
| 3 vs 3 (6)                        |            |                   |              |                              |
| 2 vs 2 (8)                        |            |                   |              |                              |
| 1 vs 1 (10)                       |            |                   |              |                              |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | $\uparrow$ | $\leftrightarrow$ | $\downarrow$ | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|------------|-------------------|--------------|------------------------------|
| 6 vs 6 (0)                        | $1/2$      | 0                 | $1/2$        | 1 bit                        |
| 5 vs 5 (2)                        |            | $1/6$             |              |                              |
| 4 vs 4 (4)                        |            |                   |              |                              |
| 3 vs 3 (6)                        |            |                   |              |                              |
| 2 vs 2 (8)                        |            |                   |              |                              |
| 1 vs 1 (10)                       |            |                   |              |                              |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | $\uparrow$ | $\leftrightarrow$ | $\downarrow$ | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|------------|-------------------|--------------|------------------------------|
| 6 vs 6 (0)                        | $1/2$      | 0                 | $1/2$        | 1 bit                        |
| 5 vs 5 (2)                        | $5/12$     | $1/6$             | $5/12$       |                              |
| 4 vs 4 (4)                        |            |                   |              |                              |
| 3 vs 3 (6)                        |            |                   |              |                              |
| 2 vs 2 (8)                        |            |                   |              |                              |
| 1 vs 1 (10)                       |            |                   |              |                              |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | $\uparrow$ | $\leftrightarrow$ | $\downarrow$ | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|------------|-------------------|--------------|------------------------------|
| 6 vs 6 (0)                        | $1/2$      | 0                 | $1/2$        | 1 bit                        |
| 5 vs 5 (2)                        | $5/12$     | $1/6$             | $5/12$       | 1.48 bits                    |
| 4 vs 4 (4)                        |            |                   |              |                              |
| 3 vs 3 (6)                        |            |                   |              |                              |
| 2 vs 2 (8)                        |            |                   |              |                              |
| 1 vs 1 (10)                       |            |                   |              |                              |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | ↑    | ↔    | ↓    | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|------|------|------|------------------------------|
| 6 vs 6 (0)                        | 1/2  | 0    | 1/2  | 1 bit                        |
| 5 vs 5 (2)                        | 5/12 | 1/6  | 5/12 | 1.48 bits                    |
| 4 vs 4 (4)                        | 4/12 | 4/12 | 4/12 |                              |
| 3 vs 3 (6)                        |      |      |      |                              |
| 2 vs 2 (8)                        |      |      |      |                              |
| 1 vs 1 (10)                       |      |      |      |                              |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | ↑      | ↔     | ↓      | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|--------|-------|--------|------------------------------|
| 6 vs 6 (0)                        | $1/2$  | 0     | $1/2$  | 1 bit                        |
| 5 vs 5 (2)                        | $5/12$ | $1/6$ | $5/12$ | 1.48 bits                    |
| 4 vs 4 (4)                        | $1/3$  | $1/3$ | $1/3$  |                              |
| 3 vs 3 (6)                        |        |       |        |                              |
| 2 vs 2 (8)                        |        |       |        |                              |
| 1 vs 1 (10)                       |        |       |        |                              |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | ↑    | ↔   | ↓    | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|------|-----|------|------------------------------|
| 6 vs 6 (0)                        | 1/2  | 0   | 1/2  | 1 bit                        |
| 5 vs 5 (2)                        | 5/12 | 1/6 | 5/12 | 1.48 bits                    |
| 4 vs 4 (4)                        | 1/3  | 1/3 | 1/3  | 1.58 bits                    |
| 3 vs 3 (6)                        |      |     |      |                              |
| 2 vs 2 (8)                        |      |     |      |                              |
| 1 vs 1 (10)                       |      |     |      |                              |



# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | ↑    | ↔   | ↓    | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|------|-----|------|------------------------------|
| 6 vs 6 (0)                        | 1/2  | 0   | 1/2  | 1 bit                        |
| 5 vs 5 (2)                        | 5/12 | 1/6 | 5/12 | 1.48 bits                    |
| 4 vs 4 (4)                        | 1/3  | 1/3 | 1/3  | 1.58 bits                    |
| 3 vs 3 (6)                        | 1/4  | 1/2 | 1/4  |                              |
| 2 vs 2 (8)                        |      |     |      |                              |
| 1 vs 1 (10)                       |      |     |      |                              |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | ↑    | ↔   | ↓    | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|------|-----|------|------------------------------|
| 6 vs 6 (0)                        | 1/2  | 0   | 1/2  | 1 bit                        |
| 5 vs 5 (2)                        | 5/12 | 1/6 | 5/12 | 1.48 bits                    |
| 4 vs 4 (4)                        | 1/3  | 1/3 | 1/3  | 1.58 bits                    |
| 3 vs 3 (6)                        | 1/4  | 1/2 | 1/4  | 1.5 bits                     |
| 2 vs 2 (8)                        |      |     |      |                              |
| 1 vs 1 (10)                       |      |     |      |                              |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | ↑    | ↔   | ↓    | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|------|-----|------|------------------------------|
| 6 vs 6 (0)                        | 1/2  | 0   | 1/2  | 1 bit                        |
| 5 vs 5 (2)                        | 5/12 | 1/6 | 5/12 | 1.48 bits                    |
| 4 vs 4 (4)                        | 1/3  | 1/3 | 1/3  | 1.58 bits                    |
| 3 vs 3 (6)                        | 1/4  | 1/2 | 1/4  | 1.5 bits                     |
| 2 vs 2 (8)                        | 1/6  | 2/3 | 1/6  | 1.25 bits                    |
| 1 vs 1 (10)                       | 1/12 | 5/6 | 1/12 | 0.82 bits                    |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Una de las 12 pelotas tiene un peso distinto al resto.

| $P(\text{Balanza} \text{Acción})$ | ↑      | ↔     | ↓      | $\mathcal{H}(\text{Acción})$ |
|-----------------------------------|--------|-------|--------|------------------------------|
| 6 vs 6 (0)                        | $1/2$  | 0     | $1/2$  | 1 bit                        |
| 5 vs 5 (2)                        | $5/12$ | $1/6$ | $5/12$ | 1.48 bits                    |
| <b>4 vs 4</b> (4)                 | $1/3$  | $1/3$ | $1/3$  | 1.58 bits                    |
| 3 vs 3 (6)                        | $1/4$  | $1/2$ | $1/4$  | 1.5 bits                     |
| 2 vs 2 (8)                        | $1/6$  | $2/3$ | $1/6$  | 1.25 bits                    |
| 1 vs 1 (10)                       | $1/12$ | $5/6$ | $1/12$ | 0.82 bits                    |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



|              |         |                    |
|--------------|---------|--------------------|
| (1, 2, 3, 4) | $1^+$   | $\uparrow:$        |
|              | $2^+$   |                    |
|              | $\dots$ |                    |
| 4 vs 4 (4)   | $12^+$  | $\leftrightarrow:$ |
|              | $1^-$   |                    |
|              | $2^-$   |                    |
| (5, 6, 7, 8) | $\dots$ | $\downarrow:$      |
|              | $12^-$  |                    |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



|              |         |                    |   |
|--------------|---------|--------------------|---|
| (1, 2, 3, 4) | $1^+$   | $\uparrow:$        | ? |
|              | $2^+$   |                    |   |
|              | $\dots$ |                    |   |
| 4 vs 4 (4)   | $12^+$  | $\leftrightarrow:$ | ? |
|              | $1^-$   |                    |   |
|              | $2^-$   |                    |   |
| (5, 6, 7, 8) | $\dots$ | $\downarrow:$      | ? |
|              | $12^-$  |                    |   |







Maximizar incertidumbre es maximizar la información esperada.

Maximizar incertidumbre es maximizar la información esperada.



|                               |                                 |                    |       |        |        |        |       |        |        |        |
|-------------------------------|---------------------------------|--------------------|-------|--------|--------|--------|-------|--------|--------|--------|
| $(1, 2, 3, 4)$                | $1^+$<br>$2^+$<br>...<br>$12^+$ | $\uparrow:$        | $1^+$ | $2^+$  | $3^+$  | $4^+$  | $5^-$ | $6^-$  | $7^-$  | $8^-$  |
| $4 \text{ vs } 4 \text{ (4)}$ |                                 | $\leftrightarrow:$ | $9^+$ | $10^+$ | $11^+$ | $12^+$ | $9^-$ | $10^-$ | $11^-$ | $12^-$ |
| $(5, 6, 7, 8)$                | $1^-$<br>$2^-$<br>...<br>$12^-$ | $\downarrow:$      | $1^-$ | $2^-$  | $3^-$  | $4^-$  | $5^+$ | $6^+$  | $7^+$  | $8^+$  |

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Ejercicio.

Elegir un plan de acción para el siguiente paso.

# Maximizar entropía

Maximizar incertidumbre es maximizar la información esperada.



Ejercicio.

Elegir un plan de acción para el siguiente paso.

Si maximizan la información esperada (entropía)  
pueden identificar la pelota en 2 pasos más.

# Máxima entropía dada información disponible

La definición formal del principio de “no mentir”.

# Máxima entropía dada información disponible

Distribuciones de creencias  
(por máxima entropía dadas restricciones)

$$\max - \int P(x|\theta) \log P(x|\theta) dx$$

$$\text{dado } \int P(x|\theta) dx = 1$$

$$\int \phi_k(x) P(x|\theta) dx = F_k \quad \forall_k$$

# Máxima entropía

## dada información disponible

Distribuciones de creencias  
(por máxima entropía dadas restricciones)

$$\max - \int P(x|\theta) \log P(x|\theta) dx$$

$$\text{dado } \int P(x|\theta) dx = 1$$

$$\int \phi_k(x) P(x|\theta) dx = F_k \quad \forall_k$$

La familia exponencial

$$P(x|\theta) = \frac{1}{Z(\theta)} h(x) \exp(\theta^T \phi(x))$$

Con:

$x \in \mathbb{X}^m$  hipótesis

$\theta \in \mathbb{R}^d$  parámetros naturales

$\phi(x) \in \mathbb{R}^d$  estadísticos suficientes

# Máxima entropía

## dada información disponible

Distribuciones de creencias  
(por máxima entropía dadas restricciones)

$$\max - \int P(x|\theta) \log P(x|\theta) dx$$

$$\text{dado } \int P(x|\theta) dx = 1$$

$$\int \phi_k(x) P(x|\theta) dx = F_k \quad \forall_k$$

La familia exponencial

$$P(x|\theta) = \frac{1}{Z(\theta)} h(x) \exp(\theta^T \phi(x))$$

- Bernoulli( $x|p$ )
- Beta( $x|\alpha, \beta$ )
- Geométrica( $x|p$ )
- Multinomial( $x|p, n$ )
- Hipergeométrica( $x|n, N, K$ )
- Poisson( $x|\lambda$ )
- Gaussiana( $x|\mu, \sigma^2$ )
- Dirichlet( $x|\alpha_1, \dots, \alpha_K$ )
- ...

# Divergencia Kullback-Leibler

$$-\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T}$$

Tasa de predicción (temporal) en órdenes de magnitud (log) en signo opuesto



# Divergencia Kullback-Leibler

$$\begin{aligned} & -\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T} \\ & = \\ & \sum_{c,s,r} P(c, s, r | \text{Realidad Causal}) \cdot (-\log P(c, s, r | \text{Modelo Causal})) \end{aligned}$$

Información esperada del sistema de comunicación

# Divergencia Kullback-Leibler

$$\begin{aligned} & -\log \lim_{T \rightarrow \infty} P(\text{Datos}_T | \text{Modelo Causal})^{1/T} \\ & = \\ & \sum_{c,s,r} P(c, s, r | \text{Realidad Causal}) \cdot (-\log P(c, s, r | \text{Modelo Causal})) \\ & = \\ & \mathcal{H}(R) + \underbrace{\sum_{c,s,r} P(c, s, r | R) \cdot \left( -\log \frac{P(c, s, r | M)}{P(c, s, r | R)} \right)}_{\text{Divergencia KL } \mathcal{D}_{KL}(R||M)} \end{aligned}$$

Tasa de información del sistema de comunicación perfecto (entropía)  
+ Tasa de información debida a la imperfección del sistema (divergencia KL)

# Divergencia Kullback-Leibler

$$\sum_{c,s,r} P(c, s, r|R) \cdot \left( -\log \frac{P(c, s, r|M)}{P(c, s, r|R)} \right)$$

Tasa de información debida a la imperfección del sistema (divergencia KL)

# Divergencia Kullback-Leibler

$$\sum_{c,s,r} P(c, s, r|R) \cdot (\log P(c, s, r|R) - \log P(c, s, r|M))$$

Tasa de información debida a la imperfección del sistema (divergencia KL)

# Divergencia Kullback-Leibler

$$\sum_{c,s,r} P(c, s, r|R) \cdot \underbrace{(\log P(c, s, r|R) - \log P(c, s, r|M))}_{\substack{\text{La diferencia de predicción} \\ \text{en órdenes de magnitud}}}$$

Tasa de información debida a la imperfección del sistema (divergencia KL)

# Divergencia Kullback-Leibler

$$\sum_{c,s,r} P(c, s, r|R) \cdot \underbrace{(\log P(c, s, r|R) - \log P(c, s, r|M))}_{\substack{\text{La diferencia de predicción} \\ \text{en órdenes de magnitud}}}$$

Tasa de información debida a la imperfección del sistema (divergencia KL)

# Divergencia Kullback-Leibler


$$\sum_{c,s,r} P(c, s, r|R) \cdot \underbrace{(\log P(c, s, r|R) - \log P(c, s, r|M))}_{\substack{\text{La diferencia de predicción} \\ \text{en órdenes de magnitud}}}$$

¿Para qué sirve si no conozco la realidad?

Tasa de información debida a la imperfección del sistema (divergencia KL)

# TrueSkill

Posterior exacto





# TrueSkill

Posterior aproximado

$$\underbrace{\hat{p}(s_a | \text{Gana}, M)}_{\text{Aproximado}} = \arg \min_{\mu, \sigma} \mathcal{D}_{KL} \left( \underbrace{p(s_a | \text{Gana}, M)}_{\text{Exacto}} \parallel \underbrace{\mathcal{N}(s_a | \mu, \sigma^2)}_{\text{Familia}} \right)$$

# Mínima Divergencia

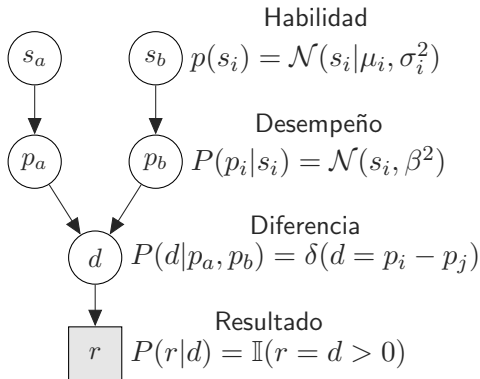
Posterior aproximado

$$\underbrace{\hat{p}(s_a|\text{Gana}, M)}_{\text{Aproximado}} = \arg \min_{\mu, \sigma} \mathcal{D}_{KL}(\underbrace{p(s_a|\text{Gana}, M)}_{\text{Exacto}} \parallel \underbrace{\mathcal{N}(s_a|\mu, \sigma^2)}_{\text{Familia}})$$

# Mínima Divergencia

Posterior aproximado

$$\underbrace{\hat{p}(s_a|\text{Gana}, M)}_{\text{Aproximado}} = \arg \min_{\mu, \sigma} \mathcal{D}_{KL} \left( \underbrace{p(s_a|\text{Gana}, M)}_{\text{Exacto}} \parallel \underbrace{\mathcal{N}(s_a|\mu, \sigma^2)}_{\text{Familia}} \right)$$



# Mínima Divergencia

Posterior aproximado

$$\underbrace{\hat{p}(s_a | \text{Gana}, M)}_{\text{Aproximado}} = \arg \min_{\mu, \sigma} \mathcal{D}_{KL} \left( \underbrace{p(s_a | \text{Gana}, M)}_{\text{Exacto}} \parallel \underbrace{\mathcal{N}(s_a | \mu, \sigma^2)}_{\text{Familia}} \right)$$

$$\underbrace{p(d, \text{Gana} \mid \text{Modelo})}_{\text{Marginal exacta}} = \int_{s_a} \int_{p_a} \int_{s_b} \int_{p_b} p(s_a) p(s_b) p(p_a | s_a) p(p_b | s_b) p(d | p_a, p_b) P(\text{Gana} | d)$$

# Mínima Divergencia

Posterior aproximado


$$\underbrace{\hat{p}(s_a | \text{Gana}, M)}_{\text{Aproximado}} = \arg \min_{\mu, \sigma} \mathcal{D}_{KL} \left( \underbrace{p(s_a | \text{Gana}, M)}_{\text{Exacto}} \parallel \underbrace{\mathcal{N}(s_a | \mu, \sigma^2)}_{\text{Familia}} \right)$$

$$\underbrace{p(d, \text{Gana} \mid \text{Modelo})}_{\text{Marginal exacta}} = \underbrace{\int_{s_a} \int_{p_a} \int_{s_b} \int_{p_b} p(s_a) p(s_b) p(p_a | s_a) p(p_b | s_b) p(d | p_a, p_b) P(\text{Gana} | d)}_{\text{Prior exacto } p(d) = \mathcal{N}(d \mid \underbrace{\mu_a - \mu_b}_{\text{Diferencia de medias}}, \underbrace{\sigma_a^2 + \sigma_b^2 + 2\beta^2}_{\text{Suma de incertidumbres})}}$$

# Mínima Divergencia

Posterior aproximado


$$p(d, \text{Gana}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(d > 0)$$



# Mínima Divergencia

Posterior aproximado


$$p(d, \text{Gana}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(d > 0)$$



# Mínima Divergencia

Posterior aproximado

$$p(d, \text{Gana}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(d > 0)$$





# Mínima Divergencia

Posterior aproximado

$$p(d, \text{Gana}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(d > 0)$$

$$\hat{p}(d, \text{Gana}) \propto \mathcal{N}\left(d \mid \underbrace{E(d, \text{Gana} | d > 0)}_{\text{Misma media}}, \underbrace{V(d, \text{Gana} | d > 0)}_{\text{Misma varianza}}\right)$$

# Mínima Divergencia

Posterior aproximado

$$p(d, \text{Gana}) = \mathcal{N}(d | \mu_a - \mu_b, \sigma_a^2 + \sigma_b^2 + 2\beta^2) \mathbb{I}(d > 0)$$

$$\hat{p}(d, \text{Gana}) \propto \mathcal{N}\left(d \mid \underbrace{E(d, \text{Gana} | d > 0)}_{\text{Misma media}}, \underbrace{V(d, \text{Gana} | d > 0)}_{\text{Misma varianza}}\right)$$

La divergencia es mínima cuando tienen mismos momentos.  
(Expectation Propagation)

# Inferencia aproximada

# Inferencia aproximada

## **Aproximaciones analíticas**

(Sesgadas pero rápidas y eficientes)

# Inferencia aproximada

## **Aproximaciones analíticas**

(Sesgadas pero rápidas y eficientes)

- Expectation propagation:  $\arg \min \mathcal{D}_{KL}(p||q)$

# Inferencia aproximada

## **Aproximaciones analíticas**

(Sesgadas pero rápidas y eficientes)

- Expectation propagation:  $\arg \min \mathcal{D}_{KL}(p||q)$
- Variational Inference:  $\arg \min \mathcal{D}_{KL}(q||p)$
- Otras

# Inferencia aproximada

## **Aproximaciones analíticas**

(Sesgadas pero rápidas y eficientes)

- Expectation propagation:  $\arg \min \mathcal{D}_{KL}(p||q)$
- Variational Inference:  $\arg \min \mathcal{D}_{KL}(q||p)$
- Otras

## **Aproximaciones por Monte Carlo**

(No sesgadas pero lentas y ineficientes)

# Inferencia aproximada

## **Aproximaciones analíticas**

(Sesgadas pero rápidas y eficientes)

- Expectation propagation:  $\arg \min \mathcal{D}_{KL}(p||q)$
- Variational Inference:  $\arg \min \mathcal{D}_{KL}(q||p)$
- Otras

## **Aproximaciones por Monte Carlo**

(No sesgadas pero lentas y ineficientes)

- Gibbs Sampler
- Metropolis Hasting
- Hamiltonian Monte Carlo
- Otras



# Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

# Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

## Soluciones

Física: acercarme para escuchar mejor

**Inferencia: interpretar la señal con ruido**

# Teoría de la información

El problema de la comunicación con la realidad

Quisiéramos que el mensaje recibido sea igual al enviado

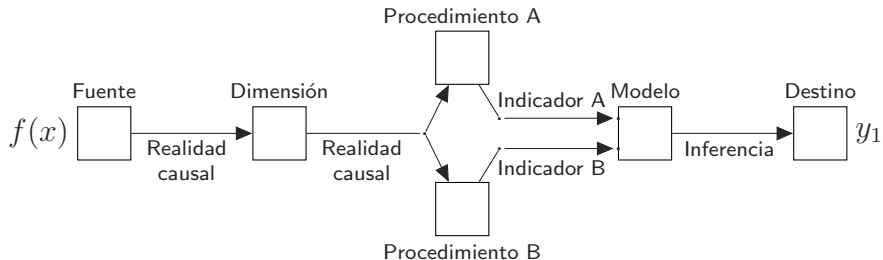
Soluciones

**Física: acercarme para escuchar mejor**

**Inferencia: interpretar la señal con ruido**

# Teoría de la información

El problema de la comunicación con la realidad



Evaluar procedimientos alternativos.

# Evaluación de test diagnóstico

## Test rápido de chagas



# Evaluación de test diagnóstico

## Test rápido de chagas

$P(\text{Diagnóstico}|\text{Estado})$

|               | D = Positivo        | D = Negativo         |
|---------------|---------------------|----------------------|
| E = Verdadero | <b>Sensibilidad</b> | 1-Sensibilidad       |
| E = Falso     | 1-Especificidad     | <b>Especificidad</b> |



# Evaluación de test diagnóstico

## Test rápido de chagas


$P(\text{Diagnóstico}|\text{Estado})$

|               | D = Positivo | D = Negativo |
|---------------|--------------|--------------|
| E = Verdadero | $s$          | $1 - s$      |
| E = Falso     | $1 - x$      | $x$          |



# Evaluación de test diagnóstico

Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$


|               | D = Positivo | D = Negativo |
|---------------|--------------|--------------|
| E = Verdadero | $s$          | $1 - s$      |
| E = Falso     | $1 - x$      | $x$          |

$$p \sim \text{Beta}(\alpha, \beta)$$



# Evaluación de test diagnóstico

Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$

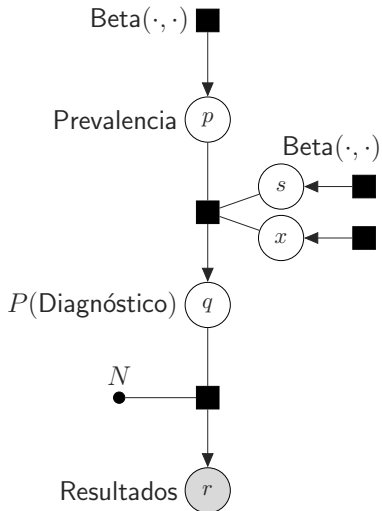
|               | D = Positivo | D = Negativo |
|---------------|--------------|--------------|
| E = Verdadero | $s$          | $1 - s$      |
| E = Falso     | $1 - x$      | $x$          |

$$p \sim \text{Beta}(\alpha, \beta)$$

$$q = p s + (1 - p) (1 - x)$$

# Evaluación de test diagnóstico

## Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$

|               | D = Positivo | D = Negativo |
|---------------|--------------|--------------|
| E = Verdadero | $s$          | $1 - s$      |
| E = Falso     | $1 - x$      | $x$          |


$$p \sim \text{Beta}(\alpha, \beta)$$

$$q = p s + (1 - p) (1 - x)$$

$$r = \underbrace{(n_0)}_{-}, \underbrace{(n_1)}_{+} \sim \text{Binomial}(q, N)$$

# Evaluación de test diagnóstico

## Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$


|               | D = Positivo | D = Negativo |
|---------------|--------------|--------------|
| E = Verdadero | $s$          | $1 - s$      |
| E = Falso     | $1 - x$      | $x$          |

$$p \sim \text{Beta}(\alpha, \beta)$$

$$r = \left( \underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++} \right) \sim \text{Multinomial}(q, N)$$

# Evaluación de test diagnóstico

## Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$

|               | D = Positivo | D = Negativo |
|---------------|--------------|--------------|
| E = Verdadero | $s$          | $1 - s$      |
| E = Falso     | $1 - x$      | $x$          |


$$p \sim \text{Beta}(\alpha, \beta)$$

$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$

$$q = (q_0, q_1, q_2, q_3)$$

# Evaluación de test diagnóstico

## Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$

|               | D = Positivo | D = Negativo |
|---------------|--------------|--------------|
| E = Verdadero | $s$          | $1 - s$      |
| E = Falso     | $1 - x$      | $x$          |

$$p \sim \text{Beta}(\alpha, \beta)$$


$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$

$$q = (q_0, q_1, q_2, q_3)$$

$$q_0 = p(1 - s_a)(1 - s_b) + (1 - p)x_a x_b$$

# Evaluación de test diagnóstico

## Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$

|               | D = Positivo | D = Negativo |
|---------------|--------------|--------------|
| E = Verdadero | $s$          | $1 - s$      |
| E = Falso     | $1 - x$      | $x$          |

$$p \sim \text{Beta}(\alpha, \beta)$$

$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$

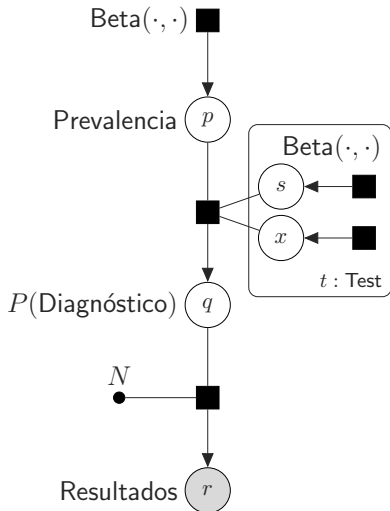
$$q = (q_0, q_1, q_2, q_3)$$

$$q_0 = p(1 - s_a)(1 - s_b) + (1 - p)x_a x_b$$

$$q_1 = p(1 - s_a)s_b + (1 - p)x_a(1 - x_b)$$

# Evaluación de test diagnóstico

## Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$

|               | D = Positivo | D = Negativo |
|---------------|--------------|--------------|
| E = Verdadero | $s$          | $1 - s$      |
| E = Falso     | $1 - x$      | $x$          |

$$p \sim \text{Beta}(\alpha, \beta)$$

$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$

$$q = (q_0, q_1, q_2, q_3)$$


$$q_0 = p(1 - s_a)(1 - s_b) + (1 - p)x_a x_b$$

$$q_1 = p(1 - s_a)s_b + (1 - p)x_a(1 - x_b)$$

$$q_2 = \dots$$

# Evaluación de test diagnóstico

## Test rápido de chagas



$P(\text{Diagnóstico}|\text{Estado})$

|               | D = Positivo | D = Negativo |
|---------------|--------------|--------------|
| E = Verdadero | $s$          | $1 - s$      |
| E = Falso     | $1 - x$      | $x$          |

$$p \sim \text{Beta}(\alpha, \beta)$$

$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$

$$q = (q_0, q_1, q_2, q_3)$$

Problema no identificable

5 hipótesis  $(p, s_a, x_a, s_b, x_b)$  y 3 datos  $(n_0, n_1, n_2)$



# Evaluación de test diagnóstico

## Test rápido de chagas

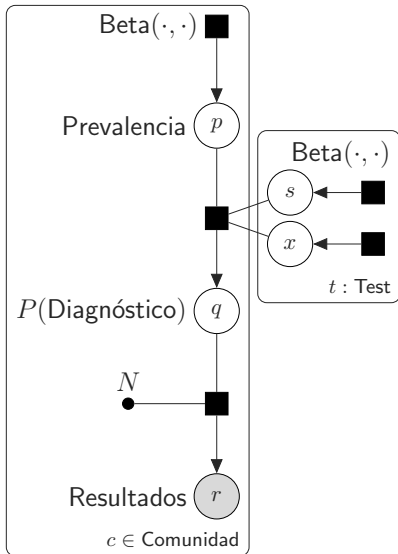
$P(\text{Diagnóstico}|\text{Estado})$

|               | D = Positivo | D = Negativo |
|---------------|--------------|--------------|
| E = Verdadero | $s$          | $1 - s$      |
| E = Falso     | $1 - x$      | $x$          |

$$p \sim \text{Beta}(\alpha, \beta)$$

$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$

$$q = (q_0, q_1, q_2, q_3)$$



# Evaluación de test diagnóstico

## Test rápido de chagas

$P(\text{Diagnóstico}|\text{Estado})$

|               | D = Positivo | D = Negativo |
|---------------|--------------|--------------|
| E = Verdadero | $s$          | $1 - s$      |
| E = Falso     | $1 - x$      | $x$          |


$$p \sim \text{Beta}(\alpha, \beta)$$

$$r = (\underbrace{n_0}_{--}, \underbrace{n_1}_{-+}, \underbrace{n_2}_{+-}, \underbrace{n_3}_{++}) \sim \text{Multinomial}(q, N)$$


$$q = (q_0, q_1, q_2, q_3)$$

Problema identificable

6 hipótesis  $(p_A, p_B, s_a, x_a, s_b, x_b)$  y 6 datos  $(r_A, r_B)$



# Evaluación de test diagnóstico



```

modelo <- "model{
  s[1] ~ dbeta(1, 1)
  s[2] ~ dbeta(1, 1)
  x[1] ~ dbeta(1, 1)
  x[2] ~ dbeta(1, 1)

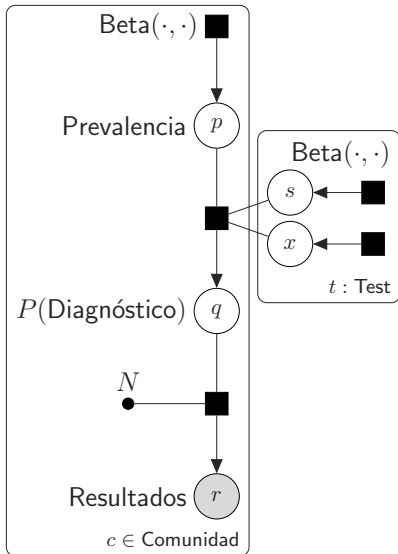
  for(c in 1:Comunidades){
    p[c] ~ dbeta(1, 1)

    q[1,c] <- p[c]*(1-s[1])*(1-s[2]) + (1-p[c])*x[1]*x[2]
    q[2,c] <- p[c]*(1-s[1])*s[2] + (1-p[c])*x[1]*(1-x[2])
    q[3,c] <- p[c]*s[1]*(1-s[2]) + (1-p[c])*(1-x[1])*x[2]
    q[4,c] <- p[c]*s[1]*s[2] + (1-p[c])*(1-x[1])*(1-x[2])

    r[1:4, c] ~ dmulti(q[1:4, c], N[c])
  }
  #data# r, N, Comunidades
  #monitor# p, s, x
  #inits# p, s, x
}"

```

# Evaluación de test diagnóstico



```
library("runjags") # JAGS: Just Another Gibbs Sampler
```

```
p = c(0, 0.15, 0.3, 0.45, 0.7) # REALIDAD
```

```
sensitivity = c(0.9, 0.6)
```

```
specificity = c(0.95, 0.9)
```

```
r <- matrix(nrow=4, ncol=length(p)) # DATA (simulada)
```

```
r[,1] <- c(839, 104, 44, 7)
```

```
r[,2] <- c(754, 92, 85, 92)
```

```
r[,3] <- c(598, 99, 134, 151)
```

```
r[,4] <- c(503, 75, 187, 240)
```

```
r[,5] <- c(275, 61, 287, 373)
```

```
N <- apply(r, MARGIN=2, FUN=sum); Comunidades = 5
```

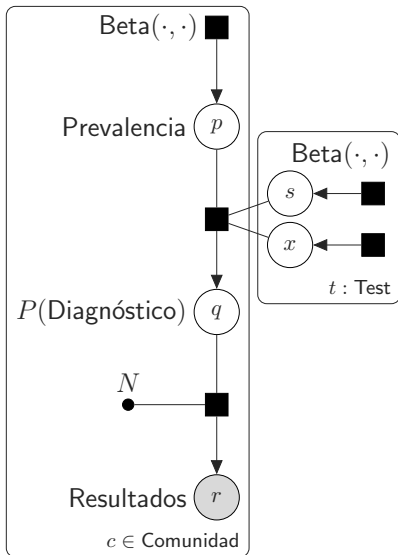
```
s <- list(chain1=c(0.5,0.99), chain2=c(0.99,0.5)) # INITS
```

```
x <- list(chain1=c(0.5,0.99), chain2=c(0.99,0.5))
```

```
p <- list(chain1=c(0.1, 0.1, 0.1, 0.9, 0.9), chain2=c(0.9,  
0.9, 0.9, 0.1, 0.1))
```


```
results <- run.jags(modelo, n.chains=2)
```

# Evaluación de test diagnóstico



|      | Lower95 | Median  | Upper95 | #Real |
|------|---------|---------|---------|-------|
| p[1] | 6e-07   | 0.0071  | 0.0184  | #0.00 |
| p[2] | 0.1213  | 0.1501  | 0.1792  | #0.15 |
| p[3] | 0.2478  | 0.2829  | 0.3207  | #0.30 |
| p[4] | 0.3922  | 0.4324  | 0.4718  | #0.45 |
| p[5] | 0.6573  | 0.7016  | 0.7428  | #0.70 |
| s[1] | 0.8822  | 0.9233  | 0.9646  | #0.95 |
| s[2] | 0.5556  | 0.5829  | 0.6129  | #0.60 |
| x[1] | 0.9429  | 0.9566  | 0.9705  | #0.95 |
| x[2] | 0.8755  | 0.8897  | 0.9034  | #0.90 |
|      | SSeff   | AC.10   | psrf    |       |
| p[1] | 5575    | 0.02143 | 1.0000  |       |
| p[2] | 6162    | 0.03274 | 1.0002  |       |
| p[3] | 5323    | 0.01990 | 1.0000  |       |
| p[4] | 4992    | 0.04256 | 0.9999  |       |
| p[5] | 3730    | 0.04781 | 1.0004  |       |
| s[1] | 2742    | 0.08044 | 1.0009  |       |
| s[2] | 7065    | 0.01934 | 1.0002  |       |
| x[1] | 4558    | 0.04616 | 1.0007  |       |
| x[2] | 4260    | 0.04574 | 1.0001  |       |

# Tasa de información de los sistemas de comunicación



¿Con qué procedimiento nos quedamos?

$p = \mathbf{b}$

Laboratorios de  
Métodos Bayesianos

# Bibliografía Unidad 4

- Bishop, C. **Pattern Recognition and Machine Learning**. 2006. ([Descargar](#)).  
(lectura 8.1, 8.2 y 8.4)
- Neal. **Pattern Recognition and Machine Learning**. 2020 (Draft). ([Descargar](#)).  
(lectura capítulo 1 y 3)