

Modelos de historia completa



Bibliografía Unidad 7

- Dangauthier P, Herbrich R, Minka T, Graepel T. *Trueskill through time: Revisiting the history of chess*. NeurIPS; 2008 ([Descargar](#)). (completo)
- Bishop, C. *Pattern recognition and machine learning*. Springer; 2006 ([Descargar](#)). (lecturas 13.2.3-13.2.4, 13.3)

Otros:

- Brodersen KH, Gallusser F, Koehler J, Remy N, Scott SL. *Inferring causal impact using Bayesian structural time-series models*. The Annals of Applied Statistics. 2015 ([Paper](#)).
- Hernán. *Causal inference: What if*. CRC Boca Raton, FL. 2020. ([Parte III](#)).

Series de tiempo

Creencias adaptativas

La función de costo epistémica

$$\underbrace{P(\text{Hipótesis}, \text{Datos})}_{\text{Creencia compatible con los datos}} = \underbrace{P(\text{Hipótesis})}_{\text{Acuerdo intersubjetivo inicial}} \underbrace{P(\text{dato}_1 | \text{Hipótesis})}_{\text{Predicción 1}} \underbrace{P(\text{dato}_2 | \text{dato}_1, \text{Hipótesis})}_{\text{Predicción 2}} \dots$$

Series de tiempo

Creencias adaptativas

La función de costo epistémica

$$\underbrace{P(\text{Hipótesis}, \text{Datos})}_{\text{Creencia compatible con los datos}} = \underbrace{P(\text{Hipótesis})}_{\text{Acuerdo intersubjetivo inicial}} \underbrace{P(\text{dato}_1 | \text{Hipótesis})}_{\text{Predicción 1}} \underbrace{P(\text{dato}_2 | \text{dato}_1, \text{Hipótesis})}_{\text{Predicción 2}} \dots$$

Un único 0 en la secuencia de predicciones
hace falsa la hipótesis para siempre.

Series de tiempo

Creencias adaptativas

La función de costo epistémica

$$\underbrace{P(\text{Hipótesis}, \text{Datos})}_{\text{Creencia compatible con los datos}} = \underbrace{P(\text{Hipótesis})}_{\text{Acuerdo intersubjetivo inicial}} \underbrace{P(\text{dato}_1 | \text{Hipótesis})}_{\text{Predicción 1}} \underbrace{P(\text{dato}_2 | \text{dato}_1, \text{Hipótesis})}_{\text{Predicción 2}} \dots$$

Ejemplo

Esa persona no está apta para realizar esa tarea.

Series de tiempo

Creencias adaptativas

La función de costo epistémica

$$\underbrace{P(\text{Hipótesis}, \text{Datos})}_{\text{Creencia compatible con los datos}} = \underbrace{P(\text{Hipótesis})}_{\text{Acuerdo intersubjetivo inicial}} \underbrace{P(\text{dato}_1 | \text{Hipótesis})}_{\text{Predicción 1}} \underbrace{P(\text{dato}_2 | \text{dato}_1, \text{Hipótesis})}_{\text{Predicción 2}} \dots$$


Ejemplo

Esa persona no está apta para realizar esa tarea.



¿Para siempre?!



Estimación de habilidad en la industria del videojuego



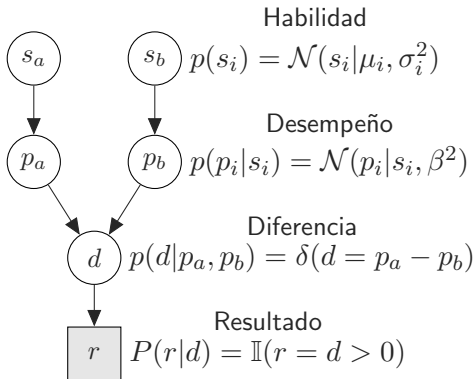
Estimación de habilidad en la industria del videojuego



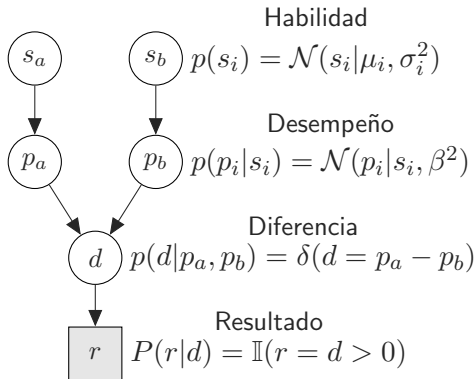
Estimación de habilidad en la industria del videojuego

Prior \rightarrow Posterior

¿Cómo estimamos una habilidad en el tiempo?



Estimación de habilidad en la industria del videojuego



Prior \rightarrow Posterior

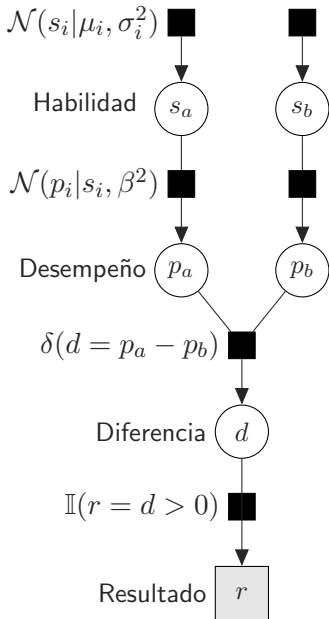
¿Cómo estimamos una habilidad en el tiempo?

¿Si usamos el último posterior como prior del siguiente evento?

Posterior _{t} \rightarrow Prior _{$t+1$}

Algoritmo suma-producto

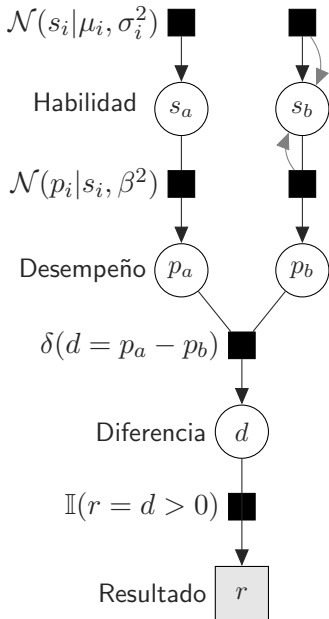
Las reglas de la probabilidad por pasaje de mensajes



Algoritmo suma-producto

Las reglas de la probabilidad por pasaje de mensajes

$$p(s_b, r) = \underbrace{m_{f_{s_b} \rightarrow s_b}(s_b)}_{\text{Prior}} \cdot \underbrace{m_{f_{p_b} \rightarrow s_b}(s_b)}_{\text{Likelihood}}$$

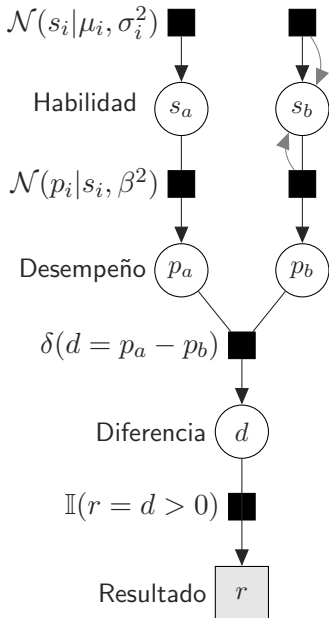


Algoritmo suma-producto

Las reglas de la probabilidad por pasaje de mensajes


$$p(s_b, r) = \underbrace{m_{f_{s_b} \rightarrow s_b}(s_b)}_{\text{Prior}} \cdot \underbrace{m_{f_{p_b} \rightarrow s_b}(s_b)}_{\text{Likelihood}}$$

$$\underbrace{m_{x \rightarrow f}(x)}_{\text{Mensaje de las variables}} = \prod_{\underbrace{g \in v(x) \setminus \{f\}}_{\text{El producto de lo que recibe de atrás}}} m_{g \rightarrow x}(x)$$



Algoritmo suma-producto

Las reglas de la probabilidad por pasaje de mensajes

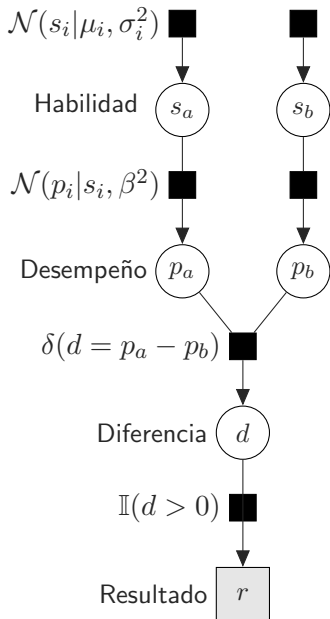


$$p(s_b, r) = \underbrace{m_{f_{s_b} \rightarrow s_b}(s_b)}_{\text{Prior}} \cdot \underbrace{m_{f_{p_b} \rightarrow s_b}(s_b)}_{\text{Likelihood}}$$

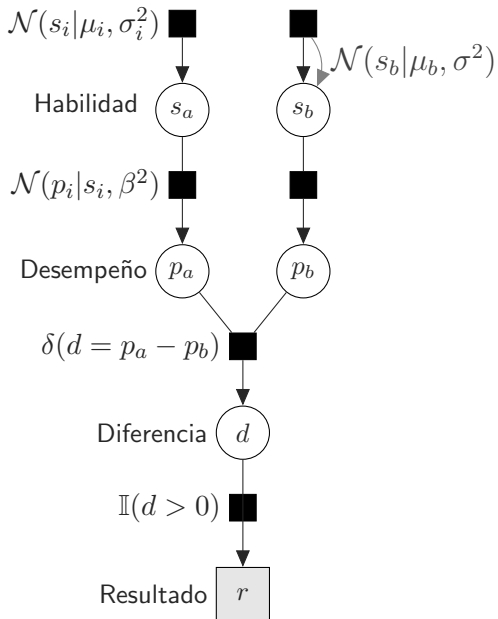
$$\underbrace{m_{x \rightarrow f}(x)}_{\text{Mensaje de las variables}} = \prod_{\underbrace{g \in v(x) \setminus \{f\}}_{\text{El producto de lo que recibe de atrás}}} m_{g \rightarrow x}(x)$$

$$\underbrace{m_{f \rightarrow x}(x)}_{\text{Mensaje de los factores}} = \sum_y \left(f(y, x) \underbrace{\prod_{y \in v(f) \setminus \{x\}} m_{y \rightarrow f}(y)}_{\text{Lo que recibe de atrás por el factor, integrando todas las variables de atrás}} \right)$$

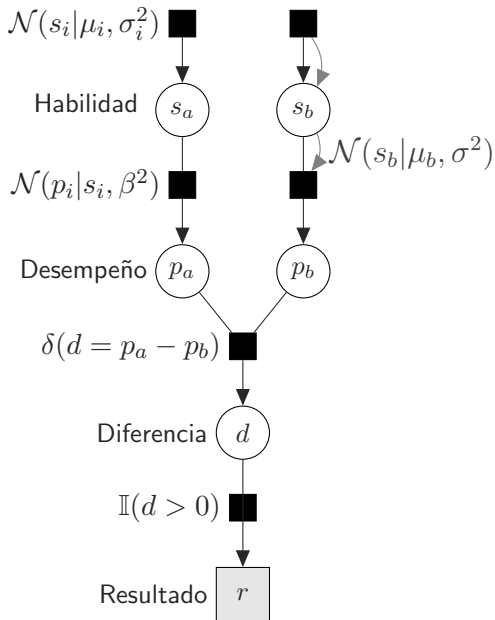
Estimación de habilidad en la industria del videojuego



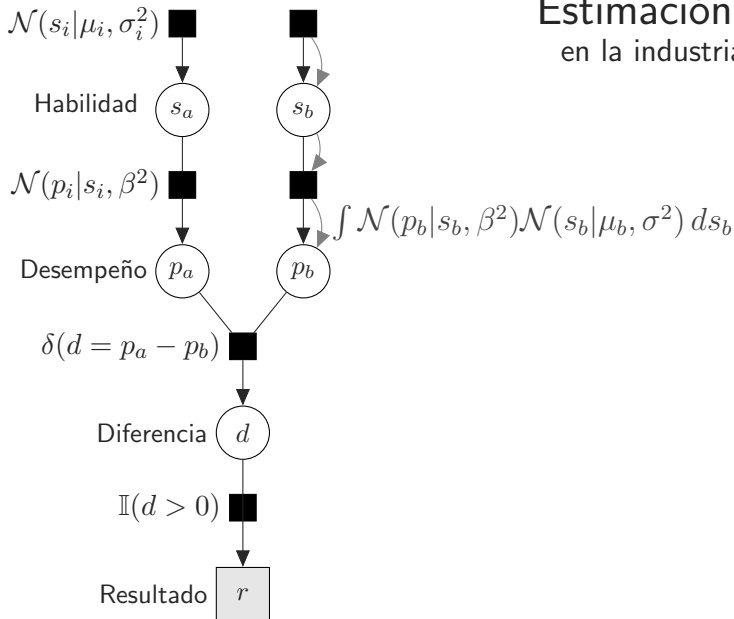
Estimación de habilidad en la industria del videojuego



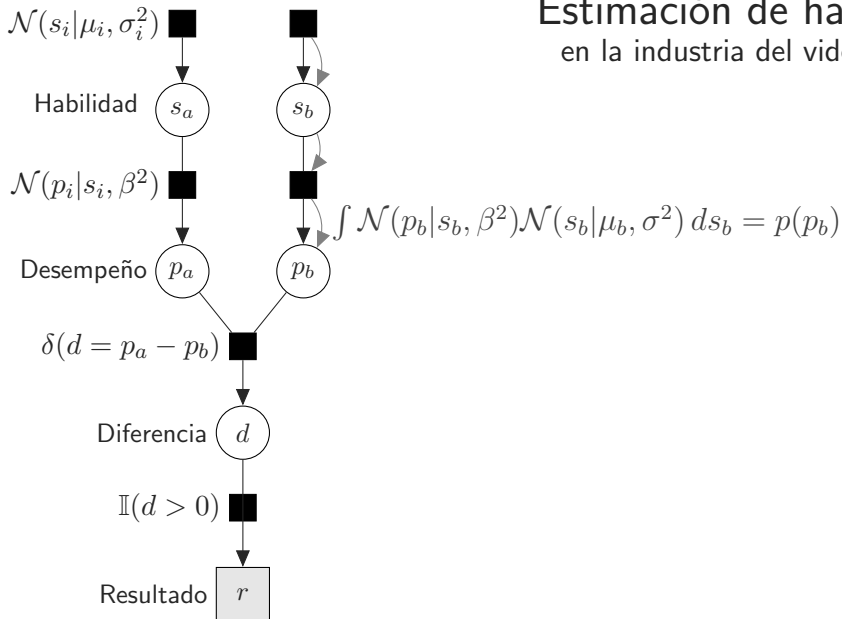
Estimación de habilidad en la industria del videojuego



Estimación de habilidad en la industria del videojuego

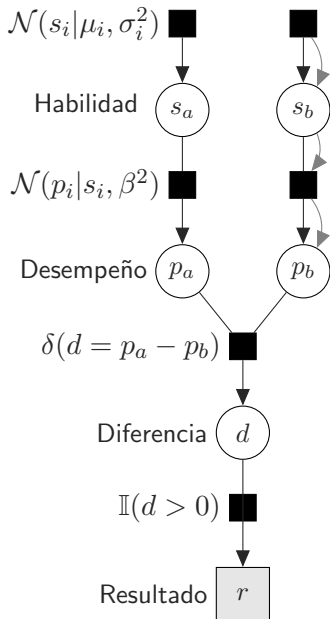


Estimación de habilidad en la industria del videojuego





Estimación de habilidad en la industria del videojuego

$$p(p_b) = \int \mathcal{N}(p_b | s_b, \beta^2) \mathcal{N}(s_b | \mu_b, \sigma_b^2) ds_b$$



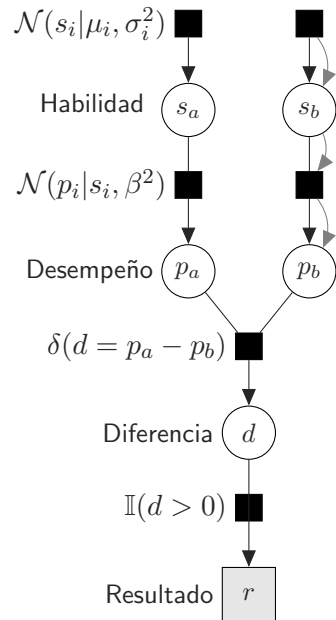


Estimación de habilidad en la industria del videojuego

$$p(p_b) = \int \mathcal{N}(p_b | s_b, \beta^2) \mathcal{N}(s_b | \mu_b, \sigma_b^2) ds_b$$



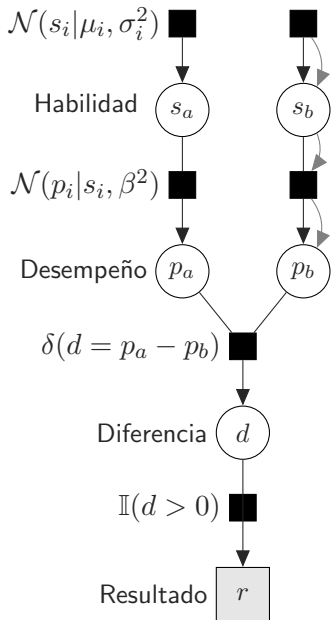
Estimación de habilidad en la industria del videojuego

$$p(p_b) = \int \mathcal{N}(p_b|s_b, \beta^2) \mathcal{N}(s_b|\mu_b, \sigma_b^2) ds_b$$



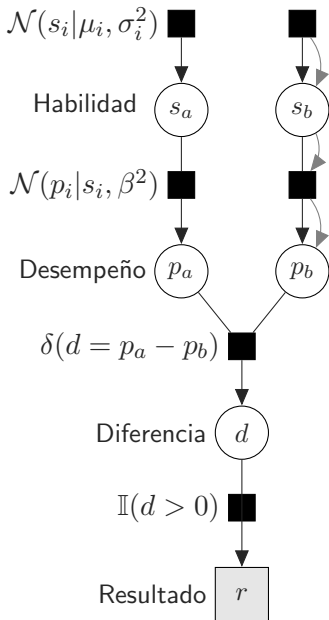
Estimación de habilidad en la industria del videojuego

$$\begin{aligned} p(p_b) &= \int \mathcal{N}(p_b | s_b, \beta^2) \mathcal{N}(s_b | \mu_b, \sigma_b^2) ds_b \\ &\stackrel{*}{=} \int \mathcal{N}(p_a | \mu_a, \beta^2 + \sigma_a^2) \mathcal{N}(s_a | \mu_*, \sigma_*^2) ds_a \end{aligned}$$




Estimación de habilidad en la industria del videojuego

$$\begin{aligned}
 p(p_b) &= \int \mathcal{N}(p_b | s_b, \beta^2) \mathcal{N}(s_b | \mu_b, \sigma_b^2) ds_b \\
 &\stackrel{*}{=} \int \underbrace{\mathcal{N}(p_b | \mu_b, \beta^2 + \sigma_b^2)}_{\text{const.}} \underbrace{\mathcal{N}(s_b | \mu_*, \sigma_*^2)}_1 ds_b
 \end{aligned}$$

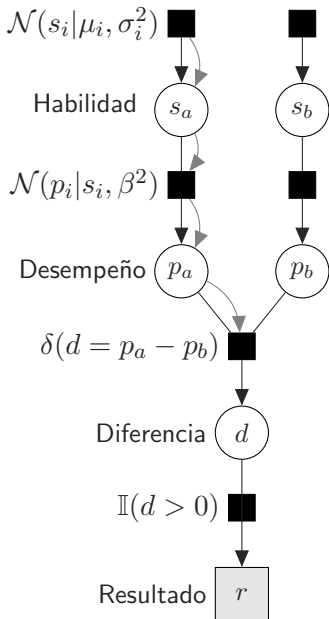


Estimación de habilidad en la industria del videojuego

$$\begin{aligned} p(p_b) &= \int \mathcal{N}(p_b | s_b, \beta^2) \mathcal{N}(s_b | \mu_b, \sigma_b^2) ds_b \\ &\stackrel{*}{=} \mathcal{N}(p_b | \mu_b, \beta^2 + \sigma_b^2) \end{aligned}$$

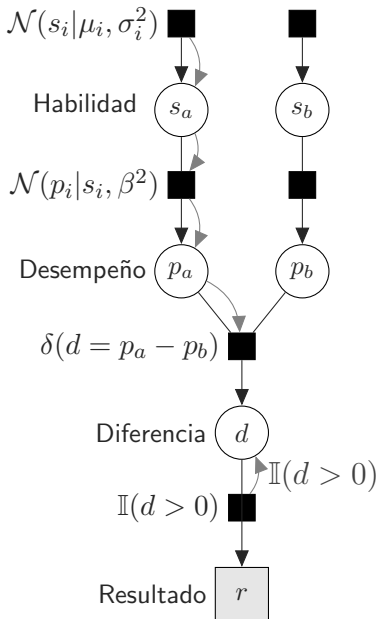


Estimación de habilidad en la industria del videojuego



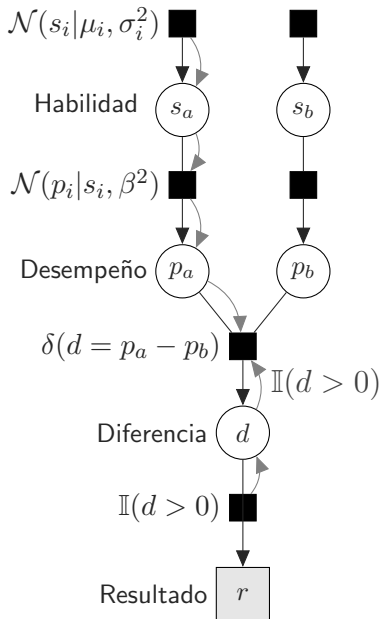
$$p(p_a) \stackrel{*}{=} \mathcal{N}(p_b | \mu_a, \beta^2 + \sigma_a^2)$$

Estimación de habilidad en la industria del videojuego



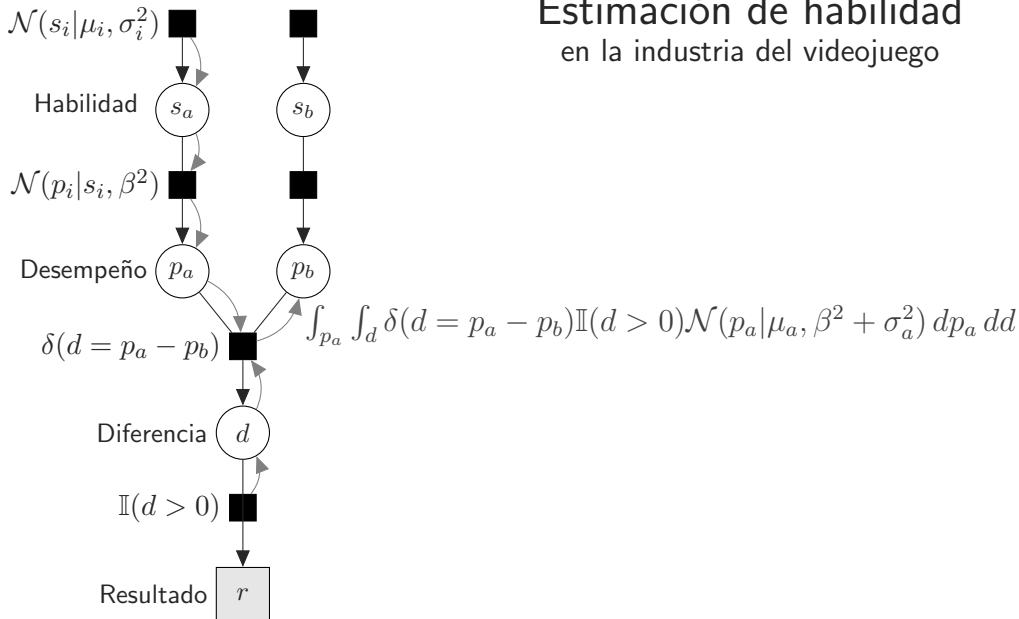
$$p(p_a) \stackrel{*}{=} \mathcal{N}(p_b | \mu_a, \beta^2 + \sigma_a^2)$$

Estimación de habilidad en la industria del videojuego

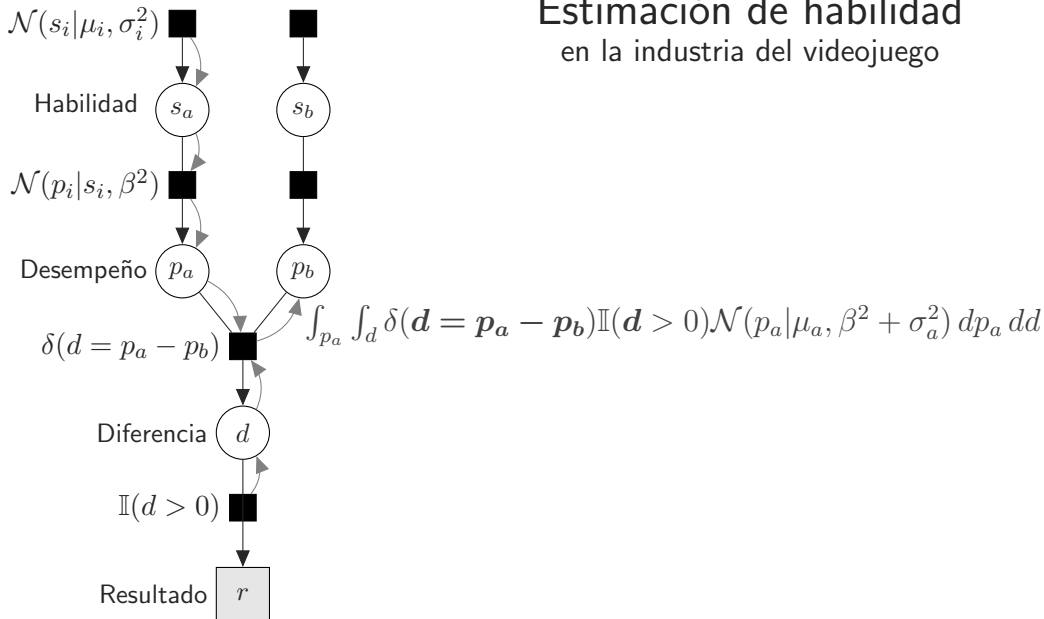


$$p(p_a) \stackrel{*}{=} \mathcal{N}(p_b | \mu_a, \beta^2 + \sigma_a^2)$$


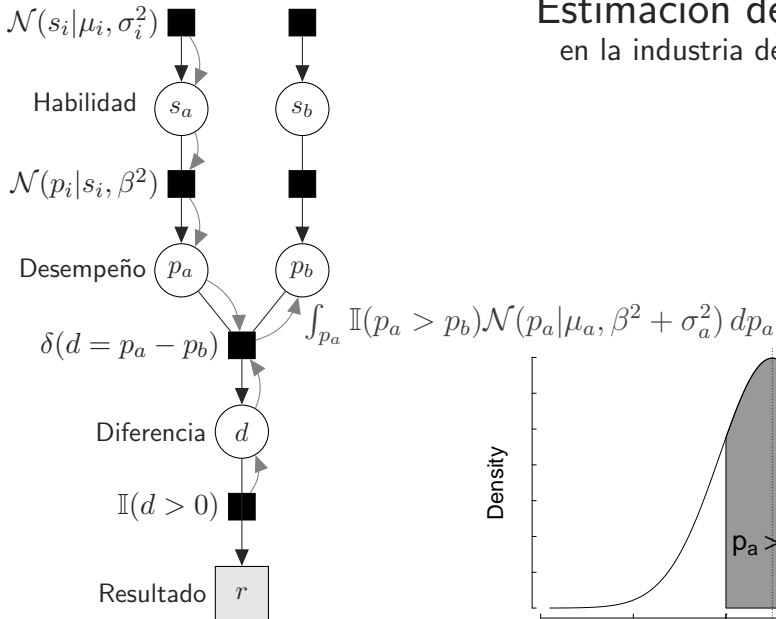
Estimación de habilidad en la industria del videojuego



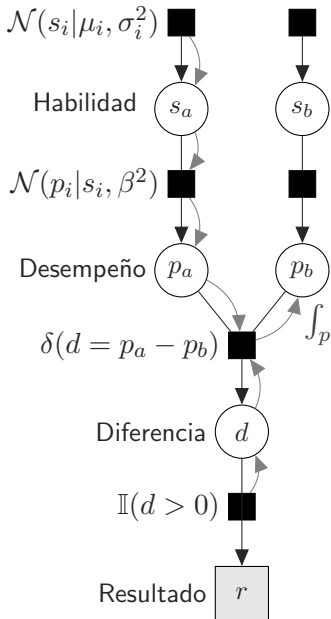
Estimación de habilidad en la industria del videojuego




Estimación de habilidad en la industria del videojuego





Estimación de habilidad en la industria del videojuego



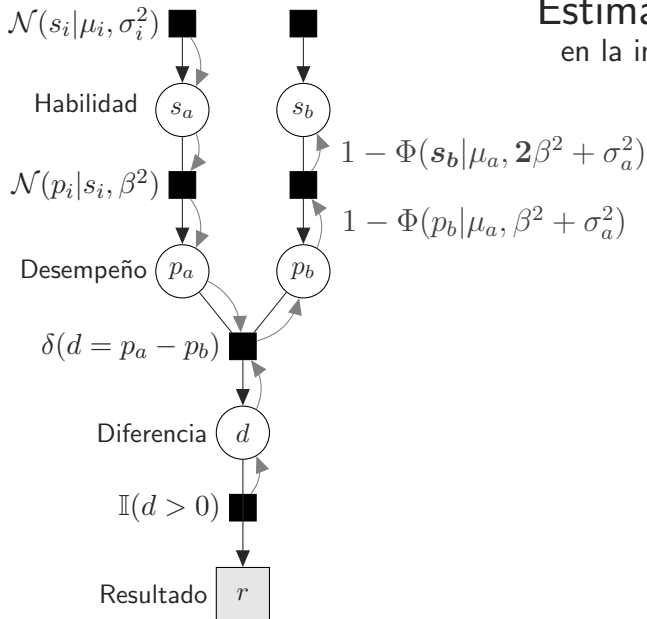
$$\int_{p_a} \mathbb{I}(p_a > p_b) \mathcal{N}(p_a | \mu_a, \beta^2 + \sigma_a^2) dp_a = 1 - \Phi(p_b | \mu_a, \beta^2 + \sigma_a^2)$$



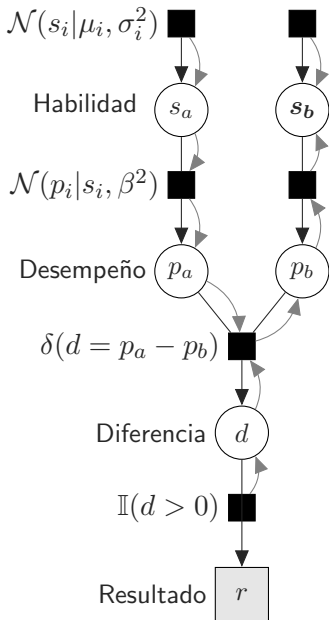
Estimación de habilidad en la industria del videojuego




Estimación de habilidad en la industria del videojuego



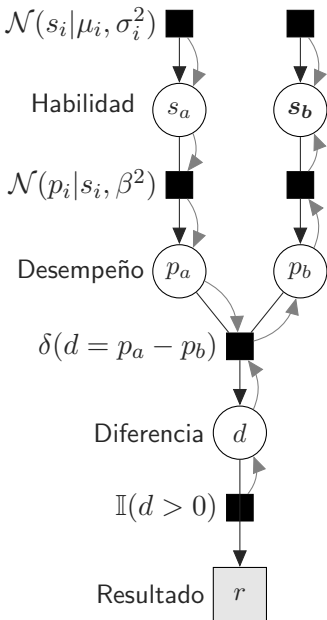
Estimación de habilidad en la industria del videojuego




$$p(s_b, r^*) = \overbrace{\mathcal{N}(s_b | \mu_b, \sigma_b^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 | \mu_a - s_b, 2\beta^2 + \sigma_a^2)}^{\text{Predicción o verosimilitud}}$$



Estimación de habilidad en la industria del videojuego

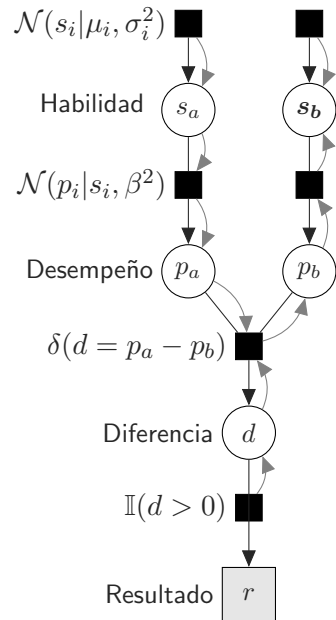



$$p(s_b, r^*) = \overbrace{\mathcal{N}(s_b | \mu_b, \sigma_b^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 | \mu_a - s_b, 2\beta^2 + \sigma_a^2)}^{\text{Predicción o verosimilitud}}$$



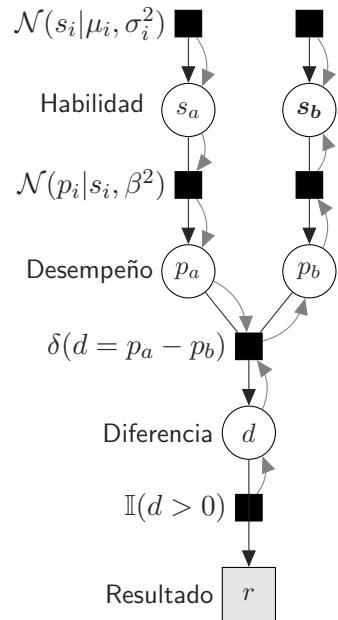

Estimación de habilidad en la industria del videojuego

$$p(s_b, r^*) = \overbrace{\mathcal{N}(s_b | \mu_b, \sigma_b^2)}^{\text{Prior}} \overbrace{1 - \Phi(0 | \mu_a - s_b, 2\beta^2 + \sigma_a^2)}^{\text{Predicción o verosimilitud}}$$



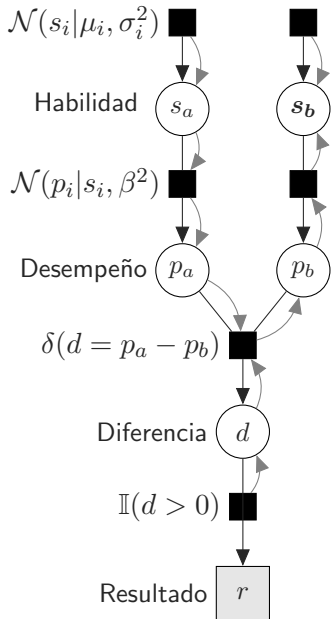

Estimación de habilidad en la industria del videojuego

$$\hat{p}(s_b|r^*) = \arg \min_{\mu, \sigma} \text{KL}(p(s_b|r^*) || \mathcal{N}(s_b|\mu, \sigma^2))$$



Estimación de habilidad en la industria del videojuego

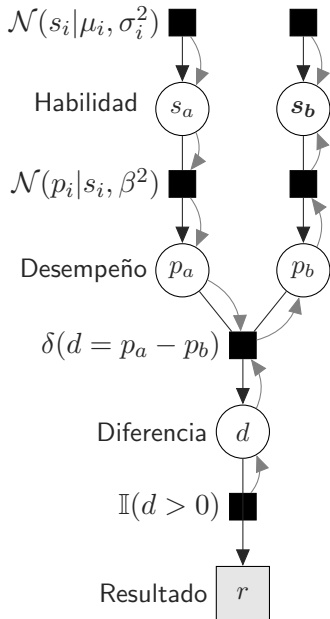
$$\hat{p}(s_b | r^*) = \mathcal{N}(s_b | \hat{\mu}, \hat{\sigma}^2)$$



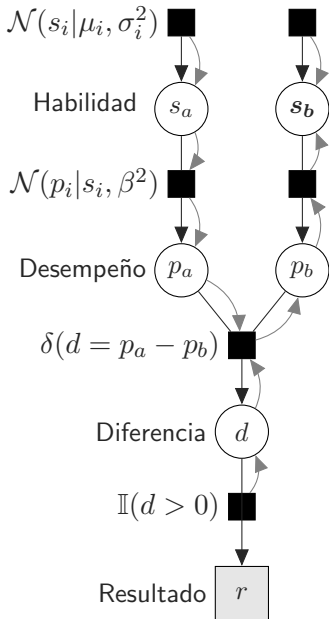
Estimación de habilidad en la industria del videojuego

$$\underbrace{\hat{p}(s_b | r^*)}_{\text{Posterior}_1} = \mathcal{N}(s_b | \hat{\mu}, \hat{\sigma}^2)$$

$$\widehat{\text{Posterior}_t} \rightarrow \text{Prior}_{t+1}$$



Estimación de habilidad en la industria del videojuego




$$\underbrace{\widehat{p}(s_b | r^*)}_{\text{Posterior}_1} = \mathcal{N}(s_b | \widehat{\mu}, \widehat{\sigma}^2)$$


$$\widehat{\text{Posterior}}_t \rightarrow \text{Prior}_{t+1}$$

$$\underbrace{p(s_b)}_{\text{Prior}_2} = \mathcal{N}(s_b | \widehat{\mu}, \widehat{\sigma}^2 + \gamma^2)$$

Enfoque Posterior \rightarrow Prior



Enfoque Posterior \rightarrow Prior



Enfoque Posterior \rightarrow Prior

Problemas de un procedimiento ad-hoc

Problemas.

- Ofrece resultados que van en contra de nuestra intuición

Enfoque Posterior \rightarrow Prior

Problemas de un procedimiento ad-hoc

Problemas.

- Ofrece resultados que van en contra de nuestra intuición
- Mucha incertidumbre al inicio de las series temporales

Enfoque Posterior \rightarrow Prior

Problemas de un procedimiento ad-hoc

Problemas.

- Ofrece resultados que van en contra de nuestra intuición
- Mucha incertidumbre al inicio de las series temporales
- No aprovecha la información disponible (entre ramas paralelas)

Enfoque Posterior \rightarrow Prior

Problemas de un procedimiento ad-hoc

Problemas.

- Ofrece resultados que van en contra de nuestra intuición
- Mucha incertidumbre al inicio de las series temporales
- No aprovecha la información disponible (entre ramas paralelas)
- No garantiza comparabilidad entre estimaciones lejanas en el tiempo y el espacio.

Enfoque Posterior \rightarrow Prior

Problemas de un procedimiento ad-hoc


Propaga la información en una sola dirección, del pasado al futuro.

Problemas.

- Ofrece resultados que van en contra de nuestra intuición
- Mucha incertidumbre al inicio de las series temporales
- No aprovecha la información disponible (entre ramas paralelas)
- No garantiza comparabilidad entre estimaciones lejanas en el tiempo y el espacio.


Modelos de historia completa

Estado del arte en la industria del videojuego.



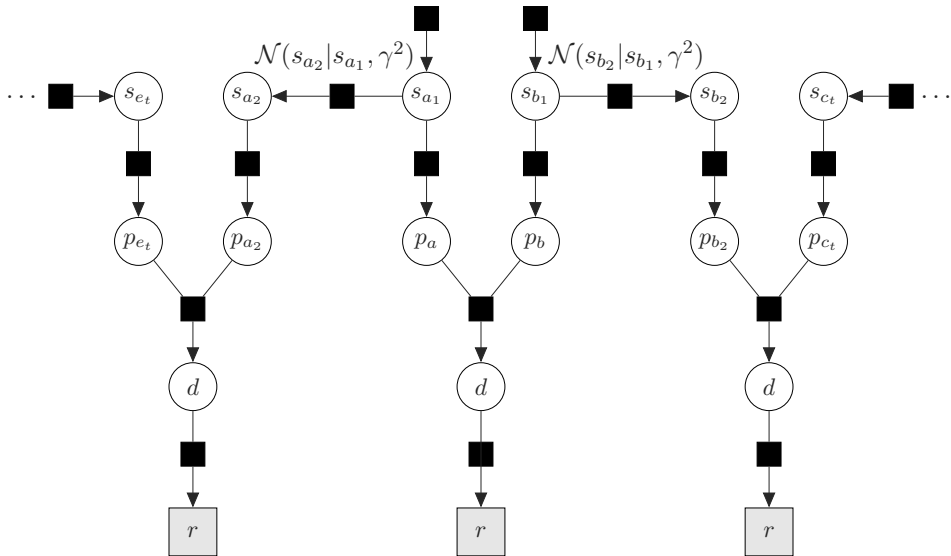
Modelos de historia completa

Estado del arte en la industria del videojuego.




Modelos de historia completa

Estado del arte en la industria del videojuego.




Modelos de historia completa

Estado del arte en la industria del videojuego.




Modelos de historia completa

Smoothing




Modelos de historia completa

Smoothing



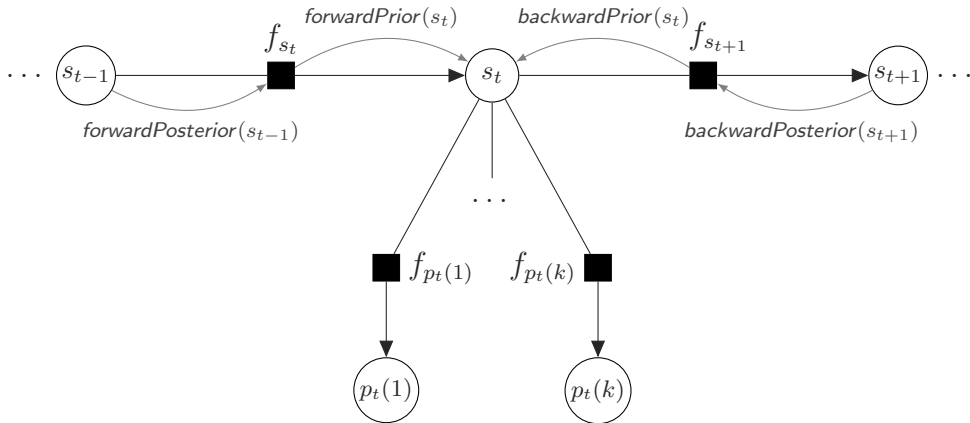
Modelos de historia completa

Smoothing



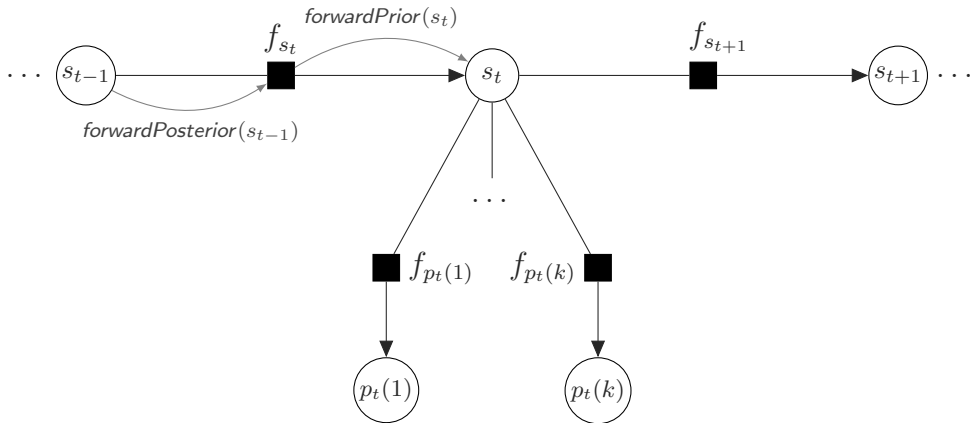
Modelos de historia completa

Smoothing



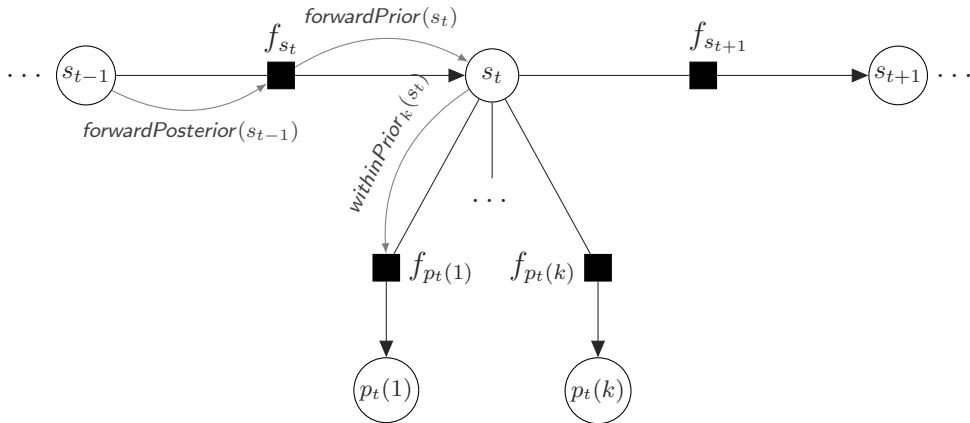
Modelos de historia completa

Smoothing



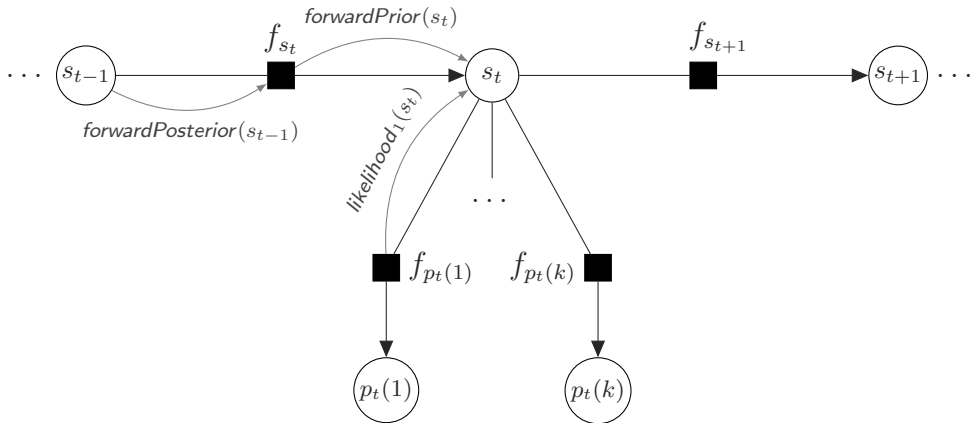
Modelos de historia completa

Smoothing



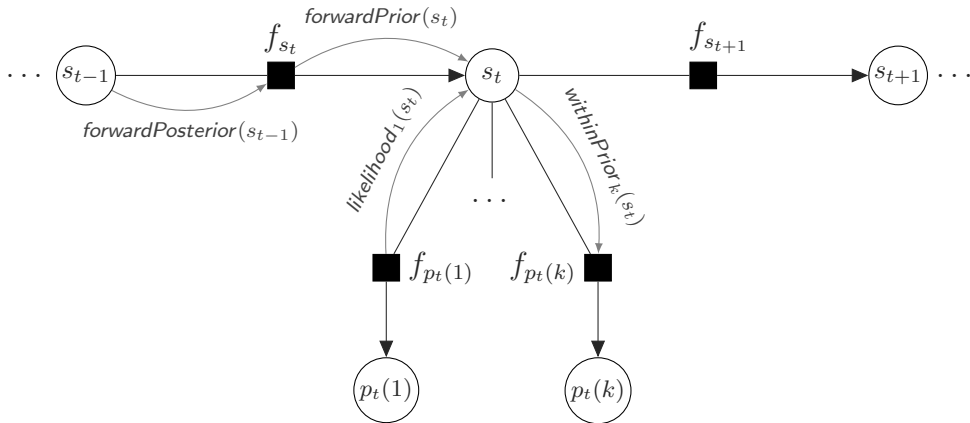
Modelos de historia completa

Smoothing



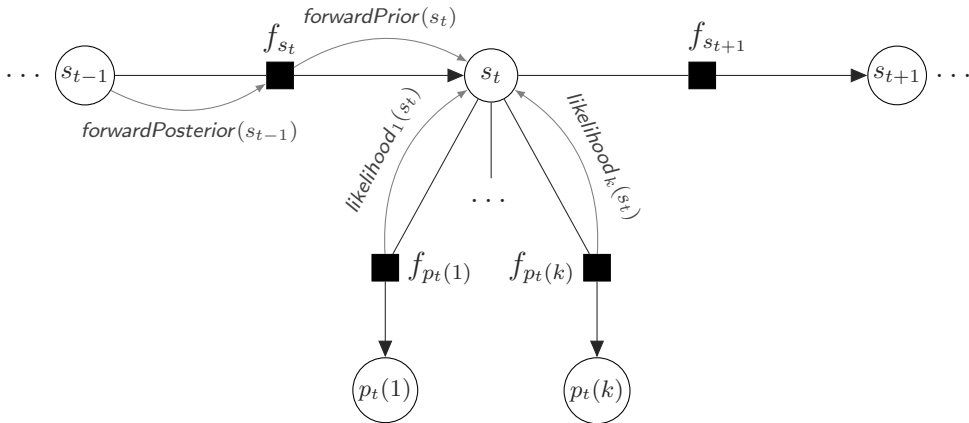
Modelos de historia completa

Smoothing



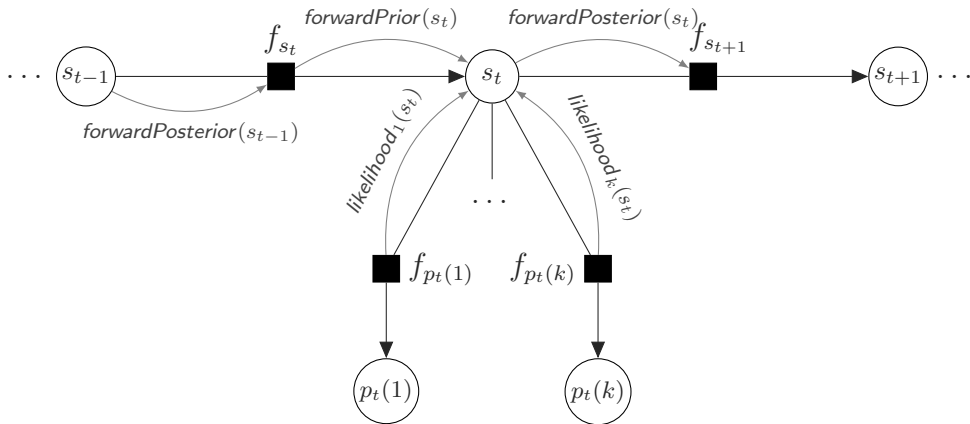
Modelos de historia completa

Smoothing



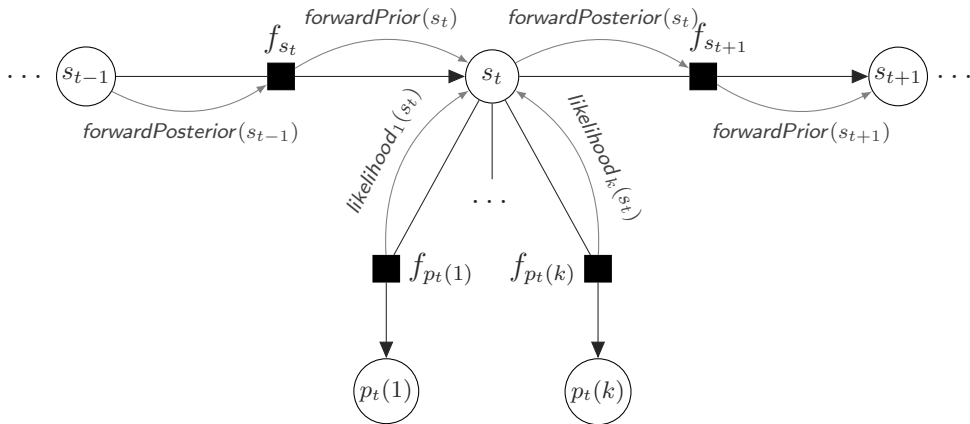
Modelos de historia completa

Smoothing



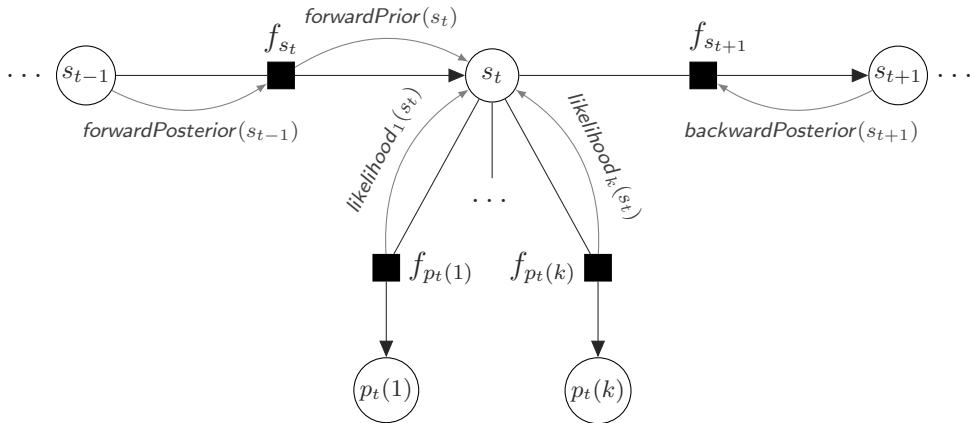
Modelos de historia completa

Smoothing




Modelos de historia completa

Smoothing



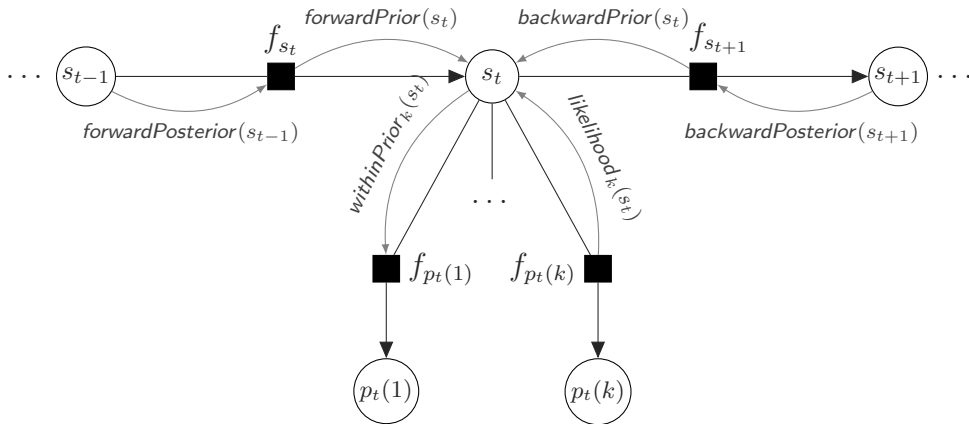
Modelos de historia completa

Smoothing



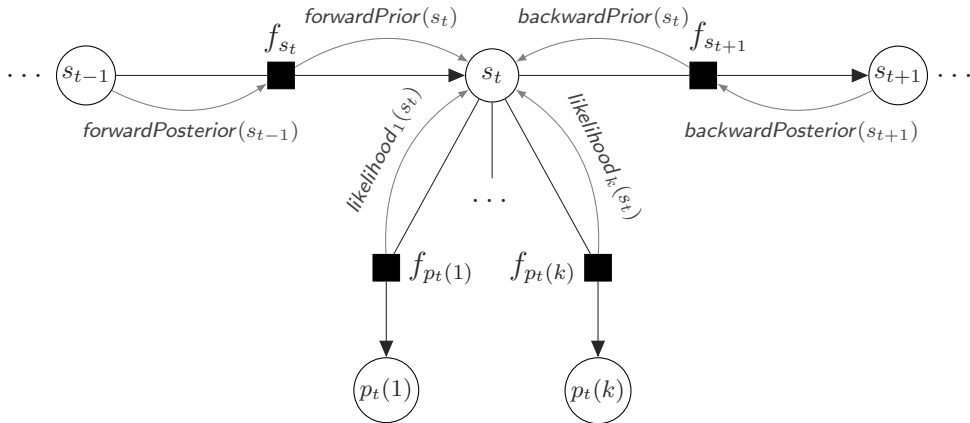
Modelos de historia completa

Smoothing



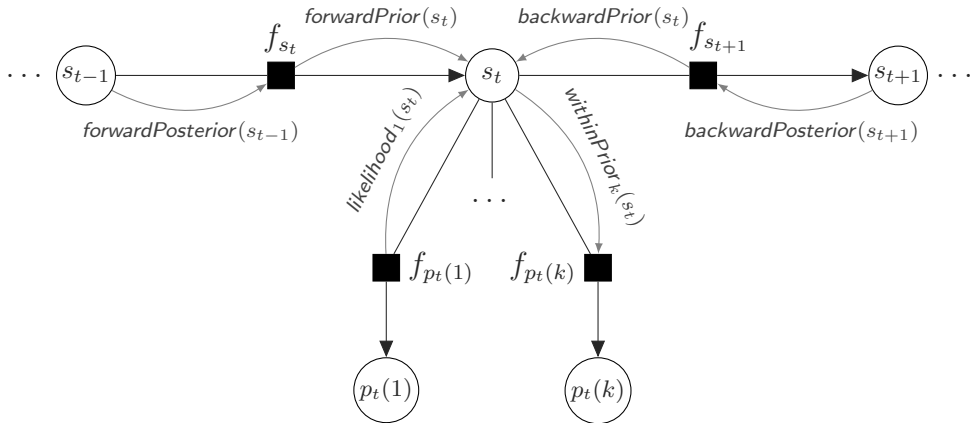
Modelos de historia completa

Smoothing




Modelos de historia completa

Smoothing



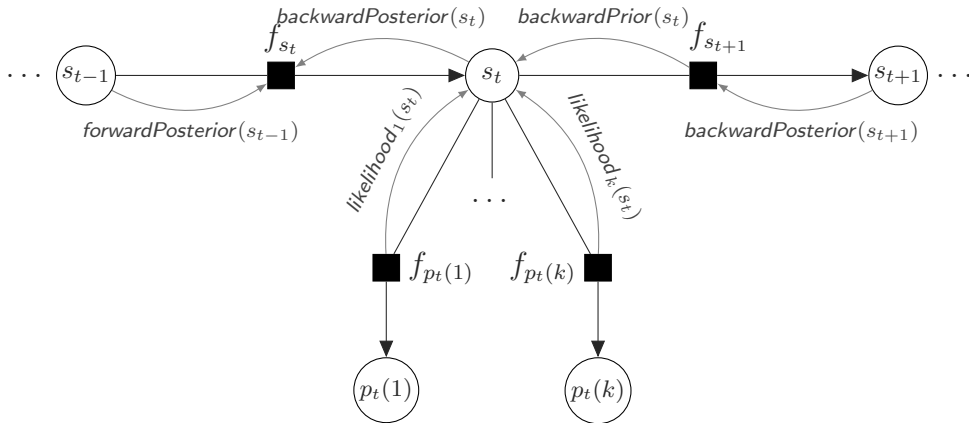
Modelos de historia completa

Smoothing



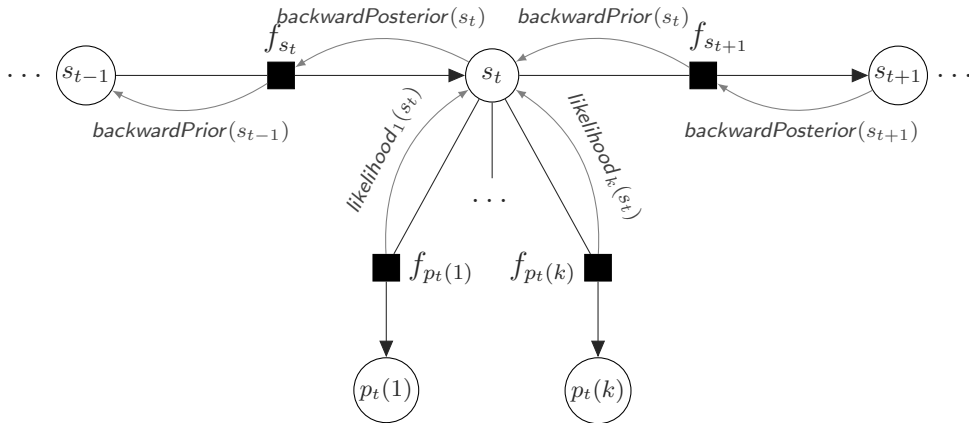
Modelos de historia completa

Smoothing



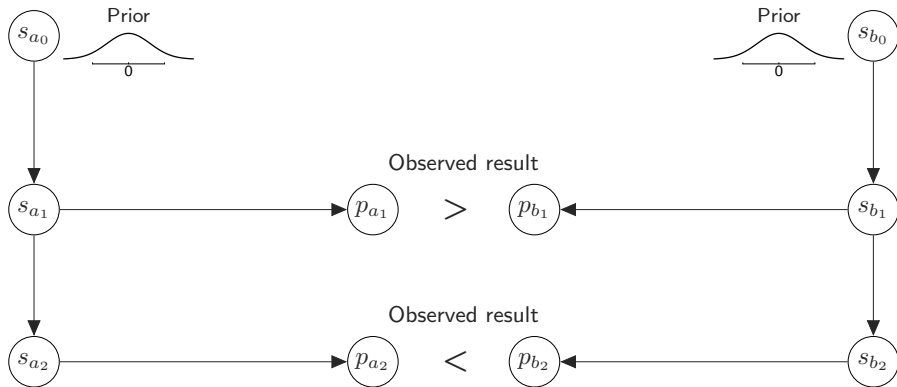
Modelos de historia completa

Smoothing



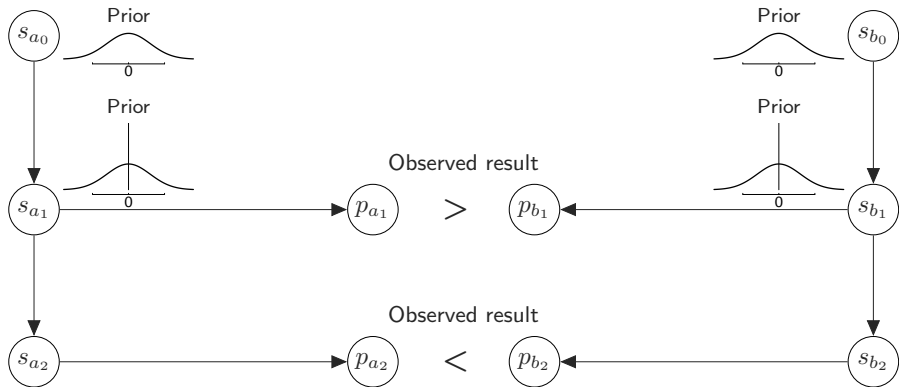
Modelos de historia completa

Smoothing



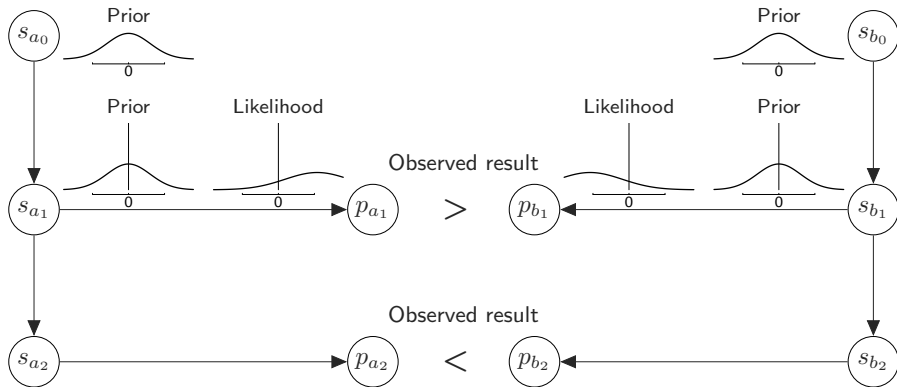
Modelos de historia completa

Smoothing



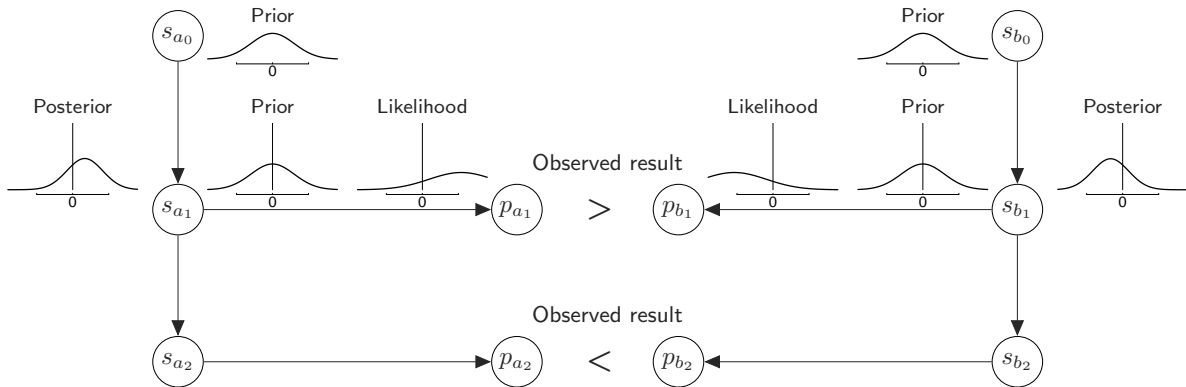
Modelos de historia completa

Smoothing



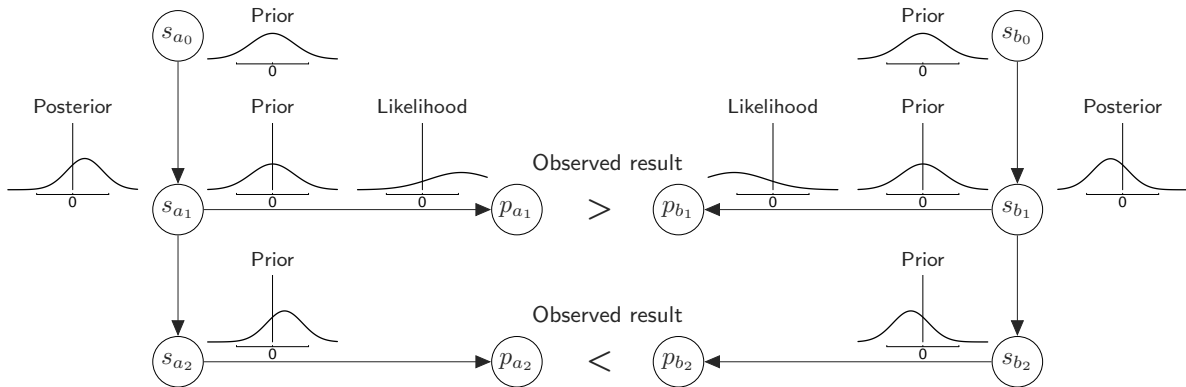
Modelos de historia completa

Smoothing



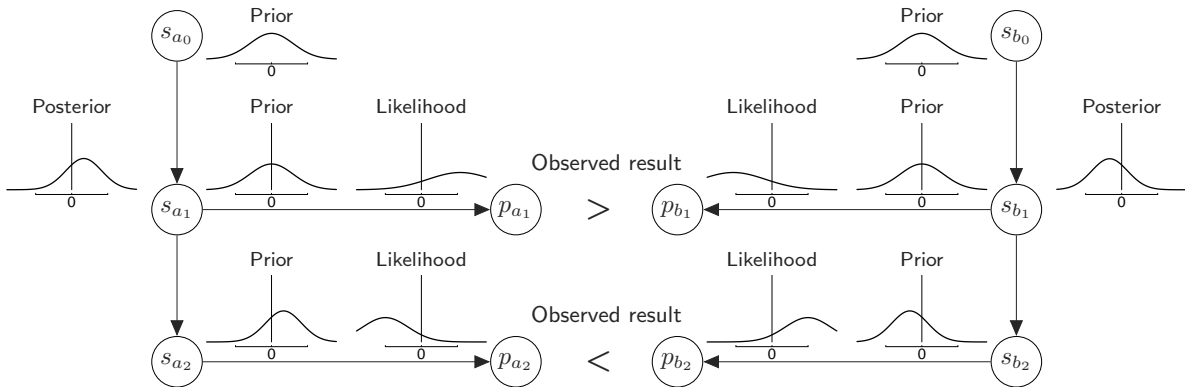
Modelos de historia completa

Smoothing



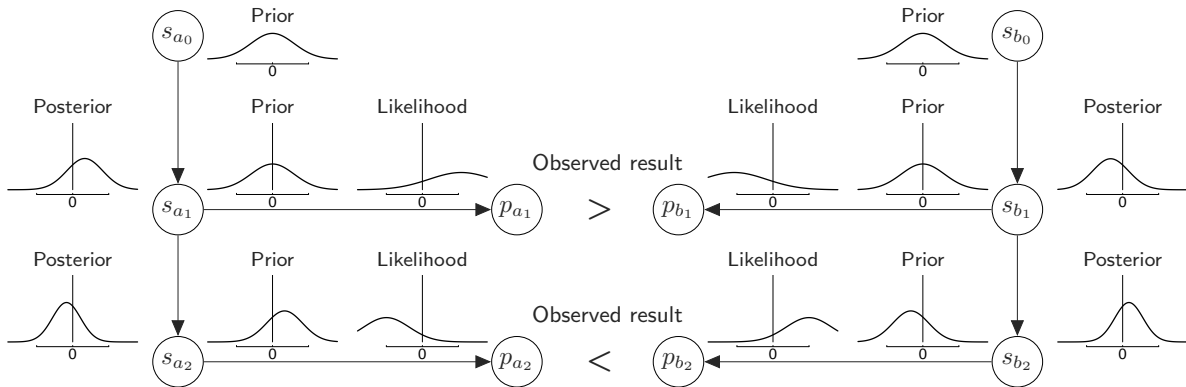
Modelos de historia completa

Smoothing



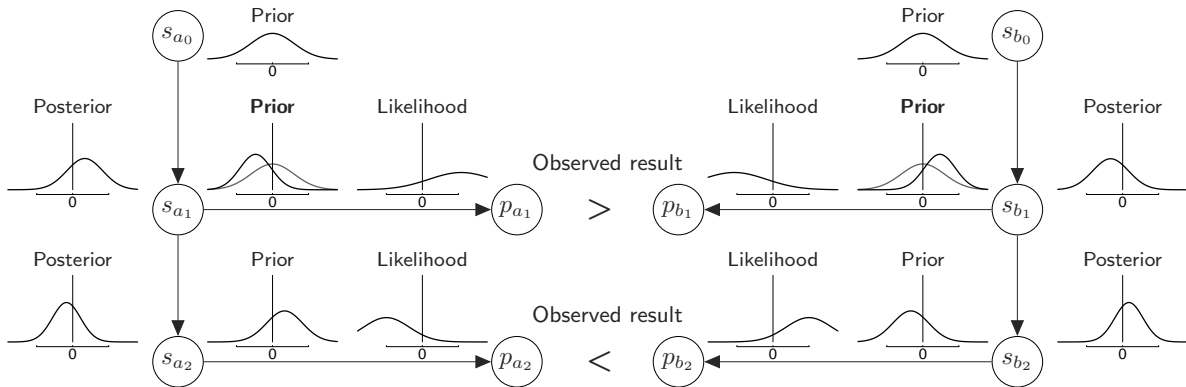
Modelos de historia completa

Smoothing



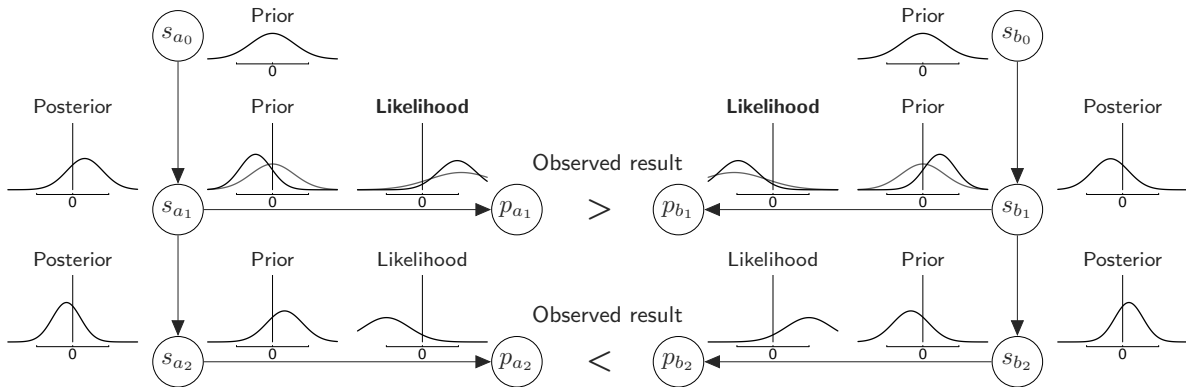
Modelos de historia completa

Smoothing



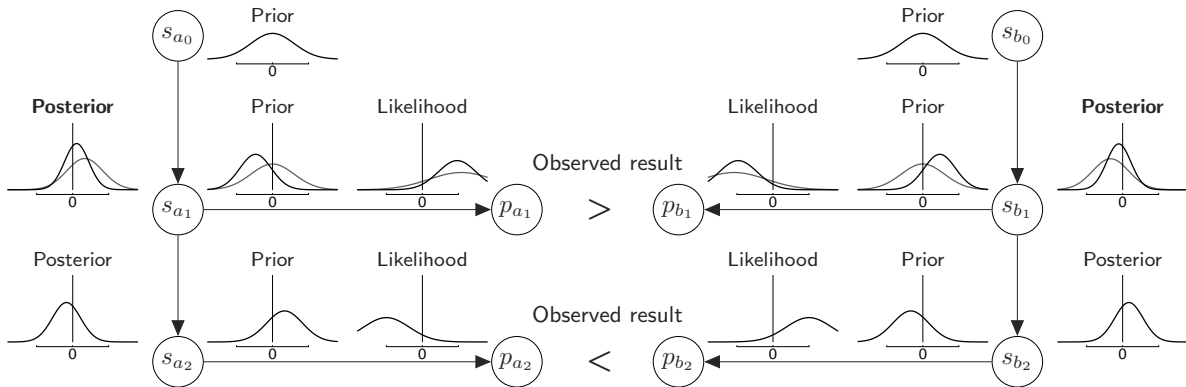
Modelos de historia completa

Smoothing



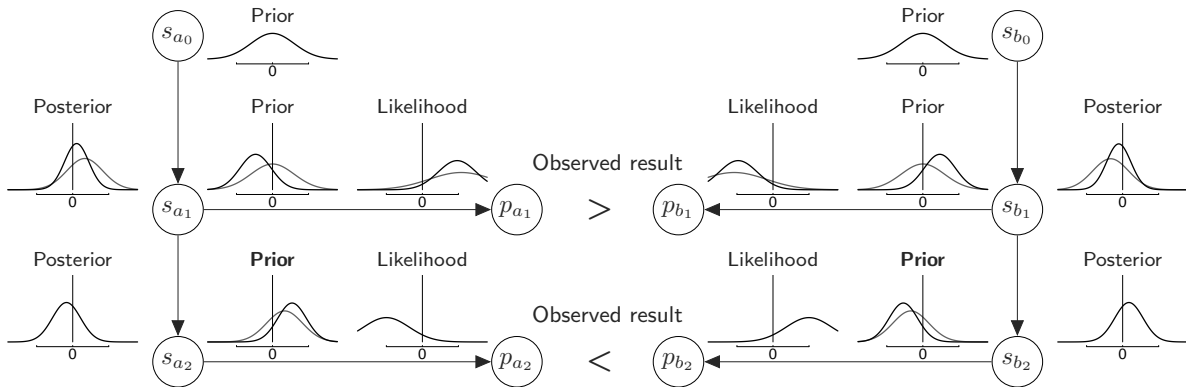
Modelos de historia completa

Smoothing



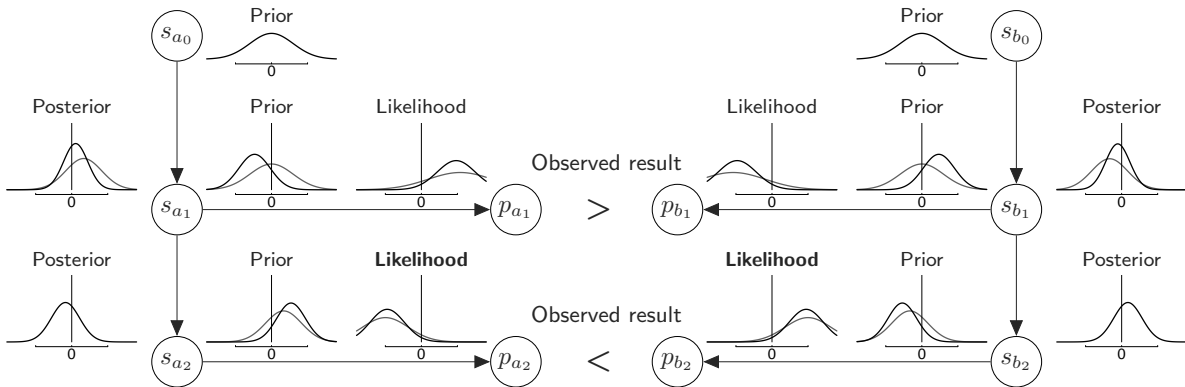
Modelos de historia completa

Smoothing



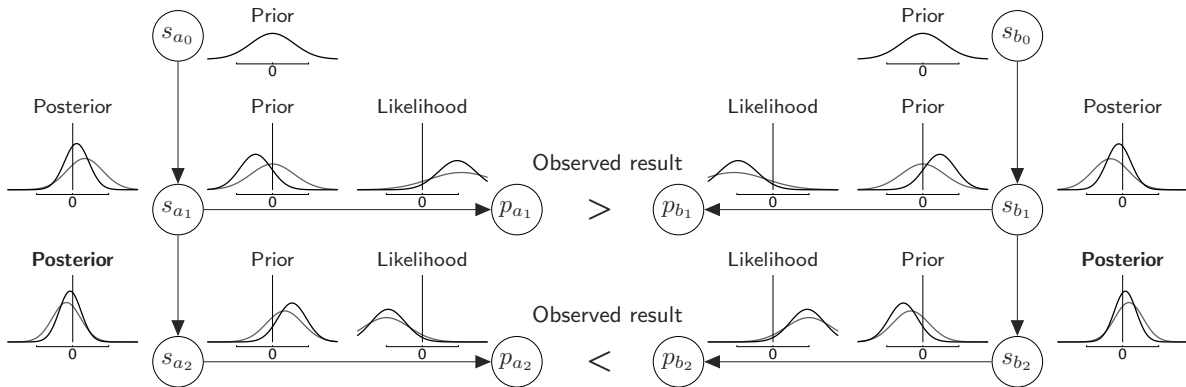
Modelos de historia completa

Smoothing



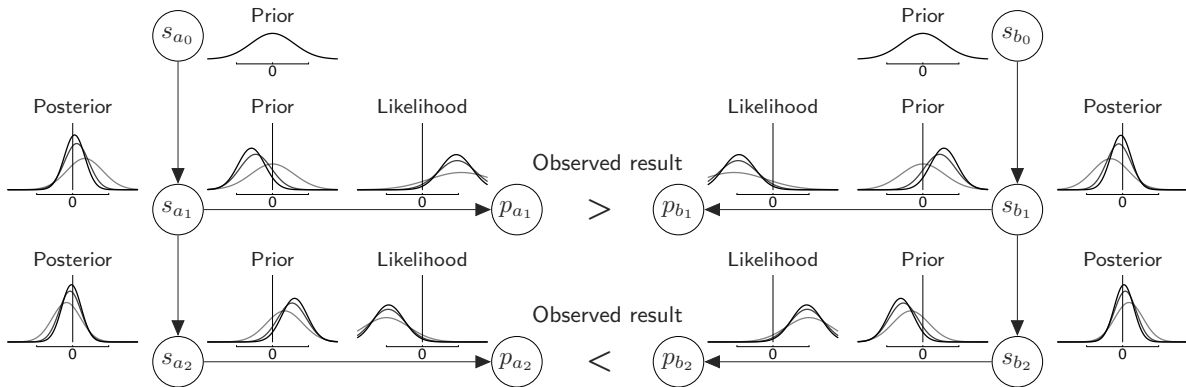
Modelos de historia completa

Smoothing



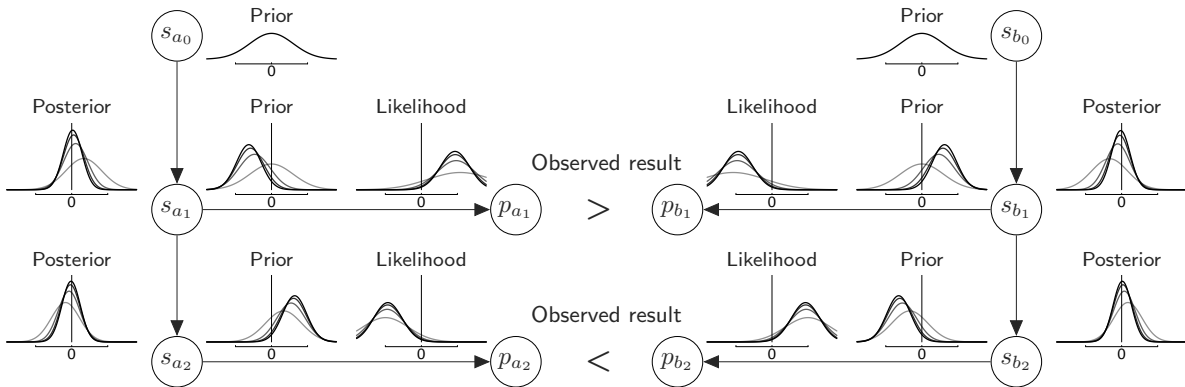
Modelos de historia completa

Smoothing



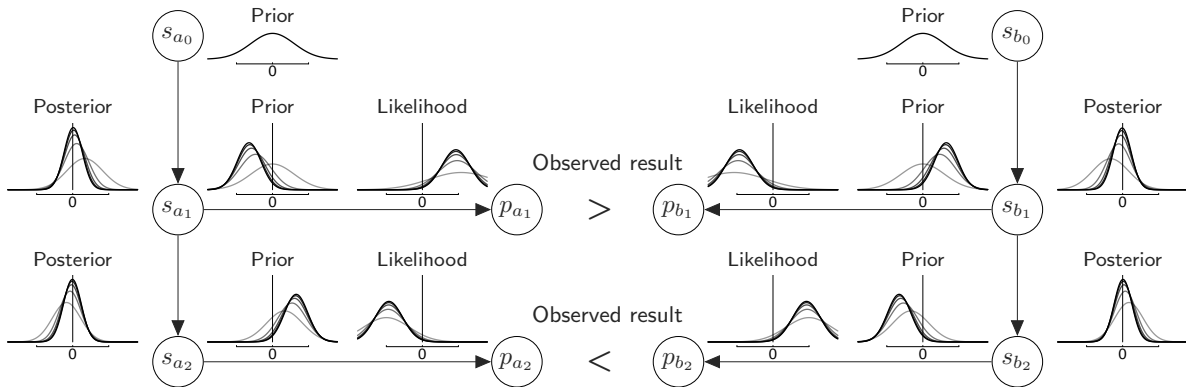
Modelos de historia completa

Smoothing



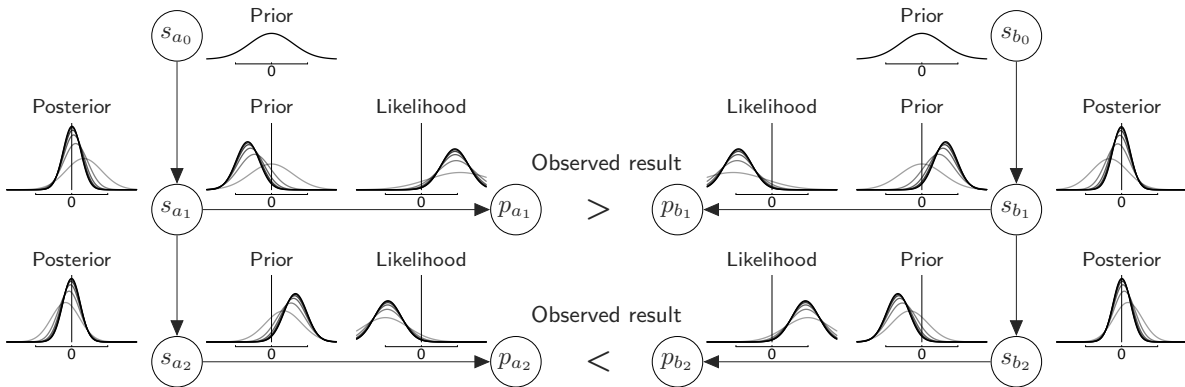
Modelos de historia completa

Smoothing



Modelos de historia completa

Smoothing



TrueSkill Through Time

Estado del arte en la industria del videojuego.



python™



TrueSkill Through Time

Estado del arte en la industria del videojuego.


```
using CSV; using Dates
using TrueSkillThroughTime
global const ttt = TrueSkillThroughTime

data = CSV.read("atp.csv")
dates = Dates.value.(data[:, "time_start"] .- Date("1900-1-1"))

matches = [ r.double == "t" ? [[r.w1_id, r.w2_id], [r.l1_id, r.l2_id]] :
            [[r.w1_id], [r.l1_id]] for r in eachrow(data) ]
h = History(composition = matches, times = dates, sigma = 1.6, gamma = 0.036)
convergence(h, epsilon = 0.01, iterations = 10)
```


TrueSkill Through Time

Estado del arte en la industria del videojuego.




Efecto causal en series temporales


Efecto causal temporal




Efecto causal temporal



Efecto causal temporal




Efecto causal temporal



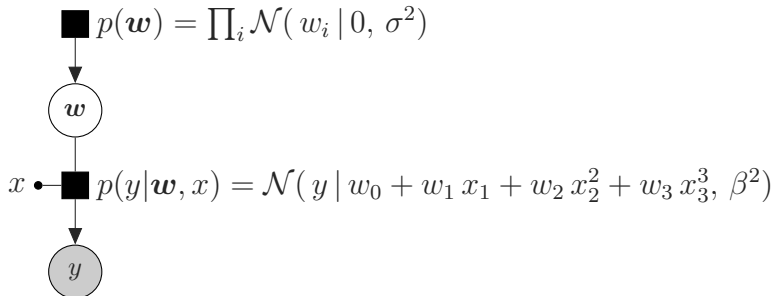
Efecto causal temporal

El control sintético



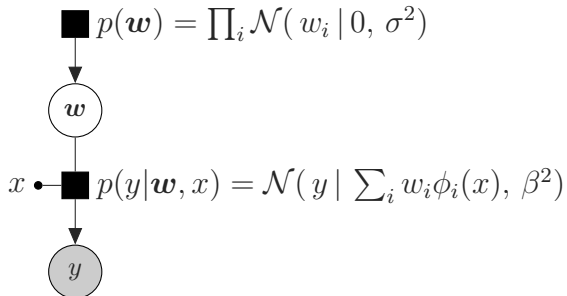
Modelos lineales para series temporales

Modelo lineal básico



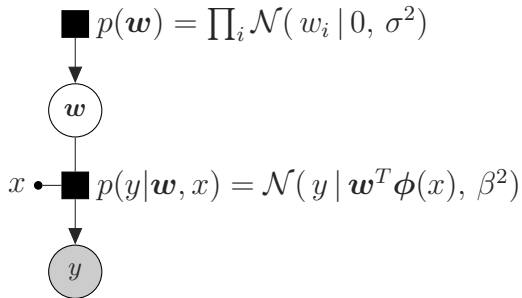
Modelos lineales para series temporales

Modelo lineal básico



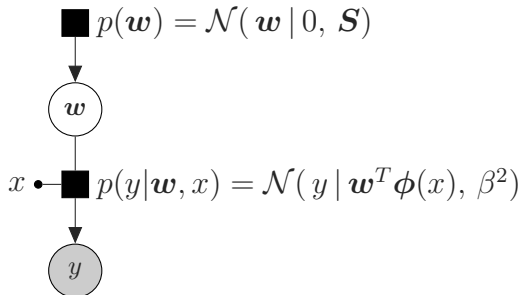
Modelos lineales para series temporales

Modelo lineal básico




Modelos lineales para series temporales

Modelo lineal básico



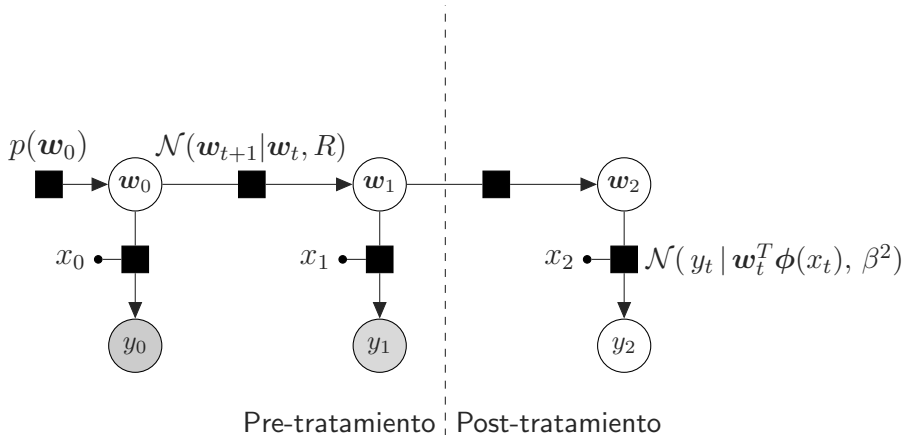
Modelos lineales para series temporales

Structural state-space models



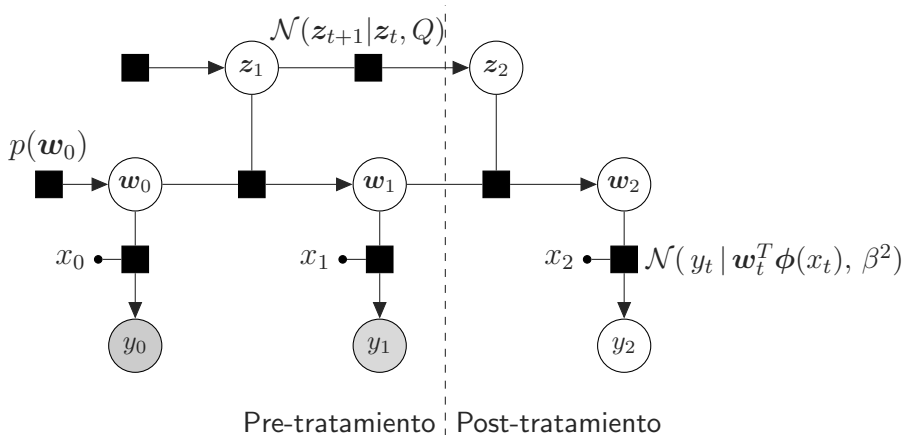
Modelos lineales para series temporales

Structural state-space models



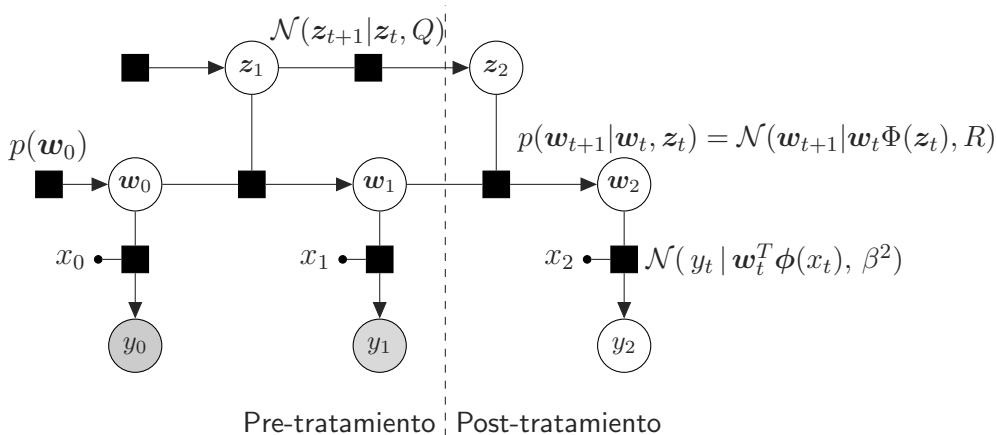
Modelos lineales para series temporales

Structural state-space models



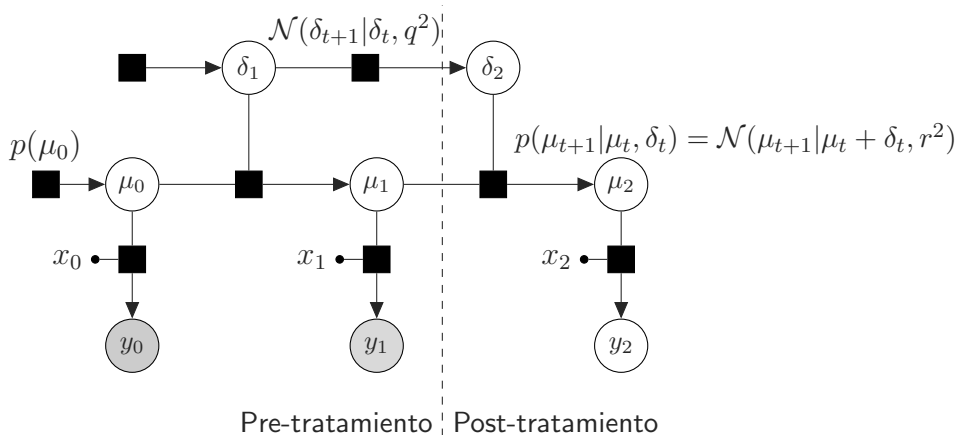
Modelos lineales para series temporales

Structural state-space models



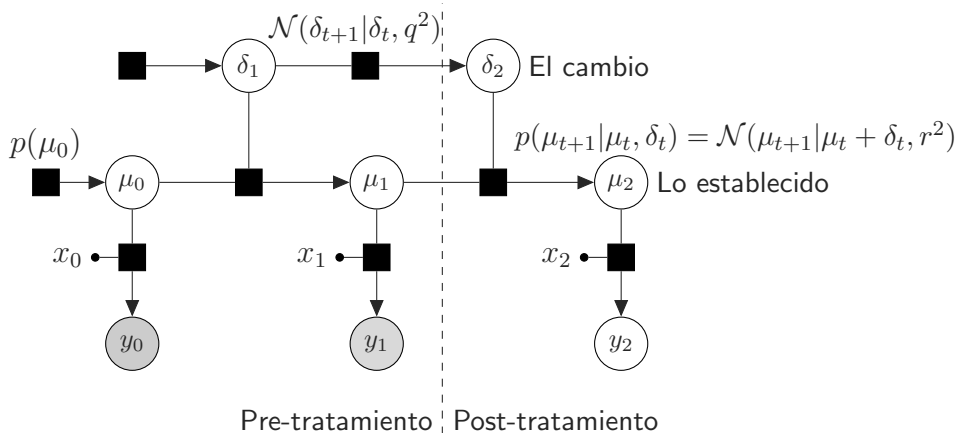
Modelos lineales para series temporales

Tendencia lineal local



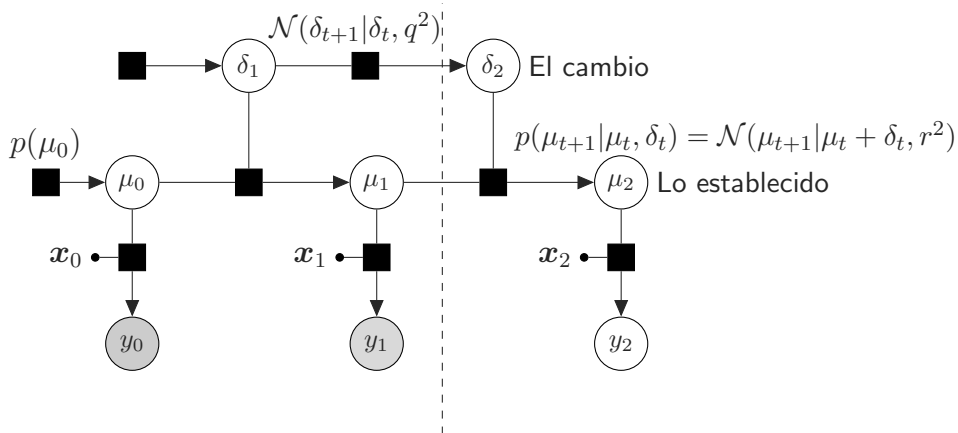
Modelos lineales para series temporales

Tendencia lineal local



Modelos lineales para series temporales

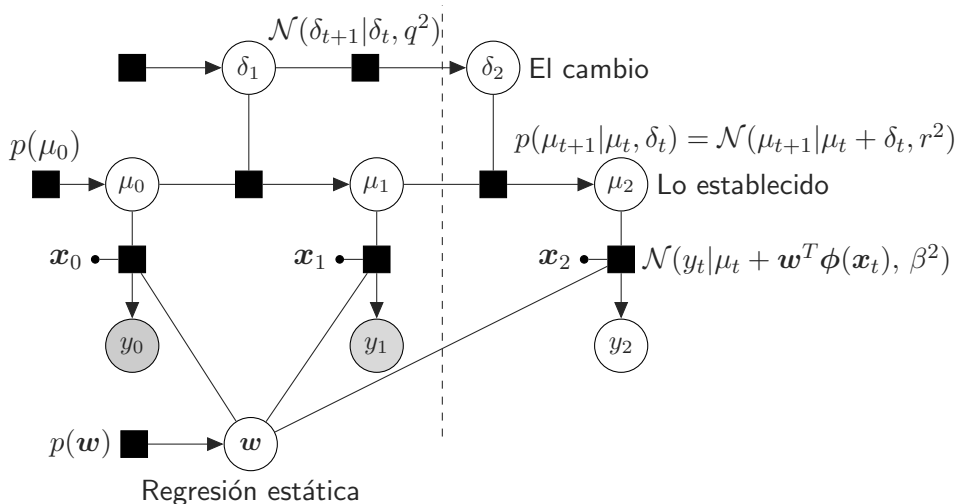
Tendencia lineal local



¿Y la relación con otras series temporales?

Modelos lineales para series temporales

Tendencia lineal local + controles externos



Modelos lineales para series temporales


Ejemplo. Generación de datos.

```
set.seed(1)
x <- 100 + arima.sim(model = list(ar = 0.999), n = 100)
y <- 1.2 * x + rnorm(100)
y[71:100] <- y[71:100] + 10 # Intervencion
```

Modelos lineales para series temporales

Ejemplo. Generación de datos.

```
set.seed(1)
x <- 100 + arima.sim(model = list(ar = 0.999), n = 100)
y <- 1.2 * x + rnorm(100)
y[71:100] <- y[71:100] + 10 # Intervencion
```




Modelos lineales para series temporales

Ejemplo. Inferencia.

```
library("CausalImpact")  
# Google "Inferring causal impact using  
# bayesian structural time-series models"  
  
data <- cbind(y, x)  
pre.period <- c(1, 70)  
post.period <- c(71, 100)  
impact <- CausalImpact(data, pre.period, post.period)
```

Modelos lineales para series temporales

Ejemplo. Inferencia.



Limitaciones

Modelo lineal

La transformaciones no-lineales $\Phi(x)$ están fijas.

$$f(x, \boldsymbol{w}) = \boldsymbol{w}^T \Phi(x)$$

Limitaciones

Modelo lineal

Las transformaciones no-lineales $\Phi(x)$ están fijas.

$$f(x, \mathbf{w}) = \mathbf{w}^T \Phi(x)$$

Necesitaríamos infinitos modelos
para poder representar cualquier función!

Procesos Gaussianos

Evaluación de infinitos modelos $f(\boldsymbol{x})$

$p(y_i) = \mathcal{N}(y_i | f(\boldsymbol{x}_i), \beta^2)$ donde f es la función objetivo

Prior sobre los modelos:

$$f(\boldsymbol{x}) \sim \mathcal{GP}(m(\boldsymbol{x}), k(\boldsymbol{x}, \boldsymbol{x}'))$$

Procesos Gaussianos

Evaluación de infinitos modelos $f(\mathbf{x})$

$p(y_i) = \mathcal{N}(y_i | f(\mathbf{x}_i), \beta^2)$ donde f es la función objetivo

Prior sobre los modelos:

$$f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}'))$$

$$m(\mathbf{x}) = \mathbb{E}[f(\mathbf{x})]$$

$$k(\mathbf{x}, \mathbf{x}') = \mathbb{E}[(f(\mathbf{x}) - m(\mathbf{x}))(f(\mathbf{x}') - m(\mathbf{x}'))]$$

Procesos Gaussianos

Evaluación de infinitos modelos $f(\mathbf{x})$

$p(y_i) = \mathcal{N}(y_i | f(\mathbf{x}_i), \beta^2)$ donde f es la función objetivo

Prior sobre los modelos:

$$f(\mathbf{x}) \sim \mathcal{GP}(m(\mathbf{x}), k(\mathbf{x}, \mathbf{x}'))$$


$$m(\mathbf{x}) = \mathbb{E}[f(\mathbf{x})]$$

$$k(\mathbf{x}, \mathbf{x}') = \mathbb{E}[(f(\mathbf{x}) - m(\mathbf{x}))(f(\mathbf{x}') - m(\mathbf{x}'))]$$

Posterior sobre los modelos tiene solución analítica!

Procesos Gaussianos

Evaluación de infinitos modelos $f(x)$



Procesos Gaussianos

y Redes Neuronales

Procesos Gaussianos

y Redes Neuronales

Se han demostrado las siguientes equivalencia

Procesos Gaussianos y Redes Neuronales

Se han demostrado las siguientes equivalencia

- Neal, RM. 1994. *Priors for infinite networks*. Universidad de Toronto. Equivalencia entre una red neuronal de una sola capa totalmente conectada infinitamente ancha y los proceso gaussiano.


Procesos Gaussianos

y Redes Neuronales

Se han demostrado las siguientes equivalencia

- Neal, RM. 1994. *Priors for infinite networks*. Universidad de Toronto.
Equivalencia entre una red neuronal de una sola capa totalmente conectada infinitamente ancha y los proceso gaussiano.
- Lee et al (Google Brain). 2018. *Deep Neural Networks as Gaussian Process*.
International Conference on Learning Representations
Derivan la equivalencia exacta entre redes infinitamente profundas y GPs.


Monty Hall



Monty Hall



Con sesgo

Uniforme?



Monty Hall



Con sesgo



Monty Hall

Con sesgo



Dirichlet(1, 1, 1)



Monty Hall



Con sesgo

Dirichlet(1, 1, 1)



Monty Hall



Con sesgo



Monty Hall

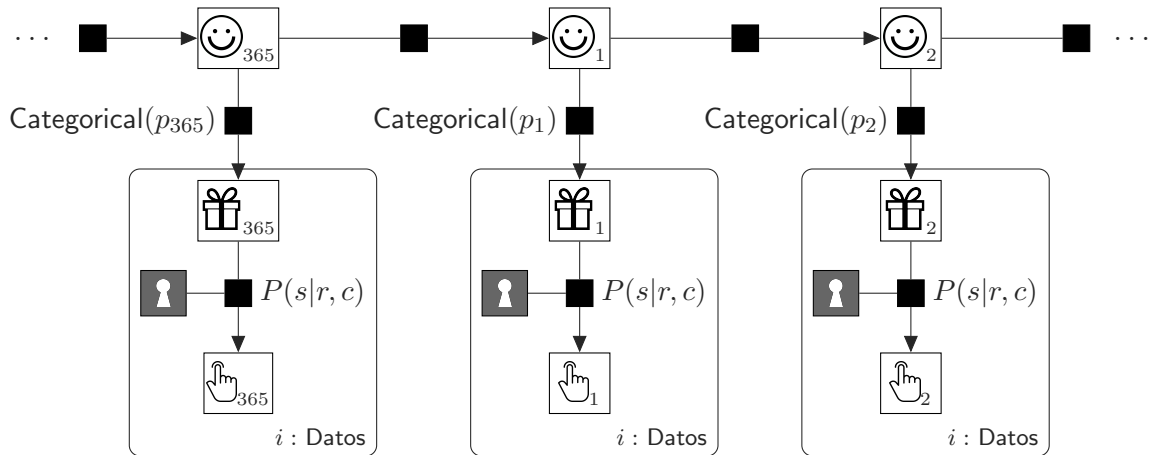
Con sesgo

Dirichlet(2, 5, 15)



Monty Hall

Con sesgo dinámico



$p = \mathbf{b}$

Laboratorios de
Métodos Bayesianos